

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Kết hợp học tăng cường và tối ưu hóa bầy đàn cho bài
toán nhúng mạng ảo đa miền

NGUYỄN VĂN ĐỦ

du.nv224833@sis.hust.edu.vn

Ngành: Khoa học máy tính

Giảng viên hướng dẫn: TS. Đỗ Tuấn Anh

Khoa: Khoa học máy tính

Trường: Công nghệ thông tin và Truyền thông

HÀ NỘI, 06/2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Kết hợp học tăng cường và tối ưu hóa bầy đàn cho bài
toán nhúng mạng ảo đa miền

NGUYỄN VĂN ĐỦ

du.nv224833@sis.hust.edu.vn

Ngành: Khoa học máy tính

Giảng viên hướng dẫn: TS. Đỗ Tuấn Anh

Chữ ký GVHD

Khoa: Khoa học máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2026

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc nhất tới **TS. Đỗ Tuấn Anh**, người đã trực tiếp định hướng đề tài và tận tình đồng hành cùng em trong suốt quá trình thực hiện đồ án này. Thầy không chỉ gợi mở cho em hướng nghiên cứu kết hợp học tăng cường với bài toán nhúng mạng ảo, mà còn kiên nhẫn chỉ bảo từ những vấn đề học thuật cốt lõi cho đến cách trình bày một công trình khoa học sao cho mạch lạc và chặt chẽ. Mỗi buổi trao đổi cùng thầy đều giúp em nhìn nhận vấn đề một cách thấu đáo hơn, biết đặt câu hỏi đúng và rèn cho em tư duy phản biện cũng như tinh thần làm việc nghiêm túc. Những góp ý quý báu và sự động viên kịp thời của thầy, đặc biệt trong những giai đoạn em gặp khó khăn hay bế tắc, là nguồn cổ vũ to lớn giúp em kiên trì hoàn thiện đồ án một cách chẵn chu.

Em cũng xin chân thành cảm ơn quý thầy cô trong **Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội** đã tận tâm giảng dạy và trang bị cho em một nền tảng kiến thức vững chắc trong suốt những năm học vừa qua. Những kiến thức nền tảng về mạng máy tính, thuật toán, trí tuệ nhân tạo và học máy mà các thầy cô truyền đạt chính là cơ sở để em tiếp cận và giải quyết bài toán đặt ra trong đồ án này. Em cũng trân trọng cảm ơn nhà trường đã tạo một môi trường học tập và nghiên cứu năng động, giàu tính kích lệ, nơi em được trau dồi cả về chuyên môn lẫn thái độ làm việc.

Em xin gửi lời cảm ơn tới các anh chị, bạn bè đã cùng em học tập, thảo luận và chia sẻ kinh nghiệm trong quá trình nghiên cứu. Những trao đổi tưởng chừng nhỏ nhặt nhưng nhiều lúc lại giúp em tháo gỡ được những vướng mắc và có thêm góc nhìn mới cho công việc của mình.

Cuối cùng, em xin dành lời cảm ơn sâu sắc nhất tới **gia đình** của em, những người đã luôn yêu thương, tin tưởng, động viên và là chỗ dựa tinh thần vững chắc cho em trong suốt quãng thời gian học tập cũng như khi thực hiện và hoàn thành đồ án tốt nghiệp. Sự ủng hộ vô điều kiện của gia đình là động lực lớn nhất để em vững bước trên con đường đã chọn.

Do thời gian và kiến thức còn hạn chế, đồ án khó tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý của quý thầy cô để công trình được hoàn thiện hơn.

Em xin chân thành cảm ơn!

TÓM TẮT NỘI DUNG ĐỒ ÁN

Bài toán nhúng mạng ảo (Virtual Network Embedding - VNE) là bài toán nền tảng của ảo hoá mạng, đòi hỏi ánh xạ mỗi yêu cầu mạng ảo lên hạ tầng vật lý sao cho thoả mãn ràng buộc tài nguyên và tối ưu hiệu quả phục vụ. VNE đã được chứng minh là NP-Hard, và các kịch bản thực tế còn phức tạp hơn do tính trực tuyến và quy mô lớn. Các phương pháp heuristic chạy nhanh nhưng phụ thuộc tri thức chuyên gia và khó tổng quát hoá; các phương pháp học tăng cường gần đây khắc phục được điều này nhưng thường bất ổn định, tốn mẫu và bỏ qua tri thức tô-pô sẵn có.

Đồ án đề xuất *CARL-VNE* (Candidate-Anchored Reinforcement Learning for Virtual Network Embedding), một phương pháp kết hợp mạng nơ-ron đồ thị với học tăng cường cho VNE đa miền. Phương pháp dùng một bộ mã hoá đồ thị *phân cấp* (GCN nội miền kết hợp GCN liên miền) và một bộ giải mã chọn ứng viên dựa trên cơ chế cross-attention có tích hợp đặc trưng chi phí tường minh (cost-aware). Quy trình huấn luyện gồm hai giai đoạn: khởi động bằng học bắt chước từ heuristic MP-VNE, rồi tinh chỉnh bằng phương pháp actor-critic có neo Kullback-Leibler. Đóng góp cốt lõi là phát hiện rằng *lựa chọn ứng viên* mới là đòn bẩy hiệu quả của học tăng cường, và việc làm cho lựa chọn này ngẫu nhiên trong huấn luyện là điều kiện cần để vượt trần hiệu năng của mô hình bắt chước.

Thực nghiệm trên bộ dữ liệu 50 nút cho thấy phương pháp đề xuất vượt heuristic MP-VNE ở 19/21 bộ dữ liệu phân phối yêu cầu mạng ảo (tại bộ dữ liệu trung tâm đạt 32,7% tỉ lệ chấp nhận so với 25,5% của MP-VNE), cho thấy ưu thế bền vững trên một dải điều kiện vận hành rộng, đồng thời quá trình huấn luyện hội tụ ổn định.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

ABSTRACT

Virtual Network Embedding (VNE) is a fundamental problem in network virtualization: each virtual network request must be mapped onto a shared physical substrate so as to satisfy resource constraints while optimizing service efficiency. VNE is NP-Hard, and real deployments are harder still due to their online nature and large scale. Heuristic methods are fast but rely on expert knowledge and generalize poorly; recent reinforcement-learning (RL) methods overcome this but tend to be unstable, sample-inefficient, and ignore readily available topological knowledge.

This thesis proposes *CARL-VNE* (Candidate-Anchored Reinforcement Learning for Virtual Network Embedding), a method that combines graph neural networks with reinforcement learning for multi-domain VNE. It uses a *hierarchical* graph encoder (intra-domain GCN combined with an inter-domain GCN) and an attention-based candidate decoder with an explicit cost bias and a hard feasibility mask. Training proceeds in two stages: an imitation-learning warm-start from the MP-VNE heuristic, followed by actor-critic fine-tuning with a Kullback-Leibler anchor. The core contribution is the finding that *candidate selection* is the effective lever for RL, and that making this selection stochastic during training is necessary to surpass the imitation ceiling.

Experiments on the 50-node scenario show that the proposed method outperforms the MP-VNE heuristic on 19 of 21 VNR-distribution scenarios (reaching 32.7% acceptance versus 25.5% at the central scenario), demonstrating a robust advantage across a wide range of operating conditions while converging stably during training.

MỤC LỤC

MỞ ĐẦU.....	1
CHƯƠNG 1. NỀN TẢNG LÝ THUYẾT	4
1.1 Học tăng cường sâu.....	4
1.1.1 Quá trình quyết định Markov.....	4
1.1.2 Policy gradient và Actor-Critic	4
1.1.3 Tối ưu hoá chính sách gần kề (PPO).....	5
1.2 Mạng nơ-ron đồ thị.....	5
1.2.1 Cơ chế truyền tin.....	5
1.2.2 Graph Convolutional Network.....	6
1.2.3 Graph Attention Network.....	6
1.3 Cơ chế attention cho lựa chọn ứng viên.....	6
CHƯƠNG 2. BÀI TOÁN NHÚNG MẠNG ẢO ĐA MIỀN	8
2.1 Các hướng tiếp cận cho bài toán VNE.....	8
2.1.1 Lời giải tối ưu và cận tối ưu.....	8
2.1.2 Hướng heuristic	8
2.1.3 Hướng metaheuristic	9
2.1.4 Hướng học tăng cường.....	9
2.1.5 Nhúng mạng ảo đa miền và so sánh	9
2.2 Mạng vật lý đa miền và mạng ảo	10
2.3 Hai pha: ánh xạ nút và ánh xạ liên kết.....	11
2.4 Hàm mục tiêu và độ đo hiệu năng	11
2.5 Phát biểu bài toán dưới dạng ILP.....	12

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT.....	13
3.1 Tổng quan giải pháp.....	13
3.1.1 Ba nguyên lý thiết kế.....	13
3.1.2 Sơ đồ khối hệ thống	14
3.1.3 Luồng tương tác môi trường - tác nhân.....	14
3.2 Bộ mã hoá đồ thị (Graph Encoder)	15
3.2.1 Mã hoá mạng vật lý phân cấp	15
3.2.2 Mã hoá yêu cầu mạng ảo	15
3.2.3 Trộn biểu diễn substrate và VNR	16
3.2.4 Phân tích thiết kế.....	16
3.3 Bộ giải mã chọn ứng viên (Candidate Decoder).....	16
3.3.1 Sinh tập ứng viên cho mỗi nút ảo.....	16
3.3.2 Cơ chế attention chọn ứng viên.....	16
3.3.3 Lựa chọn ngẫu nhiên khi huấn luyện và tắt định khi suy diễn	17
3.3.4 Ánh xạ liên kết.....	17
3.3.5 Triển khai qua PSO và multi-restart	18
3.3.6 Tính toán xác suất hành động hợp thành.....	19
3.4 Môi trường học tăng cường.....	20
3.4.1 Không gian trạng thái	20
3.4.2 Không gian hành động.....	20
3.4.3 Hàm phần thưởng.....	20
3.4.4 Cơ chế xử lý hành động không hợp lệ.....	20
3.5 Quy trình huấn luyện hai giai đoạn	21
3.5.1 Giai đoạn 1: Tiền huấn luyện có giám sát từ MP-VNE	21
3.5.2 Giai đoạn 2: Tinh chỉnh bằng actor-critic có neo KL	21
3.5.3 Mã giả thuật toán huấn luyện tổng thể.....	22

3.5.4 Các thủ thuật ổn định	22
3.6 Phân tích lý thuyết	22
3.6.1 Độ phức tạp tính toán	23
3.6.2 Độ phức tạp bộ nhớ	24
3.6.3 Phân tích hội tụ	24
CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM.....	26
4.1 Cấu hình thực nghiệm	26
4.1.1 Phần cứng và phần mềm	26
4.1.2 Tập dữ liệu	26
4.1.3 Siêu tham số huấn luyện	27
4.2 Baseline và độ đo	28
4.2.1 Các thuật toán so sánh	28
4.2.2 Độ đo đánh giá	28
4.3 Kết quả trên các bộ dữ liệu phân phối VNR.....	28
4.4 Phân tích robustness theo phân phối VNR.....	29
4.5 Quá trình huấn luyện hội tụ	33
4.5.1 Giai đoạn học bắt chước	33
4.5.2 Giai đoạn tinh chỉnh tăng cường	34
4.6 Thảo luận.....	35
KẾT LUẬN	37
TÀI LIỆU THAM KHẢO.....	41
PHỤ LỤC.....	43
A. CHI TIẾT KIẾN TRÚC, SIÊU THAM SỐ VÀ KẾT QUẢ.....	43
A.1 Chi tiết tham số mạng chính sách	43
A.2 Cấu hình kiến trúc chi tiết.....	43
A.3 Kết quả chi tiết theo epoch trên bộ dữ liệu 50 nút.....	44

B. CHI TIẾT TẬP DỮ LIỆU VÀ THUẬT TOÁN SO SÁNH	45
B.1 Chi tiết sinh tập dữ liệu.....	45
B.2 Tham số các thuật toán so sánh	46

DANH MỤC HÌNH VẼ

Hình 3.1	Kiến trúc tổng thể của CARL-VNE (khối tô đậm được huấn luyện bằng RL).	14
Hình 4.1	Tỉ lệ chấp nhận trên năm trục phân phối VNR (50 nút).	30
Hình 4.2	Bốn độ đo theo trục thời gian sống VNR (50 nút; tím: CARL-VNE, đỏ: MP-VNE).	31
Hình 4.3	Bốn độ đo theo trục kích thước VNR (50 nút).	31
Hình 4.4	Bốn độ đo theo trục mật độ liên kết VNR (50 nút).	32
Hình 4.5	Bốn độ đo theo trục nhu cầu tài nguyên (50 nút).	32
Hình 4.6	Bốn độ đo theo trục ràng buộc miền (50 nút).	33
Hình 4.7	Hội tụ giai đoạn học bắt chước (50 nút): mất mát cross-entropy, tỉ lệ thành công của lời giải mẫu, và tỉ lệ nút đích nằm trong tập ứng viên.	34
Hình 4.8	Các chỉ báo hội tụ giai đoạn tinh chỉnh tăng cường (50 nút): mất mát, KL, entropy, tỉ lệ thành công.	34
Hình 4.9	Tỉ lệ chấp nhận theo epoch khi tinh chỉnh tăng cường (test 50 nút).	35
Hình 4.10	Phần thưởng trung bình theo epoch khi tinh chỉnh tăng cường (50 nút).	35

DANH MỤC BẢNG BIỂU

Bảng 2.1	So sánh các hướng tiếp cận VNE	10
Bảng 4.1	Tham số bộ dữ liệu trung tâm (50 nút)	27
Bảng 4.2	Siêu tham số huấn luyện CARL-VNE	27
Bảng 4.3	Tỉ lệ chấp nhận (%) trên toàn bộ 21 bộ dữ liệu 50 nút: CARL-VNE so với MP-VNE (3000 VNR kiểm thử mỗi bộ dữ liệu)	29
Bảng A.1	Phân bố tham số theo khối của mạng chính sách	43
Bảng A.2	Tham số cấu hình kiến trúc	43
Bảng A.3	Kết quả CARL-VNE theo epoch (giai đoạn tinh chỉnh tăng cường, 50 nút)	44
Bảng B.1	Khoảng tham số sinh mạng vật lý (bộ dữ liệu 50 nút)	45
Bảng B.2	Khoảng tham số sinh yêu cầu mạng ảo	45
Bảng B.3	Tham số PSO của baseline MP-VNE	46

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
CARL-VNE	Phương pháp đề xuất của đồ án: học tăng cường chọn ứng viên có neo KL (Candidate-Anchored Reinforcement Learning for VNE)
CPU	Đơn vị xử lý trung tâm (Central Processing Unit)
GAT	Mạng đồ thị chú ý (Graph Attention Network)
GCN	Mạng tích chập đồ thị (Graph Convolutional Network)
GNN	Mạng nơ-ron đồ thị (Graph Neural Network)
ILP	Quy hoạch nguyên tuyến tính (Integer Linear Programming)
InP	Nhà cung cấp hạ tầng (Infrastructure Provider)
MDP	Quá trình quyết định Markov (Markov Decision Process)
MP-VNE	Thuật toán heuristic dựa trên xếp hạng nút (Marking-Probability VNE)
NFV	Ảo hoá chức năng mạng (Network Function Virtualization)
PPO	Thuật toán policy gradient có kẹp tỉ số xác suất (Proximal Policy Optimization)
PSO	Tối ưu hoá bầy hạt (Particle Swarm Optimization)
RL	Học tăng cường (Reinforcement Learning)
SDN	Mạng định nghĩa bằng phần mềm (Software-Defined Networking)

Thuật ngữ	Ý nghĩa
VNE	Bài toán nhúng mạng ảo (Virtual Network Embedding)
VNR	Yêu cầu mạng ảo (Virtual Network Request)

MỞ ĐẦU

Trong vòng hai thập kỷ qua, sự bùng nổ của điện toán đám mây, Internet vạn vật (IoT) và các dịch vụ thời gian thực đã tạo nên áp lực rất lớn lên hạ tầng mạng truyền thống. Mỗi dịch vụ có yêu cầu khác biệt về băng thông, độ trễ và đặc tính bảo mật, dẫn đến nhu cầu chạy nhiều mạng logic độc lập trên cùng một hạ tầng vật lý. Công nghệ **ảo hoá mạng** (Network Virtualization) ra đời nhằm đáp ứng nhu cầu này, đóng vai trò nền tảng cho các kiến trúc *Software-Defined Networking* (SDN) và *Network Function Virtualization* (NFV) hiện đại[1]–[3].

Trong mô hình ảo hoá mạng, nhà cung cấp hạ tầng (Infrastructure Provider - InP) đồng thời phục vụ nhiều nhà cung cấp dịch vụ (Service Provider - SP). Mỗi SP gửi tới InP một *yêu cầu mạng ảo* (Virtual Network Request - VNR) gồm tô-pô nút - cạnh cùng các yêu cầu tài nguyên (CPU cho nút, băng thông cho cạnh). Nhiệm vụ của InP là tìm cách **nhúng** từng VNR lên mạng vật lý sao cho thoả mãn ràng buộc tài nguyên và tối ưu một hàm mục tiêu đã định, chẳng hạn tỉ lệ chấp nhận yêu cầu hay tỉ số doanh thu trên chi phí (R/C)[4], [5].

Bài toán nhúng mạng ảo là cốt lõi của các kịch bản 5G/6G network slicing, multi-tenant cloud và edge computing. Hiệu quả của thuật toán VNE ảnh hưởng trực tiếp tới khả năng tận dụng hạ tầng, chất lượng dịch vụ và doanh thu của nhà cung cấp. Mặt khác, VNE đã được chứng minh là NP-Hard [6]: ngay cả phiên bản ánh xạ nút đơn lẻ đã quy được về bài toán Multi-Way Separator Problem, do vậy không thể giải tối ưu trong thời gian đa thức ở quy mô thực tế. Tính chất NP-Hard, kết hợp với tô-pô mạng vật lý có thể lên đến hàng trăm nút và VNR đến liên tục theo thời gian, đặt ra một thách thức tính toán rất lớn cho thiết kế thuật toán.

Trong các kịch bản thực tế, bài toán còn phức tạp hơn do tính **trực tuyến**: VNR đến theo phân phối Poisson, có thời gian sống ngẫu nhiên, và quyết định nhúng cho từng VNR phải đưa ra ngay lập tức mà không biết trước các yêu cầu trong tương lai. Một thuật toán tốt phải vừa khai thác hiệu quả tài nguyên hiện tại, vừa giữ “khoảng trống” chiến lược để phục vụ các yêu cầu sau.

Các hướng nghiên cứu hiện nay gồm ba nhóm chính: (i) heuristic/metaheuristic dựa trên tri thức chuyên gia (nhanh, đơn giản nhưng khó tổng quát và dễ rơi vào tối ưu cục bộ), (ii) lập trình toán học ILP (đảm bảo tối ưu nhưng chỉ áp dụng cho bài toán quy mô nhỏ), và (iii) học tăng cường sâu (học chính sách end-to-end nhưng phụ thuộc reward shaping, chưa khai thác tốt tri thức tô-pô và khó hội tụ trong không gian hành động lớn); phần khảo sát chi tiết được trình bày ở Chương 2. Những hạn chế của hướng học tăng cường là động lực chính cho phương pháp đề

xuất trong đồ án.

Mục tiêu và định hướng giải pháp

Trên cơ sở phân tích các hạn chế ở trên, đồ án đặt ra ba mục tiêu cụ thể:

1. **Trích xuất biểu diễn tô-pô đầy đủ** cho cả mạng vật lý và yêu cầu mạng ảo bằng mạng nơ-ron đồ thị (GNN), thay cho các đặc trưng thủ công của heuristic.
2. **Thu hẹp không gian hành động** bằng cơ chế attention chọn tập ứng viên (candidate) cho từng nút ảo, giúp tác nhân tập trung học sự đánh đổi giữa các phương án thực sự khả thi.
3. **Tập dụng tri thức từ heuristic** thông qua giai đoạn tiền huấn luyện có giám sát dựa trên lời giải của heuristic MP-VNE, rồi tinh chỉnh chính sách bằng học tăng cường để vượt qua trần hiệu năng của heuristic.

Định hướng giải pháp tổng thể là xây dựng kiến trúc *CARL-VNE* (Candidate-Anchored Reinforcement Learning for Virtual Network Embedding, học tăng cường chọn ứng viên có neo) gồm một bộ mã hoá đồ thị *phân cấp đa miền* (GCN nội miền kết hợp GCN liên miền), một đầu chọn ứng viên cross-attention cùng một bộ phê bình giá trị, kết hợp với quy trình huấn luyện hai giai đoạn: tiền huấn luyện có giám sát rồi tinh chỉnh bằng phương pháp *actor-critic* (gradient chính sách với phê bình giá trị làm baseline) có neo Kullback-Leibler. Một phát hiện then chốt là *lựa chọn ứng viên* mới là đòn bẩy hiệu quả của học tăng cường, nên toàn bộ tín hiệu học được dồn vào đầu chọn ứng viên. Kết quả là một tác nhân vừa kế thừa các quy luật hợp lý của heuristic, vừa có khả năng tự khám phá những phương án ánh xạ tốt hơn mà heuristic không nhìn thấy.

Đóng góp của đồ án

Đồ án có ba đóng góp chính sau:

1. Đề xuất kiến trúc *CARL-VNE* với bộ mã hoá đồ thị phân cấp đa miền (GCN nội miền + liên miền) kết hợp đầu chọn ứng viên cross-attention tích hợp đặc trưng chi phí tường minh (cost-aware) và mặt nạ khả thi cứng cho ràng buộc CPU.
2. Đề xuất quy trình huấn luyện hai giai đoạn gồm tiền huấn luyện có giám sát từ lời giải của heuristic MP-VNE và tinh chỉnh bằng phương pháp actor-critic (phê bình giá trị làm baseline) có neo Kullback-Leibler, cùng phát hiện rằng lựa chọn ứng viên là đòn bẩy hiệu quả và việc làm cho nó ngẫu nhiên trong huấn luyện là điều kiện cần để vượt trần của mô hình bắt chước.
3. Xây dựng bộ benchmark đa miền 50 nút (chia thành 10 miền) với 21 bộ dữ liệu

phân phối yêu cầu mạng ảo, và tiến hành đánh giá so sánh có hệ thống với baseline heuristic MP-VNE.

Bố cục đồ án

Phần còn lại của báo cáo được tổ chức như sau. Chương 1 trình bày nền tảng lý thuyết, bao gồm các kiến thức về học tăng cường sâu, mạng nơ-ron đồ thị và cơ chế attention. Chương 2 khảo sát các hướng tiếp cận hiện có và hình thức hoá bài toán nhúng mạng ảo đa miền: mô hình mạng vật lý đa miền và mạng ảo, hai pha ánh xạ nút và liên kết, hàm mục tiêu, các độ đo hiệu năng và phát biểu dưới dạng quy hoạch nguyên tuyến tính. Chương 3 trình bày phương pháp đề xuất của đồ án, gồm kiến trúc tổng thể, bộ mã hoá đồ thị, bộ giải mã chọn ứng viên, môi trường học tăng cường, quy trình huấn luyện hai giai đoạn và phân tích lý thuyết về độ phức tạp cùng đặc tính hội tụ. Chương 4 mô tả thiết lập thực nghiệm, các tập dữ liệu, độ đo so sánh và phân tích kết quả. Phần Kết luận tổng kết các kết quả đạt được, các hạn chế còn tồn tại và đề xuất các hướng nghiên cứu tiếp theo.

CHƯƠNG 1. NỀN TẢNG LÝ THUYẾT

Chương này hệ thống hoá các kiến thức nền tảng phục vụ cho phương pháp đề xuất: học tăng cường sâu, mạng nơ-ron đồ thị và cơ chế attention, ba khối nền tảng được sử dụng trong đề án. Phần khảo sát các hướng tiếp cận hiện có cho bài toán và phát biểu hình thức của bài toán được trình bày ở Chương 2.

1.1 Học tăng cường sâu

1.1.1 Quá trình quyết định Markov

Học tăng cường được hình thức hoá qua *Quá trình quyết định Markov* (Markov Decision Process - MDP), một bộ năm

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma),$$

trong đó $\mathcal{S}$ là không gian trạng thái, $\mathcal{A}$ là không gian hành động, $\mathcal{P}(s' | s, a)$ là xác suất chuyển trạng thái, $\mathcal{R}(s, a)$ là hàm phần thưởng, và $\gamma \in [0, 1]$ là hệ số chiết khấu. Một *chính sách* $\pi(a | s)$ là phân phối xác suất trên hành động cho mỗi trạng thái. Mục tiêu của RL là tìm chính sách π^* tối đa hoá kỳ vọng lợi ích tích lũy[7]:

$$J(\pi) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^T \gamma^t \mathcal{R}(s_t, a_t) \right], \quad (1.1)$$

trong đó $\tau = (s_0, a_0, s_1, a_1, \dots)$ là quỹ đạo tương tác. Việc kết hợp RL với mạng nơ-ron sâu (deep reinforcement learning) đã đạt nhiều thành tựu nổi bật, tiêu biểu là kiểm soát ở mức con người trên các trò chơi Atari[8].

Trong bối cảnh VNE, một episode tương ứng với quá trình nhúng một VNR. Trạng thái mô tả mạng vật lý hiện tại và VNR đang xét, hành động là ánh xạ một nút ảo tới một nút vật lý hoặc xếp hạng các nút/liên kết ảo, và phần thưởng được cấp khi VNR đã được ánh xạ hoàn chỉnh và đo bằng tỉ số R/C.

1.1.2 Policy gradient và Actor-Critic

Policy gradient là họ thuật toán RL học chính sách trực tiếp bằng cách tham số hoá $\pi_\theta(a | s)$ với tham số θ và cập nhật theo gradient của $J(\theta)$. Định lý policy gradient[7] chỉ ra:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t \right], \quad (1.2)$$

với $G_t = \sum_{k=t}^T \gamma^{k-t} \mathcal{R}(s_k, a_k)$. REINFORCE[9] là phiên bản đơn giản nhất, ước lượng kỳ vọng bằng trung bình mẫu Monte Carlo. Hạn chế chính của REINFORCE là phương sai gradient cao. Để giảm phương sai mà không gây bias, có thể trừ một *baseline* $b(s)$ độc lập với hành động:

$$\nabla_{\theta} J(\theta) = \mathbb{E} \left[\sum_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \cdot (G_t - b(s_t)) \right]. \quad (1.3)$$

Phương án phổ biến nhất là dùng hàm giá trị $V_{\phi}(s)$ làm baseline, dẫn đến kiến trúc *Actor-Critic* với hai mạng song song: *actor* là chính sách $\pi_{\theta}(a | s)$ quyết định hành động, còn *critic* là hàm giá trị $V_{\phi}(s)$ ước lượng chất lượng trạng thái và được học bằng cách hồi quy về lợi ích thực tế (mất mát bình phương). Lợi thế $A(s, a) = G_t - V_{\phi}(s)$ thay cho G_t giúp giảm phương sai gradient. Đề án này sử dụng baseline phê bình $V_{\phi}(s)$ học được (kiến trúc actor-critic) thay cho baseline trung bình đơn giản, nhằm giảm phương sai mạnh hơn trong các kịch bản phần thưởng cấp ở cuối episode.

1.1.3 Tối ưu hoá chính sách gần kề (PPO)

Proximal Policy Optimization (PPO)[10] là một thuật toán actor-critic cải tiến, cho phép tái sử dụng dữ liệu rollout qua nhiều vòng gradient mà vẫn ổn định. PPO thay mục tiêu gradient chính sách bằng một *hàm mục tiêu thay thế có cắt* (clipped surrogate) dựa trên tỉ số tầm quan trọng $\rho_t(\theta) = \pi_{\theta}(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (1.4)$$

với ϵ là biên cắt (thường 0,2). Phép cắt ngăn chính sách trôi quá xa khỏi chính sách cũ trong một bước cập nhật, đóng vai trò một ràng buộc vùng tin cậy mềm. Đề án sử dụng kiến trúc actor-critic làm phương pháp tinh chỉnh chính, đồng thời cài đặt biến thể PPO có cắt để so sánh (Chương 4).

1.2 Mạng nơ-ron đồ thị

1.2.1 Cơ chế truyền tin

Mạng nơ-ron đồ thị (Graph Neural Network - GNN) học biểu diễn của các nút bằng cơ chế *truyền tin* (message passing). Tại mỗi lớp ℓ , vector biểu diễn $h_v^{(\ell)}$ của mỗi nút v được cập nhật từ biểu diễn của các láng giềng:

$$h_v^{(\ell+1)} = \text{UPDATE}^{(\ell)} \left(h_v^{(\ell)}, \text{AGGREGATE}^{(\ell)} \left(\{h_u^{(\ell)} : u \in \mathcal{N}(v)\} \right) \right). \quad (1.5)$$

Sau L lớp truyền tin, mỗi nút “thấy” được thông tin từ các láng giềng trong bán kính L chằng. Các biến thể GNN khác nhau chủ yếu ở hai hàm AGGREGATE và UPDATE.

1.2.2 Graph Convolutional Network

Graph Convolutional Network (GCN)[11] sử dụng phép trung bình có trọng số trên láng giềng:

$$H^{(\ell+1)} = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(\ell)} W^{(\ell)} \right), \quad (1.6)$$

trong đó $\tilde{A} = A + I$ là ma trận kề có self-loop, $\tilde{D}$ là ma trận đường chéo độ bậc, $H^{(\ell)} \in \mathbb{R}^{|V| \times d_\ell}$ là ma trận biểu diễn, $W^{(\ell)}$ là tham số học được, và σ là hàm kích hoạt phi tuyến (đồ án dùng ReLU). Đồ án sử dụng GCN hai lớp với $H^{(0)} = X$ là ma trận đặc trưng đầu vào của các nút vật lý. Ma trận kề A được trọng số hoá theo tỉ lệ bằng thông còn lại trên dung lượng ban đầu, cho phép mã hoá thông tin trạng thái tài nguyên động vào quá trình truyền tin.

1.2.3 Graph Attention Network

Graph Attention Network (GAT)[12] thay phép trung bình đồng đều bằng phép tổ hợp có trọng số attention học được:

$$h_v^{(\ell+1)} = \sigma \left(\sum_{u \in \mathcal{N}(v) \cup \{v\}} \alpha_{vu}^{(\ell)} \cdot W^{(\ell)} h_u^{(\ell)} \right), \quad (1.7)$$

với hệ số attention

$$\alpha_{vu}^{(\ell)} = \frac{\exp \left(\text{LeakyReLU}(\mathbf{a}^\top [W h_v \| W h_u]) \right)}{\sum_{u' \in \mathcal{N}(v) \cup \{v\}} \exp \left(\text{LeakyReLU}(\mathbf{a}^\top [W h_v \| W h_{u'}]) \right)}. \quad (1.8)$$

GAT có khả năng biểu diễn cao hơn GCN nhờ trọng số học được, đặc biệt khi đồ thị không đồng nhất về vai trò các láng giềng. Tuy nhiên, GCN có ưu điểm về số tham số ít, tốc độ huấn luyện nhanh, và đủ biểu diễn cho các tô-pô mạng vật lý nhỏ - vừa trong VNE. Đồ án này lựa chọn GCN làm bộ mã hoá chính để giữ kiến trúc nhỏ gọn (toàn bộ chính sách chỉ khoảng 36,300 tham số), đồng thời thảo luận lại các đánh đổi với GAT trong phân tích ablation ở Chương 4.

1.3 Cơ chế attention cho lựa chọn ứng viên

Cơ chế *scaled dot-product attention*[13] là khối toán học chuẩn cho việc “một truy vấn chọn từ nhiều khoá”. Cho truy vấn $q \in \mathbb{R}^d$ và tập khoá $K = (k_1, \dots, k_n)$, điểm số cho mỗi khoá là

$$\text{score}(q, k_i) = \frac{q^\top k_i}{\sqrt{d}}. \quad (1.9)$$

Hệ số $\sqrt{d}$ giúp ổn định gradient khi d lớn. Trong bài toán VNE, mỗi nút ảo đóng vai trò truy vấn, mỗi nút vật lý ứng viên đóng vai trò khoá, và điểm số sau khi softmax biểu diễn xác suất chọn từng ứng viên. Đồ án mở rộng cơ chế này bằng cách kết hợp một nhánh MLP dư (residual) để học các tương tác phi tuyến phức tạp giữa đặc trưng của nút ảo và nút vật lý, và sử dụng *feasibility mask* cứng để loại bỏ các ứng viên không thoả mãn ràng buộc CPU ngay tại bước tính điểm. Chi tiết kiến trúc được trình bày ở Chương 3.

Chương này đã hệ thống hoá các nền tảng học tăng cường (MDP, gradient chính sách, actor-critic, PPO), các khối GNN và cơ chế attention. Chương tiếp theo khảo sát các hướng tiếp cận hiện có và phát biểu hình thức bài toán nhúng mạng ảo đa miền.

CHƯƠNG 2. BÀI TOÁN NHÚNG MẠNG ẢO ĐA MIỀN

Chương này khảo sát các hướng tiếp cận hiện có cho bài toán nhúng mạng ảo, rồi hình thức hoá bài toán ở dạng *đa miền* (multi-domain) mà đề án hướng tới. Phần đầu tổng quan các nhóm thuật toán đã được đề xuất cùng ưu nhược của chúng. Các phần sau mô tả mô hình mạng vật lý đa miền và mạng ảo, hai pha ánh xạ nút và liên kết, hàm mục tiêu cùng các độ đo, và phát biểu bài toán dưới dạng quy hoạch nguyên tuyến tính (ILP).

2.1 Các hướng tiếp cận cho bài toán VNE

Bài toán nhúng mạng ảo đã được nghiên cứu rộng rãi trong hơn hai thập kỷ; các khảo sát tổng quan [4], [5] phân loại lời giải thành các nhóm chính trình bày dưới đây.

2.1.1 Lời giải tối ưu và cận tối ưu

Bài toán có thể phát biểu chính xác dưới dạng quy hoạch nguyên (hỗn hợp) tuyến tính [14], [15]. Chowdhury và cộng sự [6] đề xuất *ViNE*, phối hợp pha ánh xạ nút và liên kết thông qua nói lỏng tuyến tính (LP-relaxation) rồi làm tròn tất định hoặc ngẫu nhiên, cải thiện rõ rệt so với việc giải hai pha tách rời. Nhóm phương pháp này cho lời giải chất lượng cao và cung cấp cận trên hữu ích để đối chiếu, nhưng độ phức tạp cấp số mũ khiến chúng chỉ khả thi trên tô-pô rất nhỏ (phân tích ở Mục 2.5), không phù hợp với kịch bản trực tuyến quy mô lớn.

2.1.2 Hướng heuristic

Các thuật toán heuristic xếp hạng nút vật lý theo những độ đo tô-pô đơn giản rồi ánh xạ tham lam. Cheng và cộng sự [16] xếp hạng nút theo *NodeRank* lấy cảm hứng từ PageRank; Gong và cộng sự [17] đề xuất *Global Resource Capacity* (GRC) tổng hợp tài nguyên lan truyền trên toàn đồ thị. Houidi và cộng sự [18] đưa ra thuật toán ánh xạ phân tán, còn Lischka và Karl [19] dùng phát hiện đồng cấu đồ thị con. Yu và cộng sự [20] cho phép *chia đường* (path splitting) và di trú để tăng tỉ lệ chấp nhận. Heuristic được so sánh trực tiếp trong đề án là MP-VNE [21], ước lượng chi phí từng cặp (n^v, n^s) qua công thức tổng hợp giữa chi phí CPU và băng thông trung bình của lán giềng (gọi là PreCost), rồi chọn các nút có chi phí ước lượng thấp nhất làm ứng viên; pha ánh xạ liên kết dùng đường đi ngắn nhất, có thể mở rộng đa đường. Ưu điểm của heuristic là đơn giản, nhanh và chạy được trên hạ tầng lớn; nhược điểm là phụ thuộc nặng vào tri thức chuyên gia, khó thích nghi khi phân phối yêu cầu thay đổi và dễ rơi vào tối ưu cục bộ.

2.1.3 Hướng metaheuristic

Các phương pháp metaheuristic như thuật toán di truyền, tối ưu hoá bầy hạt (Particle Swarm Optimization - PSO) và mô phỏng tối luyện biểu diễn mỗi lời giải ánh xạ nút như một cá thể với hàm thích nghi là chi phí nhúng, rồi tiến hoá qua các thế hệ kèm đột biến để thoát tối ưu cục bộ. MP-VNE [21] kết hợp xếp hạng PreCost với một vòng PSO để tinh chỉnh lựa chọn ứng viên. Hạn chế chung của nhóm này là chi phí tính toán cao (phải đánh giá nhiều phương án mỗi vòng lặp) và thiếu đảm bảo lý thuyết về chất lượng lời giải.

2.1.4 Hướng học tăng cường

Học tăng cường (Reinforcement Learning - RL) coi VNE như một quá trình quyết định tuần tự: tại mỗi bước, tác nhân quan sát trạng thái mạng vật lý và VNR hiện tại, chọn một hành động (ánh xạ một nút ảo) rồi nhận tín hiệu thưởng phản ánh chất lượng lời giải. Mijumbi và cộng sự [22] là một trong những công trình tiên phong áp dụng học tăng cường cho quản lý tài nguyên mạng ảo động. Với sự phát triển của mạng nơ-ron đồ thị [11], [12], [23], nhiều phương pháp kết hợp GNN để mã hoá tô-pô mạng vật lý: A3C-GCN [24] dùng Actor-Critic bất đồng bộ, DeepViNE [25] học biểu diễn từ ảnh đặc trưng tài nguyên, NeuroViNE [26] trích xuất đồ thị con hứa hẹn làm tiền xử lý cho heuristic. Gần đây, FlagVNE [27] đề xuất khung RL tổng quát và linh hoạt cho cấp phát tài nguyên mạng. Một số công trình cũng dùng tìm kiếm cây Monte-Carlo [28] hoặc cơ chế attention cho bài toán định tuyến tổ hợp [29]. Mặc dù nhiều tiềm năng, các phương pháp RL hiện hành cho VNE còn ba hạn chế chính, cũng là động lực trực tiếp cho phương pháp đề xuất: (i) phụ thuộc mạnh vào *reward shaping* chính xác, dễ bất ổn định khi reward thưa; (ii) chưa khai thác tốt tri thức tô-pô có sẵn từ các heuristic mạnh, khiến tác nhân tốn nhiều mẫu để khám phá lại các quy luật đơn giản; và (iii) không gian hành động lớn (chọn một trong hàng trăm nút vật lý cho mỗi nút ảo) làm chính sách khó hội tụ ở tô-pô lớn.

2.1.5 Nhúng mạng ảo đa miền và so sánh

Phần lớn các công trình trên giả định hạ tầng *đơn miền* với thông tin tô-pô và tài nguyên hiển thị toàn cục. Trong thực tế, hạ tầng thường được chia thành nhiều miền quản trị (administrative domain) thuộc các nhà cung cấp khác nhau, nơi thông tin nội miền không được công khai toàn cục mà chỉ trao đổi ở mức tổng hợp [5]. Cấu hình đa miền này đặt thêm hai thách thức: tôn trọng ràng buộc miền của từng nút ảo và tính tối chi phí định tuyến xuyên miền ngay khi ra quyết định ánh xạ. Đồ án tập trung vào cấu hình đa miền, kế thừa heuristic PreCost của MP-VNE làm baseline nhưng thay chính sách xếp hạng/chọn ứng viên thủ công bằng một chính sách học

được tôn trọng cấu trúc đa miền (Chương 3). Bảng 2.1 tổng hợp ưu nhược của các nhóm tiếp cận.

Bảng 2.1: So sánh các hướng tiếp cận VNE

Tiêu chí	Heuristic	Metaheuristic	Học tăng cường
Chất lượng lời giải	Trung bình	Khá	Tốt (khi huấn luyện ổn định)
Thời gian suy diễn	Rất nhanh	Chậm	Nhanh
Khả năng tổng quát hoá	Thấp	Trung bình	Cao
Phụ thuộc tri thức chuyên gia	Cao	Trung bình	Thấp
Chi phí huấn luyện	Không có	Không có	Cao

2.2 Mạng vật lý đa miền và mạng ảo

Mạng vật lý (substrate network) được biểu diễn bằng đồ thị vô hướng có trọng số

$$G^s = (N^s, E^s),$$

trong đó N^s là tập các nút vật lý và E^s là tập các liên kết. Mỗi nút $n^s \in N^s$ được đặc trưng bởi dung lượng CPU $C(n^s)$, đơn giá CPU $P(n^s)$ và độ trễ xử lý $D(n^s)$. Mỗi liên kết $e^s = (u^s, v^s) \in E^s$ được đặc trưng bởi băng thông $B(e^s)$, đơn giá băng thông $P(e^s)$ và độ trễ truyền dẫn $D(e^s)$. Tại thời điểm bất kỳ, tài nguyên còn lại của mỗi nút và liên kết là $C^{\text{avail}}(n^s) \leq C(n^s)$ và $B^{\text{avail}}(e^s) \leq B(e^s)$.

Cấu trúc đa miền. Khác với bài toán VNE đơn miền, mạng vật lý ở đây được chia thành một tập miền quản trị $\mathcal{D} = \{d_1, \dots, d_D\}$. Mỗi miền d là một đồ thị con với các *liên kết nội miền*; các miền nối với nhau qua các *liên kết liên miền* (inter-domain link) giữa những *nút biên* (boundary node). Một giả định cốt lõi của cấu hình đa miền là thông tin chi tiết của các nút bên trong một miền *không hiển thị toàn cục*: chỉ thông tin tổng hợp ở mức miền và các liên kết liên miền được trao đổi giữa các miền. Đây là điểm khác biệt chính so với VNE đơn miền và là yếu tố mà phương pháp đề xuất phải tôn trọng khi thiết kế bộ mã hoá (Chương 3).

Một **yêu cầu mạng ảo** (Virtual Network Request - VNR) bao gồm đồ thị mạng ảo và các thông tin thời gian:

$$\text{VNR} = (G^v, t_a, t_l), \quad G^v = (N^v, E^v),$$

với t_a là thời điểm đến và t_l là thời gian sống. Mỗi nút ảo $n^v \in N^v$ có yêu cầu CPU $c(n^v)$, và mỗi liên kết ảo $e^v = (u^v, v^v) \in E^v$ có yêu cầu băng thông $b(e^v)$. Trong cấu hình đa miền, mỗi nút ảo còn có thể bị ràng buộc bởi tập *miền cho phép* $\mathcal{D}(n^v) \subseteq \mathcal{D}$ (ví dụ do yêu cầu vị trí địa lý hay pháp lý): nút ảo chỉ được ánh xạ vào nút vật lý thuộc một trong các miền này.

2.3 Hai pha: ánh xạ nút và ánh xạ liên kết

Một lời giải nhúng cho VNR là một cặp ánh xạ (f_N, f_E) trong đó:

- **Ánh xạ nút** $f_N : N^v \rightarrow N^s$ thỏa mãn (i) ràng buộc tài nguyên $c(n^v) \leq C^{\text{avail}}(f_N(n^v))$ với mọi n^v , (ii) ràng buộc đơn ánh: $f_N(u^v) \neq f_N(v^v)$ với $u^v \neq v^v$, và (iii) ràng buộc miền $f_N(n^v) \in \mathcal{D}(n^v)$ nếu có.
- **Ánh xạ liên kết** $f_E : E^v \rightarrow \mathcal{P}(E^s)$ ánh xạ mỗi liên kết ảo tới một tập đường đi vật lý nối $f_N(u^v)$ và $f_N(v^v)$, với tổng băng thông trên các đường đi bằng $b(e^v)$ và không vượt quá băng thông còn lại của bất kỳ liên kết vật lý nào.

Do tính chất NP-Hard của bài toán, các phương pháp thực tế thường giải hai pha một cách phối hợp nhưng không đồng thời tối ưu: pha ánh xạ nút sử dụng một chính sách xếp hạng/lựa chọn, sau đó pha ánh xạ liên kết dùng đường đi ngắn nhất hoặc multi-path để hoàn thiện. Đề án này đi theo hướng đó, với cải tiến là sử dụng học tăng cường để học chính sách chọn ứng viên thay cho heuristic cứng, đồng thời lưu ý chi phí định tuyến xuyên miền.

2.4 Hàm mục tiêu và độ đo hiệu năng

Đối với mỗi VNR được nhúng thành công, **doanh thu** (revenue) và **chi phí** (cost) được định nghĩa:

$$\mathcal{R}(\text{VNR}) = \sum_{n^v \in N^v} c(n^v) + \sum_{e^v \in E^v} b(e^v), \quad (2.1)$$

$$\mathcal{C}(\text{VNR}) = \sum_{n^v \in N^v} c(n^v) + \sum_{e^v \in E^v} b(e^v) \cdot \ell(f_E(e^v)), \quad (2.2)$$

trong đó $\ell(\cdot)$ là tổng số chặng vật lý của tập đường đi ánh xạ liên kết ảo. Hai độ đo hiệu năng phổ biến nhất là:

- **Tỉ lệ chấp nhận** (Acceptance Ratio - AR): tỉ số giữa số VNR được nhúng thành công và tổng số VNR đến trong khoảng thời gian khảo sát.
- **Tỉ số doanh thu trên chi phí** (Revenue-to-Cost - R/C): được định nghĩa cho mỗi VNR là $\mathcal{R}(\text{VNR})/\mathcal{C}(\text{VNR})$, đo mức độ “tiết kiệm tài nguyên” khi nhúng. Ở mức hệ thống, R/C tổng được tính bằng tỉ số của tổng doanh thu và tổng chi phí trên toàn bộ VNR đã nhúng.

Ngoài AR và R/C, các độ đo bổ sung gồm thời gian chạy trung bình mỗi VNR, độ trễ trung bình của các đường đi, và độ ổn định của reward trong quá trình huấn luyện. Đề án này sử dụng đồng thời cả bốn độ đo để so sánh.

2.5 Phát biểu bài toán dưới dạng ILP

Để có hình thức hoá đầy đủ, đặt biến nhị phân $x_{n^v, n^s} \in \{0, 1\}$ bằng 1 nếu nút ảo n^v được ánh xạ tới nút vật lý n^s , và biến $y_{u^s v^s}^{u^v v^v} \in [0, 1]$ biểu diễn tỉ lệ băng thông của liên kết ảo (u^v, v^v) đi qua liên kết vật lý (u^s, v^s) . Với mục tiêu cực đại hoá tỉ số R/C, bài toán có thể viết:

$$\max \frac{\mathcal{R}(\text{VNR})}{\mathcal{C}(\text{VNR})} \quad (2.3)$$

với các ràng buộc:

$$\sum_{n^s \in N^s} x_{n^v, n^s} = 1, \quad \forall n^v \in N^v, \quad (2.4)$$

$$\sum_{n^v \in N^v} x_{n^v, n^s} \cdot c(n^v) \leq C^{\text{avail}}(n^s), \quad \forall n^s \in N^s, \quad (2.5)$$

$$\sum_{n^v \in N^v} x_{n^v, n^s} \leq 1, \quad \forall n^s \in N^s, \quad (2.6)$$

$$\sum_{(u^s, v^s) \in E^s} y_{u^s v^s}^{u^v v^v} \cdot b(u^v, v^v) \leq B^{\text{avail}}(u^s, v^s), \quad \forall (u^s, v^s), \quad (2.7)$$

$$\sum_{v^s: (u^s, v^s) \in E^s} (y_{u^s v^s}^{u^v v^v} - y_{v^s u^s}^{u^v v^v}) = x_{u^v, u^s} - x_{v^v, u^s}, \quad \forall u^s, (u^v, v^v). \quad (2.8)$$

Ràng buộc (2.4) đảm bảo mỗi nút ảo được ánh xạ tới đúng một nút vật lý; (2.5) đảm bảo không vượt CPU; (2.6) đảm bảo tính đơn ánh; (2.7) đảm bảo không vượt băng thông; và (2.8) là ràng buộc bảo toàn luồng (multi-commodity flow) cho ánh xạ liên kết. Trong cấu hình đa miền có thể bổ sung ràng buộc $x_{n^v, n^s} = 0$ với mọi n^s không thuộc miền cho phép $\mathcal{D}(n^v)$. Dạng ILP này có $|N^v| \cdot |N^s|$ biến nhị phân nút và $|E^v| \cdot |E^s|$ biến liên kết; do không gian nghiệm tăng theo cấp số mũ, việc giải tối ưu trở nên không khả thi với mạng vật lý cỡ trăm nút trở lên (phân tích độ phức tạp chi tiết được trình bày ở Mục 3.6.1 của Chương 3). Đây chính là lý do đề án theo đuổi hướng xấp xỉ bằng học tăng cường thay vì giải ILP trực tiếp.

Chương này đã khảo sát các hướng tiếp cận hiện có và phát biểu hình thức bài toán nhúng mạng ảo đa miền: mô hình mạng vật lý đa miền và mạng ảo, hai pha ánh xạ nút và liên kết, hàm mục tiêu cùng các độ đo, và dạng ILP với phân tích tính bất khả thi ở quy mô lớn. Chương tiếp theo trình bày phương pháp đề xuất CARL-VNE.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày chi tiết phương pháp đề xuất *CARL-VNE* (Candidate-Anchored Reinforcement Learning for Virtual Network Embedding). Tên gọi phản ánh hai ý tưởng trung tâm của phương pháp: *Candidate*: tín hiệu học tăng cường được dồn vào đầu chọn ứng viên, đòn bẩy hiệu quả của bài toán; và *Anchored*: chính sách được neo về mô hình học bắt chước (imitation learning) bằng độ phân kỳ Kullback-Leibler trong suốt quá trình tinh chỉnh. Về ánh xạ liên kết, phương pháp dùng một bước cam kết tài nguyên đa đường (multi-path) được trình bày ở Mục 3.3.4; lời giải mẫu cho giai đoạn học bắt chước được lấy từ heuristic MP-VNE. Phần đầu chương mô tả kiến trúc tổng thể và ba nguyên lý thiết kế cốt lõi. Các phần tiếp theo lần lượt trình bày bộ mã hoá đồ thị, bộ giải mã chọn ứng viên, môi trường học tăng cường, và quy trình huấn luyện hai giai đoạn. Phần cuối chương phân tích lý thuyết các tính chất của phương pháp, bao gồm độ phức tạp tính toán, độ phức tạp bộ nhớ và đặc tính hội tụ.

3.1 Tổng quan giải pháp

3.1.1 Ba nguyên lý thiết kế


Phương pháp đề xuất được xây dựng quanh ba nguyên lý thiết kế nhằm khắc phục trực tiếp ba hạn chế của các phương pháp học tăng cường cho VNE đã nêu ở Chương 1.

1. **Mã hoá tô-pô phân cấp đa miền.** Hạ tầng thực tế thường được chia thành nhiều miền quản trị (domain). Thay vì coi mạng vật lý là một đồ thị phẳng, đồ án sử dụng một bộ mã hoá *phân cấp* gồm hai mức: mức nội miền (intra-domain) học biểu diễn cục bộ cho từng miền, và mức liên miền (inter-domain) học biểu diễn quan hệ giữa các miền. Cách làm này tôn trọng tính cục bộ của bài toán đa miền và cho phép tác nhân “nhìn thấy” chi phí định tuyến xuyên miền ngay tại bước ra quyết định.
2. **Lựa chọn ứng viên là đòn bẩy hiệu quả.** Một phát hiện then chốt của đồ án là *lựa chọn ứng viên*, tức chọn nút vật lý nào cho mỗi nút ảo, mới là quyết định chi phối chất lượng lời giải và là nơi học tăng cường phát huy tác dụng để vượt trần hiệu năng của heuristic. Vì vậy phương pháp tập trung toàn bộ năng lực học vào một đầu chọn ứng viên cross-attention tích hợp đặc trưng chi phí tường minh (cost-aware) và mặt nạ khả thi cứng, được tinh chỉnh cùng bộ mã hoá và bộ phê bình.
3. **Khởi động bằng học bắt chước rồi tinh chỉnh actor-critic có neo KL.** Quy

trình huấn luyện gồm hai giai đoạn: (i) học bắt chước lời giải của heuristic MP-VNE để có một chính sách khởi đầu hợp lý (gọi là mô hình $R2$); (ii) tinh chỉnh bằng phương pháp actor-critic, trong đó tín hiệu thưởng đến từ kết quả nhúng thực tế, đồng thời neo phân phối chọn ứng viên về chính sách tham chiếu $R2$ bằng độ phân kỳ Kullback-Leibler (KL) để tinh chỉnh mà không sụp đổ phân phối.

3.1.2 Sơ đồ khối hệ thống

Hình 3.1 mô tả kiến trúc tổng thể. Hệ thống gồm bốn nhóm khối: (1) *bộ mã hoá đồ thị* biến mạng vật lý và yêu cầu mạng ảo thành các vector biểu diễn; (2) *hai đầu ra* gồm đầu chọn ứng viên (cross-attention) và bộ phê bình giá trị $V(s)$; (3) *bộ giải mã* ánh xạ nút theo điểm của đầu chọn ứng viên rồi ánh xạ liên kết bằng cơ chế đa đường; và (4) *môi trường* cam kết tài nguyên và trả về tín hiệu thưởng. Toàn bộ các khối (bộ mã hoá, đầu chọn ứng viên, bộ phê bình) được tinh chỉnh bằng học tăng cường, trong đó tín hiệu học được dồn vào đầu chọn ứng viên, đòn bẩy hiệu quả của bài toán.



Hình 3.1: Kiến trúc tổng thể của CARL-VNE (khối tô đậm được huấn luyện bằng RL).

3.1.3 Luồng tương tác môi trường - tác nhân

Mỗi *episode* tương ứng với quá trình nhúng một VNR và diễn ra theo các bước sau. (1) Bộ mã hoá tính biểu diễn cho mạng vật lý hiện tại và VNR đang xét. (2) Đầu chọn ứng viên tính điểm cho các nút vật lý khả thi trong từng miền cho phép để cử ứng viên top-1 mỗi miền cho mỗi nút ảo; ánh xạ nút được lấy mẫu khi huấn luyện, còn khi triển khai do PSO chọn tổ hợp (Mục 3.3.5). (3) Sau khi đã có ánh xạ nút, các liên kết ảo được ánh xạ bằng đường đi ngắn nhất. (4) Lời giải hoàn chỉnh được cam kết lên mạng vật lý theo cơ chế đa đường (multi-path), trạng thái tài nguyên được cập nhật, và môi trường trả về một tín hiệu thưởng phản ánh việc nhúng thành công hay thất bại cùng độ tiết kiệm chi phí. Phân tích độ phức tạp của luồng này được trình bày ở Mục 3.6.1, còn kết quả thực nghiệm ở Chương 4.

3.2 Bộ mã hoá đồ thị (Graph Encoder)

3.2.1 Mã hoá mạng vật lý phân cấp

Bộ mã hoá mạng vật lý hoạt động ở hai mức để phản ánh cấu trúc đa miền.

Mức nội miền. Trong mỗi miền d , một mạng tích chập đồ thị (GCN) ba lớp với chiều ẩn 32 được áp dụng lên đồ thị con của miền đó. Mỗi nút vật lý được mô tả bằng vector đặc trưng 7 chiều gồm: dung lượng CPU còn lại, đơn giá CPU, độ trễ xử lý, bậc của nút, băng thông trung bình của các liên kết kề, đơn giá băng thông trung bình của các liên kết kề, và một cờ nhị phân cho biết nút có phải nút biên (có liên kết liên miền) hay không. Tất cả đặc trưng đều được chuẩn hoá để ổn định huấn luyện. Lớp GCN tuân theo công thức truyền tin chuẩn hoá đối xứng kèm kết nối tắt (residual) và chuẩn hoá lớp (LayerNorm):

$$H^{(\ell+1)} = \text{LayerNorm}\left(H^{(\ell)} + \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(\ell)} W^{(\ell)}\right)\right), \quad (3.1)$$

trong đó $\tilde{A} = A + I$, $\tilde{D}$ là ma trận bậc tương ứng, σ là hàm ReLU. Khác với GCN cơ bản, ma trận kề A ở đây được **trọng số hoá theo băng thông còn lại** của các liên kết, nhờ đó trạng thái tài nguyên động được mã hoá trực tiếp vào quá trình truyền tin.

Mức liên miền. Sau khi có biểu diễn nội miền, mỗi miền được tóm tắt thành một vector duy nhất bằng phép max-pooling trên các nút của miền. Tập các vector tóm tắt tạo thành một “siêu đồ thị” gồm D nút (mỗi miền là một nút). Một GCN hai lớp (chiều ẩn 32) được áp dụng trên siêu đồ thị này, với ma trận kề liên miền được xây từ tổng băng thông còn lại của các liên kết liên miền giữa từng cặp miền (thêm self-loop, chuẩn hoá $\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$). Kết quả là mỗi nút vật lý nhận được hai loại ngữ cảnh: ngữ cảnh nội miền (cục bộ) và ngữ cảnh liên miền (toàn cục), nối lại thành biểu diễn 64 chiều.

3.2.2 Mã hoá yêu cầu mạng ảo

Yêu cầu mạng ảo được mã hoá bằng một GCN hai lớp (chiều ẩn 32) trên đồ thị ảo, với mỗi nút ảo mô tả bằng 7 đặc trưng gồm: nhu cầu CPU, bậc, tổng băng thông các liên kết kề, kích thước VN chuẩn hoá, mật độ liên kết của VN, tỉ lệ số miền được phép, và tỉ lệ liên kết ảo buộc phải định tuyến xuyên miền. Vì sự phối hợp giữa các nút ảo là quan trọng, ta bổ sung một khối *self-attention đa đầu* (4 đầu) trên tập biểu diễn các nút ảo (khối Transformer: attention + mạng truyền thẳng + LayerNorm). Bộ mã hoá VNR dùng **bộ trọng số riêng**, tách biệt với bộ mã hoá mạng vật lý.

3.2.3 Trộn biểu diễn substrate và VNR

Với mỗi nút ảo, ngữ cảnh mạng vật lý được tổng hợp bằng phép max-pooling trên các biểu diễn nút vật lý (chiều 64) rồi nối với biểu diễn của nút ảo (chiều 32). Vector kết hợp 96 chiều này là đầu vào chung cho đầu chọn ứng viên và bộ phê bình giá trị, đảm bảo mọi đầu ra đều “nhìn” cùng một biểu diễn nhất quán của trạng thái.

3.2.4 Phân tích thiết kế

Đề án chọn GCN thay vì GAT cho bộ mã hoá chính nhằm giữ kiến trúc nhỏ gọn: toàn bộ mạng chính sách chỉ khoảng 36,300 tham số, phù hợp huấn luyện nhanh trên tô-pô cỡ vừa và giảm rủi ro quá khớp. Cấu trúc phân cấp là lựa chọn cốt lõi cho bài toán đa miền: nó tránh việc cho mỗi nút “nhìn thấy” toàn bộ hàng trăm nút ở các miền khác (vừa tốn kém vừa nhiễu), đồng thời vẫn truyền được thông tin liên miền qua mức thứ hai. Các biến thể dùng GAT và bộ mã hoá lớn hơn được khảo sát trong phân tích ablation ở Chương 4.

3.3 Bộ giải mã chọn ứng viên (Candidate Decoder)

Đây là thành phần trung tâm của phương pháp và là nơi học tăng cường phát huy tác dụng.

3.3.1 Sinh tập ứng viên cho mỗi nút ảo

Với mỗi nút ảo n^v và mỗi miền d thuộc tập miền cho phép $\mathcal{D}(n^v)$, ta lọc ra các nút vật lý trong miền d thoả mãn ràng buộc CPU cứng ($C^{\text{avail}}(n^s) \geq c(n^v)$), rồi giữ lại K ứng viên hàng đầu theo điểm của đầu chọn ứng viên. Theo cách diễn giải chặt của thuật toán gốc, đề án dùng $K = 1$ cho mỗi miền: mỗi nút ảo chỉ giữ *một* ứng viên tốt nhất trên *mỗi* miền được phép. Cơ chế lọc theo miền này vừa thu hẹp mạnh không gian hành động, vừa đảm bảo lời giải tôn trọng ràng buộc miền.

3.3.2 Cơ chế attention chọn ứng viên

Điểm số cho mỗi cặp (nút ảo n^v , nút vật lý ứng viên n^s) được tính bằng cơ chế cross-attention có tích hợp các *đặc trưng chi phí tương minh* (cost-aware). Truy vấn là biểu diễn nút ảo, khoá là biểu diễn ngữ cảnh của nút vật lý nối với bốn đặc trưng phụ trợ: độ dư CPU chuẩn hoá, chi phí CPU ước lượng $\text{cpu_cost} = c(n^v) \cdot P(n^s)$, cờ nút biên, và chi phí liên kết ước lượng. Điểm cuối cùng là tổng của ba thành phần:

$$\begin{aligned} \text{score}(n^v, n^s) = & \underbrace{\frac{q^\top k}{\sqrt{d_h}}}_{\text{attention}} + \underbrace{\text{MLP}_{\text{res}}([h_{n^v} \parallel h_{n^s}])}_{\text{tương tác phi tuyến}} \\ & - \beta_c \text{cpu_cost} - \beta_\ell \text{link_cost} + \beta_b \text{is_boundary}, \end{aligned} \quad (3.2)$$

trong đó $\beta_c, \beta_\ell, \beta_b$ là các trọng số thiên lệch *học được*. Việc đưa các đặc trưng chi phí vào tường minh giúp đầu chọn ứng viên khởi đầu gần với quy luật xếp hạng theo chi phí ước lượng (PreCost) của heuristic, rồi học các sai lệch có lợi từ đó. Các nút không khả thi về CPU bị gán điểm -10^4 (mặt nạ khả thi cứng) để bị loại hoàn toàn sau softmax.

3.3.3 Lựa chọn ngẫu nhiên khi huấn luyện và tắt định khi suy diễn

Đây chính là cơ chế cho phép học tăng cường hoạt động. Khi **huấn luyện** (rollout học tăng cường, chế độ giải mã trực tiếp), với mỗi nút ảo một nút vật lý được *lấy mẫu* từ phân phối Categorical trên các điểm $\text{score}(\cdot)$. Tính ngẫu nhiên này tạo ra *khám phá*: tác nhân thử các phương án chọn ứng viên khác nhau và nhận phản hồi từ kết quả nhúng. Khi **triển khai**, các ứng viên top-1 mỗi miền do đầu chọn ứng viên đề cử được đưa vào một bộ tối ưu hoá bầy hạt (PSO) để chọn tổ hợp ánh xạ nút tốt nhất (Mục 3.3.5).

Phát hiện then chốt là: nếu chỉ dùng đường đi argmax chặt ($K = 1$, không lấy mẫu) ngay từ khi huấn luyện thì *không có khám phá*, do đó không có tín hiệu để học tăng cường cải thiện. Chính việc làm cho lựa chọn ứng viên trở nên ngẫu nhiên trong lúc huấn luyện mới mở ra khả năng vượt trần hiệu năng của mô hình bất chước.

3.3.4 Ánh xạ liên kết

Sau khi cố định ánh xạ nút, mỗi liên kết ảo $e^v = (u^v, v^v)$ được ánh xạ thành (các) đường đi vật lý nối $f_N(u^v)$ với $f_N(v^v)$. Trong cấu hình đa miền, việc tìm đường mang tính phân cấp: *bộ điều khiển cục bộ* của mỗi miền tìm đường nội miền, còn *bộ điều khiển toàn cục* ghép các đoạn nội miền qua các liên kết liên miền giữa các nút biên thành một đường đi xuyên miền hoàn chỉnh.

Trong **pha giải mã và kiểm tra khả thi**, mỗi liên kết ảo được thử ánh xạ vào *một* đường đi ngắn nhất (Dijkstra) mang toàn bộ băng thông yêu cầu $b(e^v)$; đường đi chỉ hợp lệ nếu băng thông còn lại nhỏ nhất dọc đường (bottleneck) không nhỏ hơn $b(e^v)$. Nếu tồn tại một liên kết ảo không tìm được đường đủ băng thông, việc nhúng VNR bị coi là thất bại. Một *mặt nạ chống trùng* bảo đảm không có hai nút ảo nào ánh xạ vào cùng một nút vật lý.

Khi **cam kết** tài nguyên cho một lời giải đã được chấp nhận, hệ thống dùng cơ chế *đa đường* (multi-path): băng thông của một liên kết ảo có thể được chia trên tối đa năm đường đi vật lý, tăng khả năng thoả mãn các yêu cầu băng thông lớn khi không một đường đơn nào đủ. Chi phí của pha ánh xạ liên kết được tính bằng tổng

trên các đường đi đã cấp phát:

$$C_{\text{link}} = \sum_{e^v \in E^v} \sum_{p \in f_E(e^v)} (D(p) + P(p) \cdot b_p), \quad (3.3)$$

với $D(p)$ là tổng độ trễ truyền dẫn dọc đường p , $P(p)$ là đơn giá băng thông và b_p là phần băng thông cấp trên p (với đường đơn $b_p = b(e^v)$).

3.3.5 Triển khai qua PSO và multi-restart

Khi triển khai, mỗi nút ảo có tối đa một ứng viên trên mỗi miền cho phép (top-1 theo điểm đầu chọn ứng viên), tạo thành một không gian tổ hợp các phương án ánh xạ nút. Đồ án dùng *tối ưu hoá bầy hạt* (Particle Swarm Optimization - PSO) để tìm tổ hợp tốt nhất trong không gian này.

Biểu diễn cá thể. Mỗi cá thể là một vector số nguyên $\mathbf{z} = (z_1, \dots, z_{|N^v|})$, trong đó z_j là chỉ số ứng viên được chọn cho nút ảo thứ j . Khi hai nút ảo chọn trùng một nút vật lý, một cơ chế sửa gán lại một trong hai sang ứng viên khả thi khác để đảm bảo ràng buộc đơn ánh.

Hàm thích nghi. Mỗi cá thể được giải mã thành một ánh xạ nút, hoàn thiện ánh xạ liên kết theo Mục 3.3.4, rồi chấm điểm bằng

$$\text{fitness}(\mathbf{z}) = \mathcal{C}(\mathbf{z}) - \alpha \sum_j p_j^{\text{cand}}(z_j), \quad (3.4)$$

trong đó $\mathcal{C}(\mathbf{z})$ là chi phí nhúng (PreCost, gồm chi phí nút và chi phí liên kết ở Công thức (3.3)), còn $p_j^{\text{cand}}(z_j)$ là xác suất mà đầu chọn ứng viên gán cho ứng viên được chọn. Số hạng thứ hai là *thiên lệch theo chính sách* (hệ số $\alpha = 50$): trừ vào chi phí để PSO ưu tiên những phương án mà chính sách học được cho điểm cao. Cá thể có liên kết không nhúng được bị phạt nặng để bị loại.

Cập nhật bầy hạt. Vận tốc $\mathbf{v}_i$ và vị trí $\mathbf{z}_i$ của mỗi cá thể i được cập nhật theo công thức PSO chuẩn:

$$\mathbf{v}_i \leftarrow w \mathbf{v}_i + c_1 r_1 (\mathbf{p}_i^{\text{best}} - \mathbf{z}_i) + c_2 r_2 (\mathbf{g}^{\text{best}} - \mathbf{z}_i), \quad (3.5)$$

$$\mathbf{z}_i \leftarrow \text{round}(\mathbf{z}_i + \mathbf{v}_i), \quad (3.6)$$

với $\mathbf{p}_i^{\text{best}}$ là vị trí tốt nhất từng đạt của cá thể i , $\mathbf{g}^{\text{best}}$ là vị trí tốt nhất toàn bầy, và $r_1, r_2 \sim \mathcal{U}(0, 1)$; vị trí được làm tròn và kẹp về chỉ số ứng viên hợp lệ. Đồ án dùng $w = 0,7$, $c_1 = c_2 = 1,5$, bổ sung xác suất đột biến 0,1 (gán ngẫu nhiên lại một số

thành phần của z) để tránh hội tụ sớm; mỗi lần chạy gồm 20 cá thể và 15 vòng lặp.

Multi-restart. Để tăng tỉ lệ chấp nhận và giảm chi phí, quá trình suy diễn lặp lại PSO $K = 3$ lần với các hạt giống khác nhau rồi chọn lời giải có chi phí thấp nhất. Việc chạy nhiều lần độc lập làm tăng xác suất tìm được ít nhất một lời giải khả thi (cải thiện tỉ lệ chấp nhận) và cho lời giải rẻ hơn theo nguyên lý best-of- K , đổi lại chi phí suy diễn tăng theo hệ số K . Thuật toán 1 tóm tắt toàn bộ quy trình suy diễn.

Algorithm 1: Suy diễn CARL-VNE qua PSO multi-restart

Input: Một VNR; mạng vật lý G^s ; chính sách π_θ ; số lần khởi động K
Output: Lời giải nhúng có chi phí thấp nhất (hoặc thất bại)
 Mã hoá G^s và VNR; với mỗi nút ảo, lấy ứng viên top-1 trên mỗi miền cho phép theo π_θ ;
 $best \leftarrow \emptyset$;
for $k \leftarrow 1$ **to** K **do**
 Khởi tạo bầy 20 cá thể với hạt giống k ;
 for 15 vòng lặp **do**
 Giải mã mỗi cá thể thành ánh xạ nút; ánh xạ liên kết bằng đường đi ngắn nhất;
 Tính fitness theo Công thức (3.4); cập nhật p_i^{best} , g^{best} và bầy hạt;
 end
 if g^{best} của lần chạy này khả thi và rẻ hơn $best$ **then**
 $best \leftarrow g^{\text{best}}$;
 end
end
 Cam kết $best$ lên mạng vật lý theo cơ chế đa đường (Mục 3.3.4);
return $best$;

3.3.6 Tính toán xác suất hành động hợp thành

Hành động của chính sách là tập các lựa chọn ứng viên cho các nút ảo, nên log-xác suất của một lời giải nhúng hoàn chỉnh là tổng log-xác suất của các lựa chọn ứng viên (tổng theo từng nút ảo):

$$\log \pi_\theta(a \mid s) = \sum_{n^v} \log p_{n^v}^{\text{cand}}. \quad (3.7)$$

Toàn bộ gradient học tăng cường đi qua thành phần này, nhờ đó tín hiệu học được tập trung hoàn toàn vào đòn bẩy hiệu quả nhất.

3.4 Môi trường học tăng cường

3.4.1 Không gian trạng thái

Trạng thái s gồm: (i) trạng thái tài nguyên hiện tại của mạng vật lý (CPU còn lại của mỗi nút, băng thông còn lại của mỗi liên kết), biến đổi dần khi các nút/liên kết ảo được cam kết; (ii) cấu trúc và nhu cầu của VNR đang xử lý; và (iii) thông tin tương thích miền giữa nút ảo và nút vật lý. Trạng thái được biểu diễn thông qua các vector mã hoá phân cấp ở Mục 3.2. Các cam kết là *on-policy* và bền vững trong suốt episode.

3.4.2 Không gian hành động

Một hành động hợp thành gồm, với mỗi nút ảo, một lựa chọn nút vật lý trên mỗi miền cho phép. Không gian hành động do đó tập trung hoàn toàn vào các lựa chọn ứng viên.

3.4.3 Hàm phần thưởng

Phần thưởng được cấp ở cuối mỗi episode theo dạng tổng quát: nhúng thất bại nhận một phần thưởng âm cố định; nhúng thành công nhận một phần thưởng dương cộng với một số hạng phản ánh độ tiết kiệm chi phí so với mức trung bình động:

$$r = \begin{cases} \rho_{\text{bonus}} + \lambda \cdot \frac{\bar{c}_{\text{EMA}} - c}{\bar{c}_{\text{EMA}}}, & \text{nếu nhúng thành công,} \\ -\rho_{\text{fail}}, & \text{nếu nhúng thất bại,} \end{cases} \quad (3.8)$$

trong đó c là chi phí thực tế của lời giải, $\bar{c}_{\text{EMA}}$ là trung bình động (hệ số suy giảm 0.95) của chi phí các lần nhúng thành công gần đây, λ điều tiết mức độ ưu tiên tiết kiệm chi phí. Đồ án đặt $\rho_{\text{bonus}} = 0,5$, $\lambda = 1,0$ và $\rho_{\text{fail}} = 0,5$; tức nhúng thành công nhận $r = 0,5 + 1,0 \cdot (\bar{c}_{\text{EMA}} - c)/\bar{c}_{\text{EMA}}$ và nhúng thất bại nhận $r = -0,5$. Cách đặt này vừa thưởng cho việc nhúng thành công, vừa nhấn mạnh số hạng tiết kiệm chi phí (trọng số $\lambda = 1,0$) để khuyến khích các lời giải rẻ hơn mức nền.

3.4.4 Cơ chế xử lý hành động không hợp lệ

Ba loại mặt nạ được áp dụng: (i) mặt nạ khả thi CPU: nút vật lý không đủ CPU bị gán điểm -10^4 ; (ii) mặt nạ chống trùng: nút vật lý đã được dùng bị gán điểm $-\infty$ trong giải mã trực tiếp; (iii) bỏ qua miền rỗng: nếu mọi nút trong một miền đều không khả thi thì miền đó bị loại khỏi bước chọn ứng viên. Nhờ các mặt nạ này, mọi hành động được lấy mẫu đều hợp lệ theo ràng buộc tài nguyên và miền.

3.5 Quy trình huấn luyện hai giai đoạn

3.5.1 Giai đoạn 1: Tiền huấn luyện có giám sát từ MP-VNE

Ở giai đoạn này, đầu chọn ứng viên được huấn luyện để bắt chước lời giải của heuristic MP-VNE trên các VNR sinh ngẫu nhiên. Quá trình dùng một bộ huấn luyện dạng actor-critic có chuẩn hoá lợi thế theo lô, với hệ số entropy suy giảm dần (từ 0,05 về 0,005 trong 60 lô đầu) và cơ chế *khởi động critic* (hoãn gradient chính sách trong 8 lô đầu để $V(s)$ bớt nhiễu). Kết quả là mô hình R2, một chính sách khởi đầu đã nắm được các quy luật hợp lý của heuristic và đạt mức hiệu năng tương đương heuristic (ví dụ 24,3% tỉ lệ chấp nhận trên bộ dữ liệu 100 nút). Mô hình R2 vừa là điểm khởi đầu, vừa là chính sách tham chiếu cho neo KL ở giai đoạn sau.

3.5.2 Giai đoạn 2: Tinh chỉnh bằng actor-critic có neo KL

Giai đoạn hai tinh chỉnh đầu chọn ứng viên bằng học tăng cường. Phương pháp sử dụng là **REINFORCE với baseline phê bình** (advantage actor-critic): chính sách (actor) được cập nhật theo gradient chính sách on-policy, còn một **bộ phê bình (critic)** học được $V_\phi(s)$ đóng vai trò đường cơ sở (baseline) để giảm phương sai. Lợi thế (advantage) của mỗi episode được tính bằng

$$A = r - V_\phi(s), \quad \hat{A} = \frac{A - \mu_A}{\sigma_A + \epsilon}, \quad (3.9)$$

với $\hat{A}$ là lợi thế đã chuẩn hoá theo lô. Hàm mất mát tổng hợp gồm bốn thành phần: mất mát chính sách, mất mát giá trị, phần thưởng entropy khuyến khích khám phá, và số hạng neo KL về chính sách tham chiếu R2:

$$\mathcal{L} = \underbrace{-\mathbb{E}[\log \pi_\theta(a | s) \hat{A}]}_{\text{chính sách}} + c_v \underbrace{(V_\phi(s) - r)^2}_{\text{giá trị}} - \beta_H \underbrace{H[\pi_\theta]}_{\text{entropy}} + \beta_{\text{KL}} \underbrace{\text{KL}(\pi_\theta \| \pi_{\text{ref}})}_{\text{neo về R2}}, \quad (3.10)$$

với các hệ số mặc định $c_v = 0.5$, $\beta_H = 0.01$, $\beta_{\text{KL}} = 0.1$. Số hạng KL giữ cho phân phối chọn ứng viên không trôi quá xa khỏi lời giải bắt chước, điều kiện cần để tinh chỉnh ổn định dưới tín hiệu thưởng nhiễu nhiễu.

Biến thể PPO có cắt. Ngoài actor-critic ở trên, đề án còn cài đặt một *biến thể* sử dụng hàm mục tiêu thay thế có cắt của PPO (clipped surrogate): mỗi lô được lưu ảnh chụp trạng thái mạng vật lý, sau đó chính sách được phát lại để tính tỉ số tầm quan trọng $\rho = \exp(\log \pi_\theta - \log \pi_{\theta_{\text{old}}})$ và áp dụng hàm mục tiêu cắt với $\epsilon = 0.2$ qua nhiều vòng gradient. Biến thể này không phải cấu hình tạo ra kết quả chính của đề án, nhưng được dùng làm đối tượng so sánh “PPO so với actor-critic” ở Chương 4.

3.5.3 Mã giả thuật toán huấn luyện tổng thể

Thuật toán 2 tóm tắt toàn bộ quy trình hai giai đoạn.

Algorithm 2: Huấn luyện hai giai đoạn của CARL-VNE

Input: Mạng vật lý G^s ; bộ sinh VNR; heuristic MP-VNE

Output: Chính sách π_θ đã tinh chỉnh

// Giai đoạn 1: học bắt chước

Khởi tạo ngẫu nhiên θ ;

for mỗi lô VNR sinh ngẫu nhiên **do**

 Giải bằng MP-VNE để lấy ánh xạ tham chiếu;

 Cập nhật θ theo mất mát actor-critic có entropy để bắt chước;

end

Lưu chính sách tham chiếu $\pi_{\text{ref}} \leftarrow \pi_\theta$ (mô hình R2);

// Giai đoạn 2: tinh chỉnh actor-critic

for mỗi lô VNR **do**

for mỗi VNR trong lô **do**

 Mã hoá trạng thái; **lấy mẫu ứng viên** theo từng miền;

 Ánh xạ liên kết bằng đường đi ngắn nhất; cam kết theo đa đường
 (multi-path);

 Tính phần thưởng r theo Công thức (3.8);

end

 Tính lợi thế chuẩn hoá $\hat{A}$ theo Công thức (3.9);

 Cập nhật θ, ϕ theo mất mát $\mathcal{L}$ trong Công thức (3.10); cắt chuẩn
 gradient ở 5.0;

end

return π_θ ;

3.5.4 Các thủ thuật ổn định

Để huấn luyện ổn định, đồ án áp dụng: cắt chuẩn gradient ở ngưỡng 5.0; bộ tối ưu AdamW với tốc độ học 3×10^{-4} và suy giảm trọng số 10^{-4} ; chuẩn hoá lợi thế theo lô; phần thưởng entropy để duy trì khám phá; và neo KL về chính sách tham chiếu để tránh sụp đổ phân phối. Các đường cong huấn luyện (mất mát chính sách, mất mát giá trị, KL, entropy, tỉ lệ chấp nhận) được trình bày ở Chương 4 nhằm minh chứng tính hội tụ và ổn định của quá trình.

3.6 Phân tích lý thuyết

Phần này phân tích các tính chất lý thuyết của phương pháp đề xuất, gồm độ phức tạp tính toán, độ phức tạp bộ nhớ, và đặc tính hội tụ trong ngữ cảnh VNE. Ký hiệu dùng trong phần này: $|N^s|, |E^s|$ là số nút và liên kết mạng vật lý; D là số miền;

$|N^v|, |E^v|$ là số nút và liên kết của một VNR; d là chiều ẩn (ở đây $d = 32$); L là số lớp GCN; K là số ứng viên giữ lại trên mỗi miền.

3.6.1 Độ phức tạp tính toán

a, Độ phức tạp suy diễn (inference)

Chi phí suy diễn cho một VNR gồm bốn thành phần.

Bộ mã hoá phân cấp. Mỗi lớp GCN nội miền có chi phí truyền tin tỉ lệ với số cạnh nhân chiều ẩn, tổng trên các miền là $\mathcal{O}(L |E^s| d)$ (mỗi cạnh chỉ thuộc một miền nên tổng số cạnh nội miền không vượt $|E^s|$). Bước tóm tắt miền và GCN liên miền trên siêu đồ thị D nút tốn $\mathcal{O}(|N^s| d + D^2 d)$. Bộ mã hoá VNR (GCN + self-attention 4 đầu) tốn $\mathcal{O}(L |E^v| d + |N^v|^2 d)$, nhỏ vì $|N^v| \leq 7$. Do đó chi phí mã hoá chủ đạo là

$$\mathcal{O}(L |E^s| d + D^2 d). \quad (3.11)$$

Bộ giải mã chọn ứng viên. Với mỗi nút ảo, đầu chọn ứng viên tính điểm cross-attention cho các nút vật lý khả thi trong các miền cho phép. Trong trường hợp xấu nhất là toàn bộ $|N^s|$ nút, chi phí là $\mathcal{O}(|N^v| |N^s| d)$; tuy nhiên nhờ lọc khả thi CPU và giới hạn K ứng viên mỗi miền, chi phí thực tế giảm còn $\mathcal{O}(|N^v| D K d)$.

Ánh xạ liên kết. Mỗi liên kết ảo dùng một lần tìm đường đi ngắn nhất (Dijkstra) tốn $\mathcal{O}(|E^s| \log |N^s|)$, tổng là $\mathcal{O}(|E^v| |E^s| \log |N^s|)$.

Tối ưu PSO khi triển khai. Ở chế độ triển khai, một lần tối ưu hoá bày hạt với P hạt và I vòng lặp đánh giá hàm thích nghi tốn $\mathcal{O}(P I |N^v|)$; cơ chế multi-restart nhân thêm hệ số K ($P = 20, I = 15, K = 3$). Đây là một thừa số hằng cộng thêm không phụ thuộc kích thước mạng vật lý.

Tổng hợp, độ phức tạp suy diễn một VNR là tuyến tính theo $|E^s|$ (bỏ qua thừa số log của Dijkstra), tức **khả mở rộng** với tô-pô lớn, trái ngược với độ phức tạp cấp số mũ của lời giải ILP đã nêu ở Chương 2.

b, Độ phức tạp một bước huấn luyện

Một bước cập nhật xử lý một lô B VNR. Mỗi VNR cần một lượt suy diễn (rollout) cộng một lượt lan truyền ngược; lan truyền ngược cùng cấp độ phức tạp với lan truyền xuôi. Ở giai đoạn tinh chỉnh actor-critic, mỗi lô cập nhật một vòng gradient, nên chi phí một bước là $\mathcal{O}(B \cdot C_{\text{infer}})$ với C_{infer} là chi phí suy diễn ở Mục a. Biến thể PPO có cắt phát lại chính sách K_{ppo} vòng trên cùng một lô nên chi phí nhân thêm hệ số K_{ppo} (mặc định $K_{\text{ppo}} = 2$).

3.6.2 Độ phức tạp bộ nhớ

Tổng số tham số của mạng chính sách khoảng 36,300 (gồm bộ mã hoá, đầu chọn ứng viên và bộ phê bình), tất cả đều được cập nhật trong quá trình huấn luyện. Đây là một mô hình *rất nhỏ gọn* so với các mạng học sâu thông thường, giúp suy diễn nhanh và phù hợp triển khai trên hạ tầng hạn chế tài nguyên.

Về bộ nhớ kích hoạt (activation), do đồ thị được xử lý theo từng miền và VNR có kích thước nhỏ, lượng kích hoạt cần lưu cho lan truyền ngược tỉ lệ $\mathcal{O}(L|N^s|d)$, tuyến tính theo số nút vật lý. Phương pháp không dùng replay buffer lớn: mỗi lô chỉ lưu các đại lượng rollout cần thiết (log-xác suất, phần thưởng, giá trị, và với biến thể PPO là ảnh chụp trạng thái mạng vật lý để phát lại), nên đầu chân bộ nhớ tổng thể nhỏ và ổn định trong suốt huấn luyện.

3.6.3 Phân tích hội tụ

a, Cải thiện đơn điệu của gradient chính sách có baseline

Phương pháp tinh chỉnh là một thuật toán gradient chính sách với baseline học được (actor-critic). Theo định lý gradient chính sách, hướng cập nhật $\mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a | s) \hat{A}]$ là ước lượng không chệch của gradient mục tiêu kỳ vọng $J(\theta)$ khi baseline $V_{\phi}(s)$ độc lập với hành động. Việc trừ baseline và chuẩn hoá lợi thế làm *giảm phương sai* của ước lượng gradient mà không gây chệch, nhờ đó các bước cập nhật ổn định hơn và kỳ vọng cải thiện đơn điệu cục bộ của $J(\theta)$ được duy trì với tốc độ học đủ nhỏ. Biến thể PPO bổ sung cận dưới có cắt (clipped surrogate) cho mục tiêu thay thế, đảm bảo mỗi bước cập nhật không làm chính sách trôi quá xa khỏi chính sách cũ, một cơ sở lý thuyết chặt hơn cho cải thiện đơn điệu.

b, Vai trò của neo KL

Số hạng neo KL về chính sách tham chiếu R2 đóng vai trò một *ràng buộc vùng tin cậy mềm*: nó giới hạn độ lệch của phân phối chọn ứng viên khỏi lời giải bất chước ban đầu, ngăn hiện tượng sụp đổ phân phối khi tín hiệu thưởng nhiều nhiễu. Đây chính là lý do lý thuyết cho thiết kế “khởi động bằng học bất chước rồi tinh chỉnh có neo”: pha bất chước cung cấp điểm khởi đầu phương sai thấp trong vùng nghiệm tốt, còn neo KL giữ cho quá trình tinh chỉnh không rời khỏi vùng đó.

c, Quan sát thực nghiệm về tính hội tụ

Các đặc tính lý thuyết trên được kiểm chứng qua quỹ đạo huấn luyện thực tế (trình bày chi tiết ở Chương 4): entropy của chính sách giảm dần và bão hoà (chính sách ngày càng tự tin), độ phân kỳ KL dao động quanh một mức nhỏ ổn định thay vì bùng nổ, và tỉ lệ thành công tăng rồi đạt bình nguyên. Sự bão hoà này phù hợp với dự đoán: khi π_{θ} tiến gần một cực trị cục bộ trong vùng tin cậy do neo KL xác

định, lợi thế kỳ vọng tiến về không và các bước cập nhật nhỏ dần.

Chương này đã trình bày đầy đủ kiến trúc, môi trường và thuật toán huấn luyện của CARL-VNE, với ba nguyên lý thiết kế cốt lõi: mã hoá phân cấp đa miền, tập trung học tăng cường vào đầu chọn ứng viên (đòn bẩy hiệu quả), và quy trình hai giai đoạn bắt chước rồi tinh chỉnh actor-critic có neo KL; đồng thời chỉ ra phương pháp có độ phức tạp tính toán tuyến tính theo kích thước mạng vật lý, dấu chân bộ nhớ nhỏ, và đặc tính hội tụ ổn định nhờ baseline giảm phương sai và neo KL. Chương tiếp theo trình bày kết quả thực nghiệm để kiểm chứng các phân tích này.

CHƯƠNG 4. ĐÁNH GIÁ THỰC NGHIỆM

Chương này trình bày thiết lập thực nghiệm, các tập dữ liệu, độ đo so sánh và phân tích kết quả của phương pháp đề xuất so với baseline trên bộ dữ liệu mạng vật lý 50 nút. Phần kết quả gồm đánh giá trên toàn bộ các bộ dữ liệu phân phối yêu cầu mạng ảo (phân tích robustness) và trực quan hoá quá trình huấn luyện hội tụ của CARL-VNE qua hai giai đoạn. Việc mở rộng đánh giá lên các quy mô lớn hơn (100 và 200 nút) được để lại cho hướng phát triển.

4.1 Cấu hình thực nghiệm

4.1.1 Phần cứng và phần mềm

Toàn bộ thực nghiệm được cài đặt bằng Python với thư viện PyTorch và NetworkX, chạy trên CPU với hạt giống ngẫu nhiên cố định để bảo đảm khả năng tái lập.

4.1.2 Tập dữ liệu

Toàn bộ đánh giá được tiến hành trên hạ tầng 50 nút đa miền. Mạng vật lý được chia thành 10 miền; mỗi nút vật lý có dung lượng CPU và đơn giá ngẫu nhiên trong khoảng cho trước, mỗi liên kết có băng thông và đơn giá tương ứng. Bộ dữ liệu *trung tâm* (chuẩn) có yêu cầu mạng ảo kích thước 3–7 nút (trung bình 5), nhu cầu CPU trong $[1, 8]$ và băng thông trong $[5, 25]$, thời gian sống trung bình 500; thời điểm đến tuân theo tiến trình Poisson, mô phỏng kịch bản trực tuyến. Tập huấn luyện gồm 10,000 VNR, tập kiểm thử gồm 3,000 VNR tách biệt.

Để đánh giá tính bền vững, ngoài bộ dữ liệu trung tâm, đồ án sinh thêm 20 bộ dữ liệu bằng cách quét năm trục phân phối VNR, mỗi trục bốn điểm biên (tổng cộng 21 bộ dữ liệu 50 nút, mỗi bộ 3,000 VNR kiểm thử). Mỗi trục được thiết kế để kiểm tra một khía cạnh vận hành khác nhau của thuật toán:

- **Thời gian sống** (125–2000): độ bền khi mức luân chuyển VNR thay đổi, từ sống ngắn (quay vòng nhanh) đến sống dài (tài nguyên bị giữ lâu).
- **Kích thước VNR** (2–3 đến 8–12 nút): khả năng phục vụ các yêu cầu từ rất nhỏ đến lớn.
- **Mật độ liên kết** (xác suất cạnh 0,0–0,8): ảnh hưởng của độ phức tạp tô-pô VNR lên pha ánh xạ liên kết.
- **Nhu cầu tài nguyên** ($0,5 \times -2,0 \times$): hành vi khi tài nguyên dồi dào so với khi khan hiếm.
- **Ràng buộc miền** (tỉ lệ nút ảo bị buộc miền 0,2–1,0): mức độ siết của ràng buộc đa miền.

Bảng 4.1 tóm tắt tham số của bộ dữ liệu trung tâm.

Bảng 4.1: Tham số bộ dữ liệu trung tâm (50 nút)

Tham số	Giá trị
Số miền	10
Số nút vật lý	50
Kích thước VNR (số nút)	3–7
Nhu cầu CPU	[1, 8]
Nhu cầu băng thông	[5, 25]
Thời gian sống trung bình	500
Số VNR huấn luyện	10000
Số VNR kiểm thử	3000
Số bộ dữ liệu đánh giá	21

4.1.3 Siêu tham số huấn luyện

Bảng 4.2 liệt kê các siêu tham số chính khi huấn luyện CARL-VNE. Bộ tối ưu là AdamW với tốc độ học 3×10^{-4} và suy giảm trọng số 10^{-4} ; mỗi epoch xử lý 5000 VNR theo lô kích thước 16. Hàm thưởng đặt $\rho_{\text{bonus}} = 0,5$, $\lambda = 1,0$, $\rho_{\text{fail}} = 0,5$ như trình bày ở Mục 3.4.3.

Bảng 4.2: Siêu tham số huấn luyện CARL-VNE

Siêu tham số	Giá trị
Bộ tối ưu	AdamW
Tốc độ học	3×10^{-4}
Suy giảm trọng số	10^{-4}
Kích thước lô	16
Số VNR mỗi epoch	5000
Hệ số giá trị c_v	0.5
Hệ số entropy β_H	0.01
Hệ số neo KL β_{KL}	0.1
Ngưỡng cắt gradient	5.0
EMA chi phí (suy giảm)	0.95
Phần thưởng ($\rho_{\text{bonus}} / \lambda / \rho_{\text{fail}}$)	0.5 / 1.0 / 0.5
PSO (cá thể $\times$ vòng lặp)	20×15
PSO ($w / c_1 / c_2 / \text{đột biến}$)	0.7 / 1.5 / 1.5 / 0.1
Multi-restart K	3
Thiên lệch chính sách PSO α	50

4.2 Baseline và độ đo

4.2.1 Các thuật toán so sánh

Đề án so sánh phương pháp đề xuất với các baseline sau, tất cả đều được cài đặt trong cùng khung thực nghiệm để bảo đảm công bằng:

- **MP-VNE** (heuristic, theo bài báo gốc): xếp hạng ứng viên theo chi phí ước lượng (PreCost) kết hợp tối ưu hoá bầy hạt PSO (10 hạt, 50 vòng lặp, hệ số quán tính/nhận thức/xã hội 0,3/0,3/0,4, đột biến 10%), ánh xạ liên kết bằng đường đi ngắn nhất. Đây là baseline heuristic được so sánh trực tiếp với phương pháp đề xuất.
- **CARL-VNE** (phương pháp đề xuất): mô hình được tinh chỉnh actor-critic từ điểm khởi đầu học bắt chước, triển khai qua PSO.

4.2.2 Độ đo đánh giá

Năm độ đo được sử dụng: (1) **tỉ lệ chấp nhận** (acceptance ratio): tỉ số VNR nhúng thành công trên tổng số VNR; (2) **doanh thu** (revenue) tích lũy; (3) **chi phí trung bình** mỗi VNR; (4) **tỉ số doanh thu/chi phí** (R/C); và (5) **độ trễ trung bình** của các đường đi ánh xạ. Tỉ lệ chấp nhận là độ đo quan trọng nhất vì hàm thưởng được thiết kế hướng tới mục tiêu này.

4.3 Kết quả trên các bộ dữ liệu phân phối VNR

Đề án đánh giá CARL-VNE so với heuristic MP-VNE trên toàn bộ 21 bộ dữ liệu phân phối VNR ở bộ dữ liệu 50 nút (mỗi bộ dữ liệu 3000 VNR kiểm thử). Bảng 4.3 trình bày tỉ lệ chấp nhận của hai phương pháp. CARL-VNE thắng ở 19/21 bộ dữ liệu, chỉ thua biên ở hai trường hợp cực trị (thời gian sống rất dài $-0,7$ và VNR rất nhỏ $-1,1$), đều là các vùng mà bài toán hoặc quá bão hoà hoặc quá dễ nên dư địa cải thiện gần như bằng không; tại bộ dữ liệu trung tâm, CARL-VNE đạt 32,7% so với 25,5% của MP-VNE. Phân tích chi tiết theo từng trục được trình bày ở Mục 4.4.

Bảng 4.3: Tỷ lệ chấp nhận (%) trên toàn bộ 21 bộ dữ liệu 50 nút: CARL-VNE so với MP-VNE (3000 VNR kiểm thử mỗi bộ dữ liệu)


Bộ dữ liệu	CARL-VNE	MP-VNE	Δ
Trung tâm (chuẩn)	32,67	25,50	+7,17
Thời gian sống 125	54,07	44,27	+9,80
Thời gian sống 250	43,03	35,80	+7,23
Thời gian sống 1000	22,60	19,53	+3,07
Thời gian sống 2000	14,23	14,97	-0,73
Kích thước 2–3 nút	81,37	82,47	-1,10
Kích thước 3–5 nút	45,07	38,07	+7,00
Kích thước 6–9 nút	10,63	6,30	+4,33
Kích thước 8–12 nút	3,20	2,30	+0,90
Mật độ liên kết 0,0	44,53	38,73	+5,80
Mật độ liên kết 0,15	36,60	32,50	+4,10
Mật độ liên kết 0,55	28,30	22,73	+5,57
Mật độ liên kết 0,8	23,87	18,87	+5,00
Nhu cầu tài nguyên $0,5\times$	49,10	38,40	+10,70
Nhu cầu tài nguyên $0,75\times$	38,47	30,17	+8,30
Nhu cầu tài nguyên $1,5\times$	23,83	20,10	+3,73
Nhu cầu tài nguyên $2,0\times$	18,23	15,20	+3,03
Ràng buộc miền 0,2	42,33	33,00	+9,33
Ràng buộc miền 0,4	38,53	29,47	+9,07
Ràng buộc miền 0,8	28,37	24,50	+3,87
Ràng buộc miền 1,0	25,00	22,63	+2,37

4.4 Phân tích robustness theo phân phối VNR

Các kết quả ở Mục 4.3 được đo trên một phân phối VNR cố định. Để đánh giá mức độ *bền vững* (robustness) của phương pháp khi điều kiện vận hành thay đổi, mục này tiến hành một *sweep* có hệ thống trên năm trục phân phối VNR độc lập, mỗi trục quét năm điểm xoay quanh một bộ dữ liệu trung tâm chung. Năm trục gồm: (1) **thời gian sống** trung bình của VNR (125–2000), (2) **kích thước** VNR (từ 2–3 đến 8–12 nút), (3) **mật độ liên kết** của VNR (xác suất cạnh 0,0–0,8), (4) **hệ số nhu cầu tài nguyên** ($0,5\times$ – $2,0\times$ so với chuẩn), và (5) **độ siết ràng buộc miền** (tỷ lệ nút ảo bị buộc miền 0,2–1,0). Tổng cộng 21 bộ dữ liệu (một trung tâm dùng chung cộng 5×4 điểm biên), mỗi bộ dữ liệu đánh giá trên 3000 VNR kiểm thử, so sánh CARL-VNE với heuristic **MP-VNE**. Toàn bộ sweep gồm 42 phép đánh giá (21 bộ dữ liệu $\times$ hai thuật toán) trên bộ dữ liệu 50 nút.

Hình 4.1 trình bày tỷ lệ chấp nhận của CARL-VNE và MP-VNE dọc theo cả năm trục. Có thể thấy CARL-VNE duy trì đường cong nằm trên MP-VNE ở gần

như toàn bộ dải quét.




Hình 4.1: Tỷ lệ chấp nhận trên năm trục phân phối VNR (50 nút).


Số liệu chi tiết của toàn bộ 21 bộ dữ liệu đã được liệt kê ở Bảng 4.3; tại bộ dữ liệu trung tâm dùng chung, CARL-VNE đạt 32,7% so với 25,5% của MP-VNE (+7,2 điểm phần trăm).

Phân tích theo từng trục cho thấy các xu hướng nhất quán với thiết kế của phương pháp. Ở trục **thời gian sống**, CARL-VNE dẫn mạnh nhất khi VNR sống ngắn (+9,8) rồi thu hẹp dần và đảo nhẹ (−0,7) khi thời gian sống rất dài, lúc này tài nguyên bão hoà nên mọi thuật toán tiệm cận nhau. Ở trục **kích thước**, lợi thế rõ rệt ở VNR cỡ vừa (+7) nhưng hoà ở hai cực: VNR rất nhỏ thì thuật toán nào cũng nhúng được, còn VNR rất lớn thì hầu như không nhúng được. Trục **mật độ liên kết** cho lợi thế *ổn định nhất*, duy trì $\approx +5$ điểm ở mọi mức mật độ. Trục **nhu cầu tài nguyên** cho lợi thế lớn nhất khi tài nguyên dồi dào (+10,7) và giảm dần khi tài nguyên khan hiếm (+3,0). Tương tự, trục **ràng buộc miền** cho thấy CARL-VNE dẫn mạnh khi ràng buộc lỏng (+9,3) và thu hẹp khi siết chặt (+2,4).


Để xem xét chi tiết hơn, Hình 4.2–4.6 trình bày đầy đủ bốn độ đo trên từng trục: tỉ lệ chấp nhận, chi phí trung bình, tỉ số doanh thu/chi phí và độ trễ trung bình. Bên cạnh ưu thế về tỉ lệ chấp nhận, CARL-VNE nhìn chung giữ chi phí trung bình và độ trễ ở mức tương đương hoặc thấp hơn MP-VNE, cho thấy việc chấp nhận thêm yêu cầu không phải đánh đổi bằng các lời giải kém hiệu quả.




Hình 4.2: Bốn đồ đo theo trực thời gian sống VNR (50 nút; tím: CARL-VNE, đỏ: MP-VNE).




Hình 4.3: Bốn đồ đo theo trực kích thước VNR (50 nút).



Hình 4.4: Bốn đồ đo theo trực mật độ liên kết VNR (50 nút).



Hình 4.5: Bốn đồ đo theo trực nhu cầu tài nguyên (50 nút).



Hình 4.6: Bốn đồ đo theo trực ràng buộc miễn (50 nút).


Tổng hợp lại, CARL-VNE thắng MP-VNE ở 19/21 bộ dữ liệu, chỉ thua biên ở hai trường hợp cực trị (thời gian sống rất dài $-0,7$ và VNR rất nhỏ $-1,1$), đều là các vùng mà bài toán hoặc quá bão hòa hoặc quá dễ nên dư địa cải thiện gần như bằng không. Ưu thế nhất quán trên cả năm trực (dẫn mạnh ở vùng dễ và tài nguyên dồi dào, thu hẹp dần ở vùng khan hiếm) cho thấy hiệu năng của phương pháp không phải do may rủi ở một phân phối cụ thể mà bền vững trên một dải điều kiện vận hành rộng, qua đó củng cố luận điểm trung tâm của đề án về hiệu quả của cơ chế lựa chọn ứng viên.

4.5 Quá trình huấn luyện hội tụ

CARL-VNE được huấn luyện qua hai giai đoạn (Mục 3.5): học bắt chước có giám sát từ heuristic MP-VNE, rồi tinh chỉnh bằng học tăng cường. Phần này trình bày quỹ đạo hội tụ của cả hai giai đoạn trên bộ dữ liệu 50 nút.

4.5.1 Giai đoạn học bắt chước


Hình 4.7 cho thấy quá trình học bắt chước: mất mát cross-entropy giảm đều khi đầu chọn ứng viên học theo lời giải của MP-VNE, đồng thời tỉ lệ nút đích nằm trong tập ứng viên đạt gần 100%. Điều này xác nhận đầu chọn ứng viên đã nắm được quy luật xếp hạng theo chi phí của heuristic, tạo điểm khởi đầu phương sai thấp cho giai đoạn tăng cường.



Hình 4.7: Hội tụ giai đoạn học bắt chước (50 nút): mất mát cross-entropy, tỉ lệ thành công của lời giải mẫu, và tỉ lệ nút đích nằm trong tập ứng viên.

4.5.2 Giai đoạn tinh chỉnh tăng cường


Hình 4.8 trình bày các chỉ báo hội tụ của giai đoạn tinh chỉnh tăng cường qua khoảng 150 epoch. Có thể quan sát ba xu hướng phù hợp với phân tích lý thuyết ở Mục 3.6.3: (i) entropy của chính sách giảm dần từ khoảng 9,4 về khoảng 4,3 rồi bão hoà, chính sách ngày càng tự tin; (ii) độ phân kỳ KL dao động quanh một mức nhỏ ổn định ($\approx 0,1-0,25$) thay vì bùng nổ, nhờ tác dụng của neo KL; và (iii) tỉ lệ thành công tăng rồi đạt bình nguyên quanh 34–35%.




Hình 4.8: Các chỉ báo hội tụ giai đoạn tinh chỉnh tăng cường (50 nút): mất mát, KL, entropy, tỉ lệ thành công.

Hình 4.9 và Hình 4.10 cho thấy đường cong tỉ lệ chấp nhận (trên tập kiểm thử) và phần thưởng trung bình theo epoch, đều tăng rồi đạt bình nguyên, xác nhận quá

trình tinh chỉnh hội tụ về một chính sách ổn định.



Hình 4.9: Tỷ lệ chấp nhận theo epoch khi tinh chỉnh tăng cường (test 50 nút).



Hình 4.10: Phần thưởng trung bình theo epoch khi tinh chỉnh tăng cường (50 nút).

4.6 Thảo luận

Kết quả thực nghiệm khẳng định ba điểm. **Thứ nhất**, trên toàn bộ 21 bộ dữ liệu phân phối VNR, CARL-VNE vượt heuristic MP-VNE ở 19/21 bộ dữ liệu với ưu thế nhất quán theo cả năm trục, cho thấy tính bền vững của phương pháp. **Thứ hai**, tại bộ dữ liệu trung tâm, CARL-VNE đạt 32,7% tỷ lệ chấp nhận so với 25,5% của MP-VNE. **Thứ ba**, quá trình huấn luyện hai giai đoạn hội tụ ổn định, không xảy ra hiện tượng sụp đổ phân phối nhờ neo KL.

Về **hạn chế**: ưu thế thu hẹp ở các vùng cực trị (tài nguyên khan hiếm, ràng buộc miền siết chặt, hoặc VNR rất lớn), nơi dư địa cải thiện nhỏ. Hiệu năng còn phụ thuộc phân phối VNR; với các phân phối lệch nhiều so với lúc huấn luyện, chính sách có thể cần tinh chỉnh lại. Việc đánh giá ở các quy mô lớn hơn (100 và 200 nút) chưa được đưa vào và là một hướng tiếp theo. Các hướng khắc phục được bàn ở

phần Kết luận.

Kết quả thực nghiệm cho thấy phương pháp đề xuất vượt heuristic MP-VNE trên gần như toàn bộ dải phân phối VNR ở bộ dữ liệu 50 nút, đồng thời giữ quá trình huấn luyện hai giai đoạn ổn định và hội tụ. Chương cuối tổng kết các đóng góp và đề xuất hướng phát triển.

KẾT LUẬN

Kết quả đạt được

Đồ án đã đề xuất và hiện thực hoá *CARL-VNE*, một phương pháp nhúng mạng ảo đa miền kết hợp mạng nơ-ron đồ thị với học tăng cường. Ba đóng góp chính đã được hoàn thành:

1. **Kiến trúc mã hoá phân cấp đa miền** gồm GCN nội miền và GCN liên miền, kết hợp đầu chọn ứng viên cross-attention tích hợp đặc trưng chi phí tường minh (cost-aware) và mặt nạ khả thi cứng, với toàn bộ mô hình chỉ khoảng 36,300 tham số.
2. **Quy trình huấn luyện hai giai đoạn** (khởi động bằng học bắt chước từ heuristic MP-VNE rồi tinh chỉnh actor-critic có neo KL) cùng phát hiện then chốt rằng *lựa chọn ứng viên* mới là đòn bẩy hiệu quả, và việc làm cho lựa chọn này ngẫu nhiên trong huấn luyện là điều kiện cần để vượt trần của mô hình bắt chước.
3. **Bộ benchmark đa bộ dữ liệu và đánh giá hệ thống** trên bộ dữ liệu 50 nút với 21 bộ dữ liệu phân phối VNR. Kết quả cho thấy phương pháp đề xuất vượt heuristic MP-VNE ở 19/21 bộ dữ liệu phân phối (tại bộ dữ liệu trung tâm đạt 32,7% so với 25,5%), cho thấy ưu thế bền vững trên một dải điều kiện vận hành rộng.

Hạn chế

Phương pháp còn một số hạn chế. Thứ nhất, đánh giá hiện mới giới hạn ở quy mô 50 nút; hiệu năng và khả năng mở rộng lên 100, 200 nút trở lên cần được kiểm chứng thêm. Thứ hai, ưu thế của phương pháp thu hẹp ở các vùng cực trị (tài nguyên khan hiếm, ràng buộc miền siết chặt, hoặc VNR rất lớn), nơi dư địa cải thiện nhỏ. Thứ ba, hiệu năng phụ thuộc phân phối VNR lúc huấn luyện; với phân phối lệch nhiều, chính sách có thể cần tinh chỉnh lại. Thứ tư, chi phí huấn luyện (khoảng 150 epoch) tuy chấp nhận được nhưng không nhỏ, và đồ án chưa khảo sát đầy đủ khía cạnh công bằng tài nguyên giữa nhiều người thuê.

Hướng phát triển trong tương lai

Một số hướng phát triển khả thi gồm: (1) **mở rộng quy mô** đánh giá lên 100, 200 nút rồi tới 500–1000 nút (các tập dữ liệu đã sẵn sàng) với bộ mã hoá GAT đa lớp biểu cảm hơn; (2) **học chuyển giao và meta-RL** để chính sách thích nghi nhanh giữa các tô-pô và phân phối yêu cầu khác nhau; (3) **tích hợp cận trên ILP** cho các tô-pô nhỏ nhằm định lượng khoảng cách tới tối ưu; (4) **tối ưu trực tuyến** có tính

tới thời gian sống và lịch đến của VNR để giữ “khoảng trống chiến lược”; và (5) bổ sung **tiêu chí công bằng** giữa các miền và người thuê vào hàm thưởng. Việc hoàn tất so sánh trực tiếp giữa chế độ actor-critic và biến thể PPO có cắt cũng là một bước tiếp theo trực tiếp.

TÀI LIỆU THAM KHẢO

- [1] L. L. Peterson **and** B. S. Davie, *Computer networks: a systems approach*. Elsevier, 2007.
- [2] D. Kreutz, F. M. V. Ramos, P. E. Verissimo, C. E. Rothenberg, S. Azodolmolky **and** S. Uhlig, “Software-defined networking: A comprehensive survey,” *Proceedings of the IEEE*, 2015.
- [3] R. Mijumbi, J. Serrat, J.-L. Gorricho, N. Bouten, F. De Turck **and** R. Boutaba, “Network function virtualization: State-of-the-art and research challenges,” *IEEE Communications Surveys & Tutorials*, 2016.
- [4] A. Fischer, J. F. Botero, M. T. Beck, H. de Meer **and** X. Hesselbach, “Virtual network embedding: A survey,” *IEEE Communications Surveys & Tutorials*, **jourvol** 15, **number** 4, **pages** 1888–1906, 2013.
- [5] H. Cao, L. Yang **and** H. Zhu, “Survey on virtual network embedding: Theory and practice,” *IEEE Communications Surveys & Tutorials*, 2019.
- [6] N. M. M. K. Chowdhury, M. R. Rahman **and** R. Boutaba, “Virtual network embedding with coordinated node and link mapping,” **in** *IEEE INFOCOM* 2009.
- [7] R. S. Sutton **and** A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd. MIT Press, 2018.
- [8] V. Mnih **and others**, “Human-level control through deep reinforcement learning,” *Nature*, **jourvol** 518, **pages** 529–533, 2015.
- [9] R. J. Williams, “Simple statistical gradient-following algorithms for connectionist reinforcement learning,” *Machine Learning*, **jourvol** 8, **pages** 229–256, 1992.
- [10] J. Schulman, F. Wolski, P. Dhariwal, A. Radford **and** O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [11] T. N. Kipf **and** M. Welling, “Semi-supervised classification with graph convolutional networks,” **in** *ICLR* 2017.
- [12] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò **and** Y. Bengio, “Graph attention networks,” **in** *ICLR* 2018.
- [13] A. Vaswani, N. Shazeer, N. Parmar **and others**, “Attention is all you need,” **in** *Advances in Neural Information Processing Systems (NeurIPS)* 2017.
- [14] D. G. Andersen, *Theoretical approaches to node assignment*, Unpublished manuscript, 2002.
- [15] Y. Zhu **and** M. Ammar, “Algorithms for assigning substrate network resources to virtual network components,” **in** *IEEE INFOCOM* 2006.

- [16] X. Cheng, S. Su, Z. Zhang **and others**, “Virtual network embedding through topology-aware node ranking,” *in ACM SIGCOMM Computer Communication Review* 2011.
- [17] L. Gong, Y. Wen, Z. Zhu **and** T. Lei, “Toward profit-seeking virtual network embedding algorithm via global resource capacity,” *in IEEE INFOCOM* 2014.
- [18] I. Houidi, W. Louati **and** D. Zeghlache, “A distributed virtual network mapping algorithm,” *in IEEE International Conference on Communications (ICC)* 2008.
- [19] J. Lischka **and** H. Karl, “A virtual network mapping algorithm based on subgraph isomorphism detection,” *in ACM SIGCOMM Workshop on Virtualized Infrastructure Systems and Architectures (VISA)* 2009.
- [20] M. Yu, Y. Yi, J. Rexford **and** M. Chiang, “Rethinking virtual network embedding: Substrate support for path splitting and migration,” *ACM SIGCOMM Computer Communication Review*, **jourvol** 38, **number** 2, **pages** 17–29, 2008.
- [21] A. Author **and** B. Author, “Mp-vne: Marking-probability-based virtual network embedding for online requests,” *Computer Networks*, 2020, TODO: cập nhật metadata chính xác.
- [22] R. Mijumbi, J.-L. Gorricho, J. Serrat, M. Claeys, F. De Turck **and** S. Latré, “Design and evaluation of learning algorithms for dynamic resource management in virtual networks,” *in IEEE Network Operations and Management Symposium (NOMS)* 2014.
- [23] Z. Wu, S. Pan, F. Chen, G. Long, C. Zhang **and** P. S. Yu, “A comprehensive survey on graph neural networks,” *IEEE Transactions on Neural Networks and Learning Systems*, **jourvol** 32, **number** 1, **pages** 4–24, 2021.
- [24] H. Yao, X. Chen, M. Li, P. Zhang **and** L. Wang, “A novel reinforcement learning algorithm for virtual network embedding,” *in Neurocomputing* 2018.
- [25] M. Dolati, S. B. Hassanpour, M. Ghaderi **and** A. Khonsari, “Deepvine: Virtual network embedding with deep reinforcement learning,” *in IEEE INFOCOM Workshops* 2019.
- [26] A. Blenk, P. Kalmbach, J. Zerwas, M. Jarschel, S. Schmid **and** W. Kellerer, “Neurovine: A neural preprocessor for your virtual network embedding algorithm,” *in IEEE INFOCOM* 2018.
- [27] T. Wang, Q. Fan, C. Wang, L. Ding, N. J. Yuan **and** H. Xiong, “Flagvne: A flexible and generalizable reinforcement learning framework for network resource allocation,” *in Proc. IJCAI* 2024.
- [28] S. Haeri **and** L. Trajković, “Virtual network embedding via monte carlo tree search,” *IEEE Transactions on Cybernetics*, **jourvol** 48, **number** 2, **pages** 510–521, 2018.

- [29] W. Kool, H. van Hoof **and** M. Welling, “Attention, learn to solve routing problems!” **in** *International Conference on Learning Representations (ICLR)* 2019.

PHỤ LỤC

A. CHI TIẾT KIẾN TRÚC, SIÊU THAM SỐ VÀ KẾT QUẢ

Phụ lục này cung cấp các chi tiết bổ sung về kiến trúc mạng chính sách, siêu tham số và kết quả thực nghiệm đầy đủ theo từng epoch, nhằm hỗ trợ tái lập kết quả của đồ án.

A.1 Chi tiết tham số mạng chính sách

Toàn bộ mạng chính sách CARL-VNE có khoảng 36,300 tham số, phân bổ theo các khối như Bảng A.1; tất cả đều được cập nhật trong quá trình tinh chỉnh tăng cường.

Bảng A.1: Phân bổ tham số theo khối của mạng chính sách

Khối	Số tham số
GCN nội miền + liên miền (substrate)	7,296
GCN mạng ảo (VN-GCN)	1,376
Self-attention mạng ảo	6,304
Đầu chọn ứng viên (candidate head)	14,905
Bộ phê bình giá trị (value head)	6,338
Tổng	36,219

A.2 Cấu hình kiến trúc chi tiết

Bảng A.2 liệt kê các tham số cấu hình kiến trúc. Bộ mã hoá nội miền dùng GCN ba lớp, bộ mã hoá liên miền dùng GCN hai lớp, đều với chiều ẩn 32. Khối self-attention mạng ảo dùng 4 đầu. Đặc trưng đầu vào của nút vật lý và nút ảo đều có 7 chiều.

Bảng A.2: Tham số cấu hình kiến trúc

Tham số	Giá trị
Số lớp GCN nội miền	3
Số lớp GCN liên miền	2
Chiều ẩn (mọi GCN)	32
Số lớp GCN mạng ảo	2
Số đầu self-attention	4
Chiều đặc trưng nút vật lý	7
Chiều đặc trưng nút ảo	7
Chiều ẩn đầu chọn ứng viên	64
Số ứng viên giữ lại / miền (K)	1
Hàm kích hoạt	ReLU
Chuẩn hoá	LayerNorm + residual

A.3 Kết quả chi tiết theo epoch trên bộ dữ liệu 50 nút

Bảng A.3 trình bày kết quả đánh giá CARL-VNE trên 3000 VNR kiểm thử ở từng epoch của giai đoạn tinh chỉnh tăng cường. Tỷ lệ chấp nhận đạt đỉnh 33,13% tại epoch 19; giá trị trung bình qua các epoch là khoảng 31,3%, ổn định và luôn cao hơn baseline MP-VNE (29,03%).

Bảng A.3: Kết quả CARL-VNE theo epoch (giai đoạn tinh chỉnh tăng cường, 50 nút)

Epoch	Chấp nhận	R/C	Chi phí	Epoch	Chấp nhận	R/C	Chi phí
1	0.3147	0.3143	231.5	17	0.3100	0.3048	233.4
2	0.2930	0.2836	242.3	18	0.3107	0.3050	224.5
3	0.3243	0.3070	243.6	19	0.3313	0.3099	233.8
4	0.3147	0.3087	236.9	20	0.3257	0.3092	233.5
5	0.3140	0.2970	240.2	21	0.3107	0.3013	234.8
6	0.3047	0.3045	233.2	22	0.3167	0.3090	227.3
7	0.3137	0.3015	235.1	23	0.3150	0.3046	237.7
8	0.2940	0.2918	241.3	24	0.3107	0.3010	239.1
9	0.3060	0.2988	241.9	25	0.3133	0.2975	241.0
10	0.3163	0.3128	228.1	26	0.3093	0.2975	239.9
11	0.3183	0.3059	236.6	27	0.3113	0.2997	235.7
12	0.3057	0.3067	237.5	28	0.3107	0.2934	243.2
13	0.3107	0.2954	240.3	29	0.3180	0.3079	238.5
14	0.3107	0.3002	237.6	30	0.2973	0.2948	245.5
15	0.3087	0.3000	235.0	31	0.3193	0.3046	237.0
16	0.3290	0.3050	235.7	32	0.3113	0.2996	240.2

B. CHI TIẾT TẬP DỮ LIỆU VÀ THUẬT TOÁN SO SÁNH

Phụ lục này mô tả chi tiết cách sinh các tập dữ liệu thực nghiệm và tham số cấu hình của các thuật toán baseline dùng để so sánh, nhằm bảo đảm khả năng tái lập.

B.1 Chi tiết sinh tập dữ liệu

Mỗi bộ dữ liệu gồm một mạng vật lý đa miền và hai tập VNR (huấn luyện và kiểm thử) tách biệt. Mạng vật lý được chia thành 10 miền; các nút và liên kết được sinh ngẫu nhiên trong các khoảng tham số ở Bảng B.1. Các liên kết liên miền nối các nút biên giữa những miền lân cận, tạo thành một tô-pô liên miền liên thông.

Bảng B.1: Khoảng tham số sinh mạng vật lý (bộ dữ liệu 50 nút)

Tham số	Giá trị
Số miền	10
Số nút	50
Số liên kết	50
Dung lượng CPU	10.5–29.4
Đơn giá CPU	1.1–3.95
Băng thông liên kết	42–93
Đơn giá băng thông	0.18–0.99
Độ trễ xử lý	0.25–1.87
Độ trễ truyền dẫn	1.05–9.76

Các yêu cầu mạng ảo được sinh với tham số ở Bảng B.2. Thời điểm đến tuân theo tiến trình Poisson và thời gian sống được sinh ngẫu nhiên, mô phỏng kịch bản trực tuyến nơi VNR đến và rời đi liên tục theo thời gian. Tập huấn luyện gồm 10,000 VNR, tập kiểm thử gồm 3,000 VNR.

Bảng B.2: Khoảng tham số sinh yêu cầu mạng ảo

Tham số	Giá trị
Số nút mỗi VNR	3–7 (trung bình 5)
Nhu cầu CPU mỗi nút ảo	1.0–8.0
Nhu cầu băng thông mỗi liên kết ảo	5.0–25.0
Phân phối thời điểm đến	Poisson
Thời gian sống	ngẫu nhiên
Số VNR huấn luyện	10,000
Số VNR kiểm thử	3,000

B.2 Tham số các thuật toán so sánh

Bảng B.3 liệt kê tham số của baseline **MP-VNE**: PSO theo bài báo gốc (10 hạt, 50 vòng lặp, hệ số quán tính/nhận thức/xã hội 0,3/0,3/0,4), xếp hạng ứng viên theo chi phí ước lượng (PreCost) và ánh xạ liên kết bằng đường đi ngắn nhất.

Bảng B.3: Tham số PSO của baseline MP-VNE

Tham số	MP-VNE
Số hạt (particles)	10
Số vòng lặp (iterations)	50
Hệ số quán tính α	0.3
Hệ số nhận thức β	0.3
Hệ số xã hội γ	0.4
Xác suất đột biến	0.1
Số ứng viên (top-K)	top-K theo miền

Mô hình **R2** là mạng chính sách chỉ qua giai đoạn học bắt chước, chưa tinh chỉnh tăng cường; nó đóng vai trò chính sách tham chiếu cho số hạng neo KL ở giai đoạn tinh chỉnh (Mục 3.5.2).