

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Nghiên cứu và đề xuất phương pháp học tăng cường
cho bài toán nhúng mạng ảo (Virtual Network
Embedding)

NGUYỄN VĂN DU

du.nv200000@sis.hust.edu.vn

Ngành: Khoa học máy tính

Giảng viên hướng dẫn: TS. ...

Khoa: Khoa học máy tính

Trường: Công nghệ thông tin và Truyền thông

HÀ NỘI, 06/2026

ĐẠI HỌC BÁCH KHOA HÀ NỘI

ĐỒ ÁN TỐT NGHIỆP

Nghiên cứu và đề xuất phương pháp học tăng cường
cho bài toán nhúng mạng ảo (Virtual Network
Embedding)

NGUYỄN VĂN DU

du.nv200000@sis.hust.edu.vn

Ngành: Khoa học máy tính

Giảng viên hướng dẫn: TS. ... _____

Chữ ký GVHD

Khoa: Khoa học máy tính

Trường: Công nghệ Thông tin và Truyền thông

HÀ NỘI, 06/2026

LỜI CẢM ƠN

Trước hết, em xin bày tỏ lòng biết ơn sâu sắc tới **TS. [Tên giảng viên hướng dẫn]**, người đã trực tiếp định hướng đề tài, tận tình chỉ bảo và đồng hành cùng em trong suốt quá trình thực hiện đồ án này. Những góp ý quý báu của thầy/cô về cả hướng nghiên cứu lẫn cách trình bày khoa học đã giúp em hoàn thiện công trình một cách chu đáo hơn rất nhiều.

Em cũng xin chân thành cảm ơn các thầy cô trong Trường Công nghệ Thông tin và Truyền thông, Đại học Bách khoa Hà Nội, đã trang bị cho em nền tảng kiến thức vững chắc trong suốt những năm học vừa qua, làm cơ sở để em thực hiện đề tài về nhúng mạng ảo và học tăng cường này.

Cuối cùng, em xin gửi lời cảm ơn tới gia đình và bạn bè — những người đã luôn động viên, ủng hộ và là chỗ dựa tinh thần cho em trong suốt quãng thời gian học tập và hoàn thành đồ án tốt nghiệp.

Em xin chân thành cảm ơn!

TÓM TẮT NỘI DUNG ĐỒ ÁN

Bài toán nhúng mạng ảo (Virtual Network Embedding - VNE) là bài toán nền tảng của ảo hoá mạng, đòi hỏi ánh xạ mỗi yêu cầu mạng ảo lên hạ tầng vật lý sao cho thoả mãn ràng buộc tài nguyên và tối ưu hiệu quả phục vụ. VNE đã được chứng minh là NP-Hard, và các kịch bản thực tế còn phức tạp hơn do tính trực tuyến và quy mô lớn. Các phương pháp heuristic chạy nhanh nhưng phụ thuộc tri thức chuyên gia và khó tổng quát hoá; các phương pháp học tăng cường gần đây khắc phục được điều này nhưng thường bất ổn định, tốn mẫu và bỏ qua tri thức tô-pô sẵn có.

Đồ án đề xuất *RL-OA-MP-VNE*, một phương pháp kết hợp mạng nơ-ron đồ thị với học tăng cường cho VNE đa miền. Phương pháp dùng một bộ mã hoá đồ thị *phân cấp* (GCN nội miền kết hợp GCN liên miền) và một bộ giải mã chọn ứng viên dựa trên cơ chế attention với thiên lệch chi phí tường minh. Quy trình huấn luyện gồm hai giai đoạn: khởi động bằng học bắt chước từ heuristic OA-MP-VNE, rồi tinh chỉnh bằng phương pháp actor-critic có neo Kullback-Leibler. Đóng góp cốt lõi là phát hiện rằng *lựa chọn ứng viên* mới là đòn bẩy hiệu quả của học tăng cường, và việc làm cho lựa chọn này ngẫu nhiên trong huấn luyện là điều kiện cần để vượt trần hiệu năng của mô hình bắt chước; nhờ đó hai đầu xếp hạng được đóng băng và chỉ đầu chọn ứng viên được tinh chỉnh.

Thực nghiệm trên ba quy mô (50, 100, 200 nút) cho thấy phương pháp đề xuất đạt 33,1% tỉ lệ chấp nhận trên kịch bản 50 nút (vượt heuristic 29,0%), cải thiện +8,8 điểm phần trăm so với mô hình chỉ học bắt chước trên kịch bản 100 nút (26,0% so với 17,2%), và chính sách học được chuyển giao tốt sang quy mô lớn hơn, đồng thời quá trình huấn luyện hội tụ ổn định.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

ABSTRACT

Virtual Network Embedding (VNE) is a fundamental problem in network virtualization: each virtual network request must be mapped onto a shared physical substrate so as to satisfy resource constraints while optimizing service efficiency. VNE is NP-Hard, and real deployments are harder still due to their online nature and large scale. Heuristic methods are fast but rely on expert knowledge and generalize poorly; recent reinforcement-learning (RL) methods overcome this but tend to be unstable, sample-inefficient, and ignore readily available topological knowledge.

This thesis proposes *RL-OA-MP-VNE*, a method that combines graph neural networks with reinforcement learning for multi-domain VNE. It uses a *hierarchical* graph encoder (intra-domain GCN combined with an inter-domain GCN) and an attention-based candidate decoder with an explicit cost bias and a hard feasibility mask. Training proceeds in two stages: an imitation-learning warm-start from the OA-MP-VNE heuristic, followed by actor-critic fine-tuning with a Kullback-Leibler anchor. The core contribution is the finding that *candidate selection*, rather than processing order, is the effective lever for RL, and that making this selection stochastic during training is necessary to surpass the imitation ceiling; accordingly, the two ranking heads are frozen and only the candidate head is fine-tuned.

Experiments at three scales (50, 100, 200 nodes) show that the proposed method reaches 33.1% acceptance on the 50-node scenario (beating the 29.0% heuristic), improves by +8.8 percentage points over the imitation-only model on the 100-node scenario (26.0% vs. 17.2%), and transfers well to larger scales, all while converging stably during training.

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI.....	1
1.1 Đặt vấn đề.....	1
1.2 Các giải pháp hiện tại và hạn chế	2
1.2.1 Hướng heuristic và metaheuristic.....	2
1.2.2 Hướng lập trình toán học	2
1.2.3 Hướng học tăng cường.....	2
1.3 Mục tiêu và định hướng giải pháp	2
1.4 Đóng góp của đề án	3
1.5 Bố cục đề án	3
CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT	5
2.1 Mô hình hoá bài toán nhúng mạng ảo	5
2.1.1 Mạng vật lý và mạng ảo.....	5
2.1.2 Hai pha của VNE: ánh xạ nút và ánh xạ liên kết.....	5
2.1.3 Hàm mục tiêu và độ đo hiệu năng.....	6
2.1.4 Phát biểu bài toán dưới dạng ILP	6
2.2 Các hướng tiếp cận hiện tại.....	7
2.2.1 Hướng heuristic	7
2.2.2 Hướng metaheuristic	7
2.2.3 Hướng học tăng cường.....	8
2.2.4 So sánh và động lực của đề án.....	8
2.3 Học tăng cường sâu.....	8
2.3.1 Quá trình quyết định Markov.....	8
2.3.2 Policy gradient và Actor-Critic	9
2.3.3 Tối ưu hoá chính sách gần kề (PPO).....	10

2.3.4 Plackett-Luce sampling.....	10
2.4 Mạng nơ-ron đồ thị	10
2.4.1 Cơ chế truyền tin.....	10
2.4.2 Graph Convolutional Network.....	11
2.4.3 Graph Attention Network.....	11
2.5 Cơ chế attention cho lựa chọn ứng viên.....	11
CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT.....	13
3.1 Tổng quan giải pháp.....	13
3.1.1 Ba nguyên lý thiết kế	13
3.1.2 Sơ đồ khối hệ thống	14
3.1.3 Luồng tương tác môi trường - tác nhân.....	14
3.2 Bộ mã hoá đồ thị (Graph Encoder)	14
3.2.1 Mã hoá mạng vật lý phân cấp	14
3.2.2 Mã hoá yêu cầu mạng ảo	15
3.2.3 Trộn biểu diễn substrate và VNR	15
3.2.4 Phân tích thiết kế.....	16
3.3 Bộ giải mã chọn ứng viên (Candidate Decoder).....	16
3.3.1 Sinh tập ứng viên cho mỗi nút ảo.....	16
3.3.2 Cơ chế attention chọn ứng viên.....	16
3.3.3 Lựa chọn ngẫu nhiên khi huấn luyện và tất định khi suy diễn	17
3.3.4 Ánh xạ liên kết.....	17
3.3.5 Tính toán xác suất hành động hợp thành.....	17
3.4 Môi trường học tăng cường.....	18
3.4.1 Không gian trạng thái	18
3.4.2 Không gian hành động.....	18
3.4.3 Hàm phần thưởng.....	18

3.4.4 Cơ chế xử lý hành động không hợp lệ.....	18
3.5 Quy trình huấn luyện hai giai đoạn.....	19
3.5.1 Giai đoạn 1: Tiền huấn luyện có giám sát từ OA-MP-VNE	19
3.5.2 Giai đoạn 2: Tinh chỉnh bằng actor-critic có neo KL	19
3.5.3 Kỹ thuật đóng băng tham số.....	20
3.5.4 Mã giả thuật toán huấn luyện tổng thể.....	20
3.5.5 Các thủ thuật ổn định	21
CHƯƠNG 4. PHÂN TÍCH LÝ THUYẾT.....	22
4.1 Độ phức tạp tính toán.....	22
4.1.1 Độ phức tạp suy diễn (inference)	22
4.1.2 Độ phức tạp một bước huấn luyện.....	22
4.2 Độ phức tạp bộ nhớ.....	23
4.3 Phân tích hội tụ	23
4.3.1 Cải thiện đơn điệu của gradient chính sách có baseline	23
4.3.2 Vai trò của neo KL và đóng băng tham số	23
4.3.3 Quan sát thực nghiệm về tính hội tụ.....	24
CHƯƠNG 5. ĐÁNH GIÁ THỰC NGHIỆM.....	25
5.1 Cấu hình thực nghiệm	25
5.1.1 Phần cứng và phần mềm	25
5.1.2 Tập dữ liệu	25
5.1.3 Siêu tham số huấn luyện	25
5.2 Baseline và độ đo	26
5.2.1 Các thuật toán so sánh	26
5.2.2 Độ đo đánh giá	26
5.3 Kết quả tổng thể	27
5.3.1 Kết quả trên kịch bản 50 nút.....	27

5.3.2 Kết quả trên kịch bản 100 nút.....	28
5.3.3 Kết quả trên kịch bản 200 nút.....	28
5.3.4 Tổng hợp và bàn luận	28
5.4 Phân tích ablation	29
5.4.1 Ảnh hưởng của giai đoạn học tăng cường	29
5.4.2 Vai trò của khám phá trong lựa chọn ứng viên.....	29
5.4.3 So sánh actor-critic với biến thể PPO có cắt.....	29
5.5 Trực quan hoá quỹ đạo huấn luyện	29
5.6 Thảo luận.....	31
CHƯƠNG 6. KẾT LUẬN	32
6.1 Kết quả đạt được.....	32
6.2 Hạn chế	32
6.3 Hướng phát triển trong tương lai	32
TÀI LIỆU THAM KHẢO.....	35
PHỤ LỤC.....	37
A. CHI TIẾT KIẾN TRÚC, SIÊU THAM SỐ VÀ KẾT QUẢ.....	37
A.1 Chi tiết tham số mạng chính sách	37
A.2 Cấu hình kiến trúc chi tiết.....	37
A.3 Kết quả chi tiết theo epoch trên kịch bản 50 nút	38
B. CHI TIẾT TẬP DỮ LIỆU VÀ THUẬT TOÁN SO SÁNH	39
B.1 Chi tiết sinh tập dữ liệu.....	39
B.2 Tham số các thuật toán so sánh	40

DANH MỤC HÌNH VẼ

Hình 3.1	Kiến trúc tổng thể của RL-OA-MP-VNE. Khối tô đậm được huấn luyện ở giai đoạn tinh chỉnh; khối nét đứt (hai đầu xếp hạng) bị đóng băng.	14
Hình 5.1	So sánh RL-OA-MP-VNE (theo từng epoch) với baseline MP-VNE-V4 trên kịch bản 50 nút, bốn độ đo: tỉ lệ chấp nhận, chi phí, R/C, độ trễ.	27
Hình 5.2	Các chỉ báo hội tụ của quá trình huấn luyện cấu hình chuẩn trên kịch bản 50 nút: mất mát, KL, entropy và tỉ lệ thành công qua các epoch.	30
Hình 5.3	Đường cong tỉ lệ chấp nhận theo epoch trên tập kiểm thử 50 nút.	30
Hình 5.4	Đường cong phần thưởng trung bình theo epoch (cấu hình chuẩn, 50 nút).	31

DANH MỤC BẢNG BIỂU

Bảng 2.1	So sánh ba hướng tiếp cận VNE	8
Bảng 5.1	Tham số các tập dữ liệu thực nghiệm	25
Bảng 5.2	Siêu tham số cấu hình chuẩn (V19 normal-reward)	26
Bảng 5.3	Kết quả trên kịch bản 50 nút (3000 VNR kiểm thử)	27
Bảng 5.4	Kết quả trên kịch bản 100 nút (3000 VNR kiểm thử)	28
Bảng 5.5	Kết quả trên kịch bản 200 nút (3000 VNR kiểm thử)	28
Bảng A.1	Phân bố tham số theo khối của mạng chính sách	37
Bảng A.2	Tham số cấu hình kiến trúc	38
Bảng A.3	Kết quả theo epoch trên kịch bản 50 nút (cấu hình chuẩn) . . .	38
Bảng B.1	Khoảng tham số sinh mạng vật lý (kịch bản 50 và 100 nút) . .	39
Bảng B.2	Khoảng tham số sinh yêu cầu mạng ảo	39
Bảng B.3	Tham số PSO của các baseline heuristic	40

DANH MỤC THUẬT NGỮ VÀ TỪ VIẾT TẮT

Thuật ngữ	Ý nghĩa
A3C	Asynchronous Advantage Actor-Critic
CPU	Đơn vị xử lý trung tâm (Central Processing Unit)
DRL	Học tăng cường sâu (Deep Reinforcement Learning)
GAT	Mạng đồ thị chú ý (Graph Attention Network)
GCN	Mạng tích chập đồ thị (Graph Convolutional Network)
GNN	Mạng nơ-ron đồ thị (Graph Neural Network)
ILP	Quy hoạch nguyên tuyến tính (Integer Linear Programming)
InP	Nhà cung cấp hạ tầng (Infrastructure Provider)
MC-VNM	Thuật toán nhúng dựa trên Monte-Carlo (Monte-Carlo Virtual Network Mapping)
MDP	Quá trình quyết định Markov (Markov Decision Process)
MP-VNE	Thuật toán heuristic dựa trên xếp hạng nút (Marking-Probability VNE)
NFV	Ảo hoá chức năng mạng (Network Function Virtualization)
OA-MP-VNE	Phiên bản mở rộng đa mục tiêu của MP-VNE (Objective-Aware MP-VNE)
PPO	Thuật toán policy gradient có kẹp tỉ số xác suất (Proximal Policy Optimization)
PSO	Tối ưu hoá bầy hạt (Particle Swarm Optimization)
QoS	Chất lượng dịch vụ (Quality of Service)
RL	Học tăng cường (Reinforcement Learning)

Thuật ngữ	Ý nghĩa
SDN	Mạng định nghĩa bằng phần mềm (Software-Defined Networking)
VNE	Bài toán nhúng mạng ảo (Virtual Network Embedding)
VNR	Yêu cầu mạng ảo (Virtual Network Request)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

Chương này giới thiệu bối cảnh và động lực của bài toán nhúng mạng ảo (Virtual Network Embedding - VNE), khảo sát ngắn gọn các hướng tiếp cận hiện hành cùng những hạn chế còn tồn đọng, xác định mục tiêu, định hướng giải pháp và đóng góp chính của đề án. Phần cuối chương trình bày bố cục của báo cáo.

1.1 Đặt vấn đề

Trong vòng hai thập kỷ qua, sự bùng nổ của điện toán đám mây, Internet vạn vật (IoT) và các dịch vụ thời gian thực đã tạo nên áp lực rất lớn lên hạ tầng mạng truyền thống. Mỗi dịch vụ có yêu cầu khác biệt về băng thông, độ trễ và đặc tính bảo mật, dẫn đến nhu cầu chạy nhiều mạng logic độc lập trên cùng một hạ tầng vật lý. Công nghệ **ảo hoá mạng** (Network Virtualization) ra đời nhằm đáp ứng nhu cầu này, đóng vai trò nền tảng cho các kiến trúc *Software-Defined Networking* (SDN) và *Network Function Virtualization* (NFV) hiện đại[1], [2].

Trong mô hình ảo hoá mạng, nhà cung cấp hạ tầng (Infrastructure Provider - InP) đồng thời phục vụ nhiều nhà cung cấp dịch vụ (Service Provider - SP). Mỗi SP gửi tới InP một *yêu cầu mạng ảo* (Virtual Network Request - VNR) gồm tô-pô nút - cạnh cùng các yêu cầu tài nguyên (CPU cho nút, băng thông cho cạnh). Nhiệm vụ của InP là tìm cách **nhúng** từng VNR lên mạng vật lý sao cho thỏa mãn ràng buộc tài nguyên và tối ưu một hàm mục tiêu đã định, chẳng hạn tỉ lệ chấp nhận yêu cầu hay tỉ số doanh thu trên chi phí (R/C)[3], [4].

Bài toán nhúng mạng ảo là cốt lõi của các kịch bản 5G/6G network slicing, multi-tenant cloud và edge computing. Hiệu quả của thuật toán VNE ảnh hưởng trực tiếp tới khả năng tận dụng hạ tầng, chất lượng dịch vụ và doanh thu của nhà cung cấp. Mặt khác, VNE đã được chứng minh là NP-Hard [5]: ngay cả phiên bản ánh xạ nút đơn lẻ đã quy được về bài toán Multi-Way Separator Problem, do vậy không thể giải tối ưu trong thời gian đa thức ở quy mô thực tế. Tính chất NP-Hard, kết hợp với tô-pô mạng vật lý có thể lên đến hàng trăm nút và VNR đến liên tục theo thời gian, đặt ra một thách thức tính toán rất lớn cho thiết kế thuật toán.

Trong các kịch bản thực tế, bài toán còn phức tạp hơn do tính **trực tuyến**: VNR đến theo phân phối Poisson, có thời gian sống ngẫu nhiên, và quyết định nhúng cho từng VNR phải đưa ra ngay lập tức mà không biết trước các yêu cầu trong tương lai. Một thuật toán tốt phải vừa khai thác hiệu quả tài nguyên hiện tại, vừa giữ “khoảng trống” chiến lược để phục vụ các yêu cầu sau.

1.2 Các giải pháp hiện tại và hạn chế

Các nghiên cứu hiện nay có thể chia thành ba nhóm chính như sau.

1.2.1 Hướng heuristic và metaheuristic

Nhóm này gồm các thuật toán dựa trên tri thức chuyên gia, sử dụng các luật heuristic để xếp hạng nút và tìm đường đi. Đại diện tiêu biểu là VNE-NR[6] ánh xạ nút theo NodeRank, ViNE[5] dùng LP-relaxation để gợi ý ánh xạ nút rồi ánh xạ liên kết bằng đường đi ngắn nhất, và MP-VNE[7] kết hợp lựa chọn ứng viên theo chi phí ước lượng với tối ưu hoá bầy hạt PSO. Ưu điểm của nhóm này là đơn giản, dễ triển khai và chạy nhanh. Nhược điểm là phụ thuộc nặng vào tri thức chuyên gia, khó tổng quát hoá khi tô-pô và phân phối yêu cầu thay đổi, đồng thời dễ rơi vào tối ưu cục bộ.

1.2.2 Hướng lập trình toán học

Bài toán VNE có thể được phát biểu chính xác dưới dạng quy hoạch nguyên tuyến tính (Integer Linear Programming - ILP) hoặc Mixed-Integer Linear Programming. Phương pháp này cho lời giải tối ưu trong từng bước, đồng thời cung cấp cận trên hữu ích để so sánh các phương pháp xấp xỉ. Tuy nhiên, độ phức tạp tính toán theo cấp số mũ khiến cách tiếp cận này chỉ khả thi trên các tô-pô rất nhỏ (dưới 30 nút vật lý), trong khi hạ tầng thực tế thường có hàng trăm đến hàng nghìn nút. Hơn nữa, ILP không thích hợp với kịch bản trực tuyến vì thời gian giải thường vượt quá ngân sách thời gian cho phép của mỗi VNR.

1.2.3 Hướng học tăng cường

Trong vài năm gần đây, học tăng cường sâu (Deep Reinforcement Learning - DRL) được ứng dụng rộng rãi cho VNE nhằm khắc phục các hạn chế của heuristic. Các nghiên cứu tiêu biểu gồm A3C-GCN của Yao và cộng sự[8], FlagVNE[9]. Tác nhân RL học chính sách ánh xạ end-to-end trực tiếp từ tín hiệu thưởng, không cần luật heuristic cứng nhắc. Tuy nhiên, các phương pháp hiện hành còn gặp ba hạn chế chính: (i) phụ thuộc mạnh vào việc *reward shaping* chính xác, dễ bất ổn định khi reward thừa; (ii) bỏ qua tri thức tô-pô có sẵn từ các thuật toán heuristic mạnh, khiến tác nhân tốn rất nhiều mẫu để khám phá lại các quy luật đơn giản; và (iii) không gian hành động lớn (chọn một trong hàng trăm nút vật lý cho mỗi nút ảo) làm chính sách khó hội tụ ở các tô-pô lớn.

1.3 Mục tiêu và định hướng giải pháp

Trên cơ sở phân tích các hạn chế ở trên, đề án đặt ra ba mục tiêu cụ thể:

1. **Trích xuất biểu diễn tô-pô đầy đủ** cho cả mạng vật lý và yêu cầu mạng ảo bằng mạng nơ-ron đồ thị (GNN), thay cho các đặc trưng thủ công của heuristic.

2. **Thu hẹp không gian hành động** bằng cơ chế attention chọn tập ứng viên (candidate) cho từng nút ảo, giúp tác nhân tập trung học sự đánh đổi giữa các phương án thực sự khả thi.
3. **Tận dụng tri thức từ heuristic** thông qua giai đoạn tiền huấn luyện có giám sát dựa trên lời giải của thuật toán MP-VNE / OA-MP-VNE, rồi tinh chỉnh chính sách bằng học tăng cường để vượt qua trần hiệu năng của heuristic.

Định hướng giải pháp tổng thể là xây dựng kiến trúc *RL-OA-MP-VNE* gồm một bộ mã hoá đồ thị *phân cấp đa miền* (GCN nội miền kết hợp GCN liên miền), ba đầu ra tác vụ (đầu xếp hạng nút ảo, đầu xếp hạng liên kết ảo và đầu chọn ứng viên cross-attention) cùng một bộ phê bình giá trị, kết hợp với quy trình huấn luyện hai giai đoạn: tiền huấn luyện có giám sát rồi tinh chỉnh bằng phương pháp *actor-critic* (gradient chính sách với phê bình giá trị làm baseline) có neo Kullback-Leibler. Một phát hiện then chốt là *lựa chọn ứng viên* mới là đòn bẩy hiệu quả của học tăng cường, nên ở giai đoạn tinh chỉnh hai đầu xếp hạng được đóng băng và chỉ đầu chọn ứng viên được huấn luyện. Kết quả là một tác nhân vừa kế thừa các quy luật hợp lý của heuristic, vừa có khả năng tự khám phá những phương án ánh xạ tốt hơn mà heuristic không nhìn thấy.

1.4 Đóng góp của đề án

Đề án có ba đóng góp chính sau:

1. Đề xuất kiến trúc *RL-OA-MP-VNE* với bộ mã hoá đồ thị phân cấp đa miền (GCN nội miền + liên miền) kết hợp ba đầu ra phối hợp: đầu xếp hạng nút ảo, đầu xếp hạng liên kết ảo, và đầu chọn ứng viên cross-attention có thiên lệch chi phí tường minh và mặt nạ khả thi cứng cho ràng buộc CPU.
2. Đề xuất quy trình huấn luyện hai giai đoạn gồm tiền huấn luyện có giám sát từ lời giải OA-MP-VNE và tinh chỉnh bằng phương pháp actor-critic (phê bình giá trị làm baseline) có neo Kullback-Leibler, cùng phát hiện rằng lựa chọn ứng viên là đòn bẩy hiệu quả và việc làm cho nó ngẫu nhiên trong huấn luyện là điều kiện cần để vượt trần của mô hình bắt chước.
3. Xây dựng bộ benchmark đa miền ở ba quy mô (50, 100 và 200 nút vật lý, mỗi mạng chia thành 10 miền) và tiến hành đánh giá so sánh có hệ thống với các baseline heuristic (MP-VNE, MP-VNE-V4) và mô hình chỉ học bắt chước (R2).

1.5 Bố cục đề án

Phần còn lại của báo cáo được tổ chức như sau. Chương 2 trình bày nền tảng lý thuyết, bao gồm hình thức hoá bài toán VNE dưới dạng ILP, khảo sát các hướng

tiếp cận hiện có, và các kiến thức về học tăng cường sâu cũng như mạng nơ-ron đồ thị làm cơ sở cho phương pháp đề xuất. Chương 3 trình bày phương pháp đề xuất của đồ án, gồm kiến trúc tổng thể, bộ mã hoá đồ thị, bộ giải mã chọn ứng viên, môi trường học tăng cường và quy trình huấn luyện hai giai đoạn. Chương 4 phân tích lý thuyết về độ phức tạp tính toán, độ phức tạp bộ nhớ và đặc tính hội tụ của thuật toán đề xuất. Chương 5 mô tả thiết lập thực nghiệm, các tập dữ liệu, độ đo so sánh và phân tích kết quả. Chương 6 tổng kết các kết quả đạt được, các hạn chế còn tồn tại và đề xuất các hướng nghiên cứu tiếp theo.

CHƯƠNG 2. NỀN TẢNG LÝ THUYẾT

Chương này hệ thống hoá các kiến thức nền tảng phục vụ cho phương pháp đề xuất ở Chương 3. Phần đầu trình bày mô hình hoá bài toán nhúng mạng ảo và phát biểu dưới dạng quy hoạch nguyên tuyến tính. Tiếp theo là khảo sát các hướng tiếp cận hiện có cùng phân tích ưu nhược. Phần sau trình bày các công cụ học tăng cường sâu và mạng nơ-ron đồ thị, là hai khối nền tảng được sử dụng trong đề án.

2.1 Mô hình hoá bài toán nhúng mạng ảo

2.1.1 Mạng vật lý và mạng ảo

Mạng vật lý (substrate network) được biểu diễn bằng đồ thị vô hướng có trọng số

$$G^s = (N^s, E^s),$$

trong đó N^s là tập các nút vật lý và E^s là tập các liên kết. Mỗi nút $n^s \in N^s$ được đặc trưng bởi dung lượng CPU $C(n^s)$, đơn giá CPU $P(n^s)$ và độ trễ xử lý $D(n^s)$. Mỗi liên kết $e^s = (u^s, v^s) \in E^s$ được đặc trưng bởi băng thông $B(e^s)$, đơn giá băng thông $P(e^s)$ và độ trễ truyền dẫn $D(e^s)$. Tại thời điểm bất kỳ, tài nguyên còn lại của mỗi nút và liên kết là $C^{\text{avail}}(n^s) \leq C(n^s)$ và $B^{\text{avail}}(e^s) \leq B(e^s)$.

Một **yêu cầu mạng ảo** (Virtual Network Request - VNR) bao gồm đồ thị mạng ảo và các thông tin thời gian:

$$\text{VNR} = (G^v, t_a, t_l), \quad G^v = (N^v, E^v),$$

với t_a là thời điểm đến và t_l là thời gian sống. Mỗi nút ảo $n^v \in N^v$ có yêu cầu CPU $c(n^v)$, và mỗi liên kết ảo $e^v = (u^v, v^v) \in E^v$ có yêu cầu băng thông $b(e^v)$. Trong cấu hình đa miền, mỗi nút ảo có thể có thêm tập miền cho phép $\mathcal{D}(n^v) \subseteq \mathcal{D}$.

2.1.2 Hai pha của VNE: ánh xạ nút và ánh xạ liên kết

Một lời giải nhúng cho VNR là một cặp ánh xạ (f_N, f_E) trong đó:

- **Ánh xạ nút** $f_N : N^v \rightarrow N^s$ thoả mãn (i) ràng buộc tài nguyên $c(n^v) \leq C^{\text{avail}}(f_N(n^v))$ với mọi n^v , (ii) ràng buộc đơn ánh: $f_N(u^v) \neq f_N(v^v)$ với $u^v \neq v^v$, và (iii) ràng buộc miền $f_N(n^v) \in \mathcal{D}(n^v)$ nếu có.
- **Ánh xạ liên kết** $f_E : E^v \rightarrow \mathcal{P}(E^s)$ ánh xạ mỗi liên kết ảo tới một tập đường đi vật lý nối $f_N(u^v)$ và $f_N(v^v)$, với tổng băng thông trên các đường đi bằng $b(e^v)$ và không vượt quá băng thông còn lại của bất kỳ liên kết vật lý nào.

Do tính chất NP-Hard của bài toán, các phương pháp thực tế thường giải hai

pha một cách phối hợp nhưng không đồng thời tối ưu: pha ánh xạ nút sử dụng một chính sách xếp hạng/lựa chọn, sau đó pha ánh xạ liên kết dùng đường đi ngắn nhất hoặc multi-path để hoàn thiện. Đề án này đi theo hướng đó, với cải tiến là sử dụng học tăng cường để học chính sách xếp hạng và chọn ứng viên thay cho heuristic cứng.

2.1.3 Hàm mục tiêu và độ đo hiệu năng

Đối với mỗi VNR được nhúng thành công, **doanh thu** (revenue) và **chi phí** (cost) được định nghĩa:

$$\mathcal{R}(\text{VNR}) = \sum_{n^v \in N^v} c(n^v) + \sum_{e^v \in E^v} b(e^v), \quad (2.1)$$

$$\mathcal{C}(\text{VNR}) = \sum_{n^v \in N^v} c(n^v) + \sum_{e^v \in E^v} b(e^v) \cdot \ell(f_E(e^v)), \quad (2.2)$$

trong đó $\ell(\cdot)$ là tổng số chặng vật lý của tập đường đi ánh xạ liên kết ảo. Hai độ đo hiệu năng phổ biến nhất là:

- **Tỉ lệ chấp nhận** (Acceptance Ratio - AR): tỉ số giữa số VNR được nhúng thành công và tổng số VNR đến trong khoảng thời gian khảo sát.
- **Tỉ số doanh thu trên chi phí** (Revenue-to-Cost - R/C): được định nghĩa cho mỗi VNR là $\mathcal{R}(\text{VNR})/\mathcal{C}(\text{VNR})$, đo mức độ “tiết kiệm tài nguyên” khi nhúng. Ở mức hệ thống, R/C tổng được tính bằng tỉ số của tổng doanh thu và tổng chi phí trên toàn bộ VNR đã nhúng.

Ngoài AR và R/C, các độ đo bổ sung gồm thời gian chạy trung bình mỗi VNR, độ trễ trung bình của các đường đi, và độ ổn định của reward trong quá trình huấn luyện. Đề án này sử dụng đồng thời cả bốn độ đo để so sánh.

2.1.4 Phát biểu bài toán dưới dạng ILP

Để có hình thức hoá đầy đủ, đặt biến nhị phân $x_{n^v, n^s} \in \{0, 1\}$ bằng 1 nếu nút ảo n^v được ánh xạ tới nút vật lý n^s , và biến $y_{u^s v^s}^{u^v v^v} \in [0, 1]$ biểu diễn tỉ lệ băng thông của liên kết ảo (u^v, v^v) đi qua liên kết vật lý (u^s, v^s) . Với mục tiêu cực đại hoá tỉ số R/C, bài toán có thể viết:

$$\max \quad \frac{\mathcal{R}(\text{VNR})}{\mathcal{C}(\text{VNR})} \quad (2.3)$$

với các ràng buộc:

$$\sum_{n^s \in N^s} x_{n^v, n^s} = 1, \quad \forall n^v \in N^v, \quad (2.4)$$

$$\sum_{n^v \in N^v} x_{n^v, n^s} \cdot c(n^v) \leq C^{\text{avail}}(n^s), \quad \forall n^s \in N^s, \quad (2.5)$$

$$\sum_{n^v \in N^v} x_{n^v, n^s} \leq 1, \quad \forall n^s \in N^s, \quad (2.6)$$

$$\sum_{(u^s, v^s) \in E^s} y_{u^s v^s}^{u^v v^v} \cdot b(u^v, v^v) \leq B^{\text{avail}}(u^s, v^s), \quad \forall (u^s, v^s), \quad (2.7)$$

$$\sum_{v^s: (u^s, v^s) \in E^s} (y_{u^s v^s}^{u^v v^v} - y_{v^s u^s}^{u^v v^v}) = x_{u^v, u^s} - x_{v^v, u^s}, \quad \forall u^s, (u^v, v^v). \quad (2.8)$$

Ràng buộc (2.4) đảm bảo mỗi nút ảo được ánh xạ tới đúng một nút vật lý; (2.5) đảm bảo không vượt CPU; (2.6) đảm bảo tính đơn ánh; (2.7) đảm bảo không vượt băng thông; và (2.8) là ràng buộc bảo toàn luồng (multi-commodity flow) cho ánh xạ liên kết. Như đã phân tích ở Mục 1.1 của Chương 3, dạng ILP này có $|N^v| \cdot |N^s|$ biến nhị phân nút và $|E^v| \cdot |E^s|$ biến liên kết, làm cho việc giải tối ưu trở nên không khả thi với mạng vật lý cỡ trăm nút trở lên.

2.2 Các hướng tiếp cận hiện tại

2.2.1 Hướng heuristic

Các thuật toán heuristic sử dụng các luật xếp hạng đơn giản dựa trên đặc trưng tô-pô như bậc của nút, NodeRank[6], hoặc chỉ số kết hợp giữa tài nguyên còn lại và tổng băng thông của các cạnh kề. ViNE[5] giải LP-relaxation của bài toán nhị phân để gợi ý ánh xạ nút, rồi làm tròn. MP-VNE[7] ước lượng chi phí của từng cặp (n^v, n^s) qua công thức tổng hợp giữa CPU-cost và băng thông trung bình của các láng giềng, rồi chọn các nút có chi phí ước lượng thấp nhất làm ứng viên. Pha ánh xạ liên kết phổ biến nhất là đường đi ngắn nhất theo Dijkstra hoặc Floyd, có thể mở rộng thành *multi-path* cho phép chia một liên kết ảo thành nhiều đường đi vật lý.

Ưu điểm của heuristic là đơn giản, có thể chạy trên hạ tầng lớn, và thường cho kết quả chấp nhận được trong các tình huống điển hình. Nhược điểm là phụ thuộc nặng vào tri thức chuyên gia, không thích nghi với phân phối yêu cầu thay đổi, và dễ rơi vào tối ưu cục bộ.

2.2.2 Hướng metaheuristic

Các phương pháp metaheuristic gồm thuật toán di truyền (Genetic Algorithm), tối ưu hoá bầy hạt (Particle Swarm Optimization - PSO), và mô phỏng tôi luyện (Simulated Annealing). Trong bài toán VNE, mỗi cá thể/cá nhân biểu diễn một

phương án ánh xạ nút hoàn chỉnh, hàm thích nghi (fitness) là chi phí nhúng. Cá thể tốt được chọn lọc qua các thế hệ, kết hợp với phép đột biến để thoát khỏi tối ưu cục bộ. MP-VNE[7] sử dụng PSO với 10 hạt, 50 vòng lặp, và xác suất đột biến 10% để cân bằng giữa khám phá và khai thác. Hạn chế chung của nhóm metaheuristic là chi phí tính toán cao (phải đánh giá nhiều phương án trong mỗi vòng lặp) và không có đảm bảo lý thuyết về chất lượng lời giải.

2.2.3 Hướng học tăng cường

Học tăng cường (Reinforcement Learning - RL) coi VNE như một quá trình quyết định tuần tự: tại mỗi bước, tác nhân quan sát trạng thái mạng vật lý và VNR hiện tại, chọn một hành động (ánh xạ một nút ảo) rồi nhận tín hiệu thưởng phản ánh chất lượng của lời giải cuối cùng. A3C-GCN[8] là một trong những công trình tiên phong sử dụng mạng nơ-ron đồ thị để mã hoá tô-pô mạng vật lý, kết hợp với thuật toán Actor-Critic bất đồng bộ. Gần đây, FlagVNE[9] đề xuất khung làm việc tổng quát cho RL trong cấp phát tài nguyên mạng, tách bạch giữa môi trường, biểu diễn, và thuật toán huấn luyện, đồng thời chỉ ra hiệu năng vượt trội so với heuristic và phương pháp metaheuristic trên nhiều bộ benchmark.

2.2.4 So sánh và động lực của đề án

Bảng 2.1 tổng hợp ưu nhược của ba nhóm tiếp cận.

Bảng 2.1: So sánh ba hướng tiếp cận VNE

Tiêu chí	Heuristic	Metaheuristic	Học tăng cường
Chất lượng lời giải	Trung bình	Khá	Tốt (khi huấn luyện ổn định)
Thời gian suy diễn	Rất nhanh	Chậm	Nhanh
Khả năng tổng quát hoá	Thấp	Trung bình	Cao
Phụ thuộc tri thức chuyên gia	Cao	Trung bình	Thấp
Chi phí huấn luyện	Không có	Không có	Cao

Phân tích trên cho thấy hướng học tăng cường có tiềm năng lớn nhất nhưng còn hai trở ngại: (i) cần huấn luyện trên lượng mẫu lớn để hội tụ, và (ii) khó kết hợp tri thức tô-pô. Đề án đề xuất kết hợp ưu điểm của heuristic (nguồn tri thức tô-pô) và RL (khả năng học và tổng quát hoá) thông qua quy trình huấn luyện hai giai đoạn được trình bày ở Chương 3.

2.3 Học tăng cường sâu

2.3.1 Quá trình quyết định Markov

Học tăng cường được hình thức hoá qua *Quá trình quyết định Markov* (Markov Decision Process - MDP), một bộ năm

$$\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma),$$

trong đó $\mathcal{S}$ là không gian trạng thái, $\mathcal{A}$ là không gian hành động, $\mathcal{P}(s' | s, a)$ là xác suất chuyển trạng thái, $\mathcal{R}(s, a)$ là hàm phần thưởng, và $\gamma \in [0, 1]$ là hệ số chiết khấu. Một *chính sách* $\pi(a | s)$ là phân phối xác suất trên hành động cho mỗi trạng thái. Mục tiêu của RL là tìm chính sách π^* tối đa hoá kỳ vọng lợi ích tích lũy [10]:

$$J(\pi) = \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^T \gamma^t \mathcal{R}(s_t, a_t) \right], \quad (2.9)$$

trong đó $\tau = (s_0, a_0, s_1, a_1, \dots)$ là quỹ đạo tương tác.

Trong bối cảnh VNE, một episode tương ứng với quá trình nhúng một VNR. Trạng thái mô tả mạng vật lý hiện tại và VNR đang xét, hành động là ánh xạ một nút ảo tới một nút vật lý hoặc xếp hạng các nút/liên kết ảo, và phần thưởng được cấp khi VNR đã được ánh xạ hoàn chỉnh và đo bằng tỉ số R/C.

2.3.2 Policy gradient và Actor-Critic

Policy gradient là họ thuật toán RL học chính sách trực tiếp bằng cách tham số hoá $\pi_\theta(a | s)$ với tham số θ và cập nhật theo gradient của $J(\theta)$. Định lý policy gradient [10] chỉ ra:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t \right], \quad (2.10)$$

với $G_t = \sum_{k=t}^T \gamma^{k-t} \mathcal{R}(s_k, a_k)$. REINFORCE [11] là phiên bản đơn giản nhất, ước lượng kỳ vọng bằng trung bình mẫu Monte Carlo. Hạn chế chính của REINFORCE là phương sai gradient cao. Để giảm phương sai mà không gây bias, có thể trừ một *baseline* $b(s)$ độc lập với hành động:

$$\nabla_\theta J(\theta) = \mathbb{E} \left[\sum_t \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot (G_t - b(s_t)) \right]. \quad (2.11)$$

Phương án phổ biến nhất là dùng hàm giá trị $V_\phi(s)$ làm baseline, dẫn đến kiến trúc *Actor-Critic* với hai mạng song song: *actor* là chính sách $\pi_\theta(a | s)$ quyết định hành động, còn *critic* là hàm giá trị $V_\phi(s)$ ước lượng chất lượng trạng thái và được học bằng cách hồi quy về lợi ích thực tế (mất mát bình phương). Lợi thế $A(s, a) = G_t - V_\phi(s)$ thay cho G_t giúp giảm phương sai gradient. Đồ án này sử dụng baseline phê bình $V_\phi(s)$ học được (kiến trúc actor-critic) thay cho baseline trung bình đơn giản, nhằm giảm phương sai mạnh hơn trong các kịch bản phần thưởng cấp ở cuối episode.

2.3.3 Tối ưu hoá chính sách gần kề (PPO)

Proximal Policy Optimization (PPO)[12] là một thuật toán actor-critic cải tiến, cho phép tái sử dụng dữ liệu rollout qua nhiều vòng gradient mà vẫn ổn định. PPO thay mục tiêu gradient chính sách bằng một *hàm mục tiêu thay thế có cắt* (clipped surrogate) dựa trên tỉ số tầm quan trọng $\rho_t(\theta) = \pi_\theta(a_t | s_t) / \pi_{\theta_{\text{old}}}(a_t | s_t)$:

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right], \quad (2.12)$$

với ϵ là biên cắt (thường 0,2). Phép cắt ngăn chính sách trôi quá xa khỏi chính sách cũ trong một bước cập nhật, đóng vai trò một ràng buộc vùng tin cậy mềm. Đồ án sử dụng kiến trúc actor-critic làm phương pháp tính chỉnh chính, đồng thời cài đặt biến thể PPO có cắt để so sánh (Chương 5).

2.3.4 Plackett-Luce sampling

Trong bài toán VNE, tác nhân cần sinh ra một *hoán vị* (thứ tự xử lý nút/liên kết ảo) thay vì chỉ một hành động đơn lẻ. *Mô hình Plackett-Luce*[13] biểu diễn phân phối xác suất trên hoán vị thông qua điểm số $s_1, \dots, s_n$:

$$P(\pi | \mathbf{s}) = \prod_{k=1}^n \frac{\exp(s_{\pi(k)})}{\sum_{j \in \mathcal{R}_k} \exp(s_j)}, \quad (2.13)$$

với $\mathcal{R}_k$ là tập các phần tử chưa được chọn ở các bước trước. Sampling thực hiện bằng cách softmax-sample phần tử đầu tiên, loại khỏi tập, rồi lặp lại. Log-likelihood của hoán vị có thể tính được trực tiếp, cho phép kết hợp với REINFORCE để cập nhật gradient.

2.4 Mạng nơ-ron đồ thị

2.4.1 Cơ chế truyền tin

Mạng nơ-ron đồ thị (Graph Neural Network - GNN) học biểu diễn của các nút bằng cơ chế *truyền tin* (message passing). Tại mỗi lớp ℓ , vector biểu diễn $h_v^{(\ell)}$ của mỗi nút v được cập nhật từ biểu diễn của các láng giềng:

$$h_v^{(\ell+1)} = \text{UPDATE}^{(\ell)} \left(h_v^{(\ell)}, \text{AGGREGATE}^{(\ell)} \left(\{h_u^{(\ell)} : u \in \mathcal{N}(v)\} \right) \right). \quad (2.14)$$

Sau L lớp truyền tin, mỗi nút “thấy” được thông tin từ các láng giềng trong bán kính L chằng. Các biến thể GNN khác nhau chủ yếu ở hai hàm AGGREGATE và UPDATE.

2.4.2 Graph Convolutional Network

Graph Convolutional Network (GCN)[14] sử dụng phép trung bình có trọng số trên láng giềng:

$$H^{(\ell+1)} = \sigma \left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(\ell)} W^{(\ell)} \right), \quad (2.15)$$

trong đó $\tilde{A} = A + I$ là ma trận kề có self-loop, $\tilde{D}$ là ma trận đường chéo độ bậc, $H^{(\ell)} \in \mathbb{R}^{|V| \times d_\ell}$ là ma trận biểu diễn, $W^{(\ell)}$ là tham số học được, và σ là hàm kích hoạt phi tuyến (đề án dùng ReLU). Đề án sử dụng GCN hai lớp với $H^{(0)} = X$ là ma trận đặc trưng đầu vào của các nút vật lý. Ma trận kề A được trọng số hoá theo tỉ lệ bằng thông còn lại trên dung lượng ban đầu, cho phép mã hoá thông tin trạng thái tài nguyên động vào quá trình truyền tin.

2.4.3 Graph Attention Network

Graph Attention Network (GAT)[15] thay phép trung bình đồng đều bằng phép tổ hợp có trọng số attention học được:

$$h_v^{(\ell+1)} = \sigma \left(\sum_{u \in \mathcal{N}(v) \cup \{v\}} \alpha_{vu}^{(\ell)} \cdot W^{(\ell)} h_u^{(\ell)} \right), \quad (2.16)$$

với hệ số attention

$$\alpha_{vu}^{(\ell)} = \frac{\exp \left(\text{LeakyReLU}(\mathbf{a}^\top [W h_v \| W h_u]) \right)}{\sum_{u' \in \mathcal{N}(v) \cup \{v\}} \exp \left(\text{LeakyReLU}(\mathbf{a}^\top [W h_v \| W h_{u'}]) \right)}. \quad (2.17)$$

GAT có khả năng biểu diễn cao hơn GCN nhờ trọng số học được, đặc biệt khi đồ thị không đồng nhất về vai trò các láng giềng. Tuy nhiên, GCN có ưu điểm về số tham số ít, tốc độ huấn luyện nhanh, và đủ biểu diễn cho các tô-pô mạng vật lý nhỏ - vừa trong VNE. Đề án này lựa chọn GCN làm bộ mã hoá chính để giữ kiến trúc nhỏ gọn (toàn bộ chính sách chỉ khoảng 20,000 tham số), đồng thời thảo luận lại các đánh đổi với GAT trong phân tích ablation ở Chương 5.

2.5 Cơ chế attention cho lựa chọn ứng viên

Cơ chế *scaled dot-product attention*[16] là khối toán học chuẩn cho việc “một truy vấn chọn từ nhiều khoá”. Cho truy vấn $q \in \mathbb{R}^d$ và tập khoá $K = (k_1, \dots, k_n)$, điểm số cho mỗi khoá là

$$\text{score}(q, k_i) = \frac{q^\top k_i}{\sqrt{d}}. \quad (2.18)$$

Hệ số $\sqrt{d}$ giúp ổn định gradient khi d lớn. Trong bài toán VNE, mỗi nút ảo đóng vai trò truy vấn, mỗi nút vật lý ứng viên đóng vai trò khoá, và điểm số sau khi softmax biểu diễn xác suất chọn từng ứng viên. Đề án mở rộng cơ chế này bằng

cách kết hợp một nhánh MLP dư (residual) để học các tương tác phi tuyến phức tạp giữa đặc trưng của nút ảo và nút vật lý, và sử dụng *feasibility mask* cứng để loại bỏ các ứng viên không thoả mãn ràng buộc CPU ngay tại bước tính điểm. Chi tiết kiến trúc được trình bày ở Chương 3.

Chương này đã hệ thống hoá các khái niệm và mô hình cần thiết cho phương pháp đề xuất, bao gồm mô hình hoá VNE và phát biểu ILP, khảo sát ba hướng tiếp cận hiện hành, nền tảng học tăng cường (MDP, gradient chính sách, actor-critic, PPO, Plackett-Luce), và các khối GNN và attention. Chương tiếp theo sử dụng các nền tảng này để thiết kế kiến trúc và thuật toán huấn luyện của RL-OA-MP-VNE.

CHƯƠNG 3. PHƯƠNG PHÁP ĐỀ XUẤT

Chương này trình bày chi tiết phương pháp đề xuất *RL-OA-MP-VNE*. Trong đó, hậu tố *OA-MP* kế thừa cơ chế ánh xạ liên kết đa đường có nhận biết thứ tự (Order-Aware Multi-Path) của thuật toán OA-MP-VNE, còn tiền tố *RL* biểu thị việc tinh chỉnh bộ chọn ứng viên bằng học tăng cường trên nền một mô hình đã được khởi động bằng học bắt chước (imitation learning). Phần đầu chương mô tả kiến trúc tổng thể và ba nguyên lý thiết kế cốt lõi. Các phần tiếp theo lần lượt trình bày bộ mã hoá đồ thị, bộ giải mã chọn ứng viên, môi trường học tăng cường, và quy trình huấn luyện hai giai đoạn.

3.1 Tổng quan giải pháp

3.1.1 Ba nguyên lý thiết kế


Phương pháp đề xuất được xây dựng quanh ba nguyên lý thiết kế nhằm khắc phục trực tiếp ba hạn chế của các phương pháp học tăng cường cho VNE đã nêu ở Chương 1.

1. **Mã hoá tô-pô phân cấp đa miền.** Hạ tầng thực tế thường được chia thành nhiều miền quản trị (domain). Thay vì coi mạng vật lý là một đồ thị phẳng, đồ án sử dụng một bộ mã hoá *phân cấp* gồm hai mức: mức nội miền (intra-domain) học biểu diễn cục bộ cho từng miền, và mức liên miền (inter-domain) học biểu diễn quan hệ giữa các miền. Cách làm này tôn trọng tính cục bộ của bài toán đa miền và cho phép tác nhân “nhìn thấy” chi phí định tuyến xuyên miền ngay tại bước ra quyết định.
2. **Đóng băng các đầu xếp hạng, chỉ tinh chỉnh đầu chọn ứng viên.** Một phát hiện then chốt của đồ án là: trong bài toán này, *lựa chọn ứng viên* (chọn nút vật lý nào cho mỗi nút ảo) mới là đòn bẩy thực sự để vượt trần hiệu năng của heuristic, còn *thứ tự xử lý* nút/liên kết ảo gần như không cải thiện được bằng học tăng cường. Do đó, sau khi khởi động bằng học bắt chước, ta **đóng băng** đầu xếp hạng nút và đầu xếp hạng liên kết, chỉ huấn luyện tăng cường cho đầu chọn ứng viên (cùng bộ mã hoá và bộ phê bình). Việc này tránh cho gradient ngẫu nhiên từ các đầu xếp hạng làm hỏng bộ mã hoá dùng chung.
3. **Khởi động bằng học bắt chước rồi tinh chỉnh actor-critic có neo KL.** Quy trình huấn luyện gồm hai giai đoạn: (i) học bắt chước lời giải của thuật toán OA-MP-VNE để có một chính sách khởi đầu hợp lý (gọi là mô hình *R2*); (ii) tinh chỉnh bằng phương pháp actor-critic, trong đó tín hiệu thưởng đến từ kết quả nhúng thực tế, đồng thời neo phân phối chọn ứng viên về chính sách tham

chiều R2 bằng độ phân kỳ Kullback-Leibler (KL) để tinh chỉnh mà không sụp đổ phân phối.

3.1.2 Sơ đồ khối hệ thống

Hình 3.1 mô tả kiến trúc tổng thể. Hệ thống gồm bốn nhóm khối: (1) *bộ mã hoá đồ thị* biến mạng vật lý và yêu cầu mạng ảo thành các vector biểu diễn; (2) *bốn đầu ra* gồm đầu xếp hạng nút ảo, đầu xếp hạng liên kết ảo, đầu chọn ứng viên (cross-attention) và bộ phê bình giá trị $V(s)$; (3) *bộ giải mã* kết hợp các đầu ra để sinh một lời giải nhúng hoàn chỉnh; và (4) *môi trường* cam kết tài nguyên và trả về tín hiệu thưởng. Ở giai đoạn tinh chỉnh, các khối tô đậm (đầu chọn ứng viên, bộ mã hoá, bộ phê bình) được cập nhật, còn hai đầu xếp hạng (tô nhạt) bị đóng băng.



Hình 3.1: Kiến trúc tổng thể của RL-OA-MP-VNE. Khối tô đậm được huấn luyện ở giai đoạn tinh chỉnh; khối nét đứt (hai đầu xếp hạng) bị đóng băng.

3.1.3 Luồng tương tác môi trường - tác nhân

Mỗi *episode* tương ứng với quá trình nhúng một VNR và diễn ra theo các bước sau. (1) Bộ mã hoá tính biểu diễn cho mạng vật lý hiện tại và VNR đang xét. (2) Đầu xếp hạng nút sinh một thứ tự xử lý các nút ảo bằng lấy mẫu Plackett-Luce. (3) Với mỗi nút ảo theo thứ tự đó, đầu chọn ứng viên tính điểm cho các nút vật lý khả thi trong từng miền cho phép và chọn ra một nút (lấy mẫu khi huấn luyện, lấy cực đại khi suy diễn). (4) Sau khi đã có ánh xạ nút, các liên kết ảo được ánh xạ tuần tự bằng đường đi ngắn nhất. (5) Lời giải hoàn chỉnh được cam kết lên mạng vật lý theo cơ chế đa đường OA-MP, trạng thái tài nguyên được cập nhật, và môi trường trả về một tín hiệu thưởng phản ánh việc nhúng thành công hay thất bại cùng độ tiết kiệm chi phí. Phân tích độ phức tạp của luồng này được trình bày ở Chương 4, còn kết quả thực nghiệm ở Chương 5.

3.2 Bộ mã hoá đồ thị (Graph Encoder)

3.2.1 Mã hoá mạng vật lý phân cấp

Bộ mã hoá mạng vật lý hoạt động ở hai mức để phản ánh cấu trúc đa miền.

Mức nội miền. Trong mỗi miền d , một mạng tích chập đồ thị (GCN) ba lớp với chiều ẩn 32 được áp dụng lên đồ thị con của miền đó. Mỗi nút vật lý được mô tả bằng vector đặc trưng 7 chiều gồm: dung lượng CPU còn lại, đơn giá CPU, độ trễ xử lý, bậc của nút, băng thông trung bình của các liên kết kề, đơn giá băng thông trung bình của các liên kết kề, và một cờ nhị phân cho biết nút có phải nút biên (có liên kết liên miền) hay không. Tất cả đặc trưng đều được chuẩn hoá để ổn định huấn luyện. Lớp GCN tuân theo công thức truyền tin chuẩn hoá đối xứng kèm kết nối tắt (residual) và chuẩn hoá lớp (LayerNorm):

$$H^{(\ell+1)} = \text{LayerNorm}\left(H^{(\ell)} + \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(\ell)} W^{(\ell)}\right)\right), \quad (3.1)$$

trong đó $\tilde{A} = A + I$, $\tilde{D}$ là ma trận bậc tương ứng, σ là hàm ReLU. Khác với GCN cơ bản, ma trận kề A ở đây được **trọng số hoá theo băng thông còn lại** của các liên kết, nhờ đó trạng thái tài nguyên động được mã hoá trực tiếp vào quá trình truyền tin.

Mức liên miền. Sau khi có biểu diễn nội miền, mỗi miền được tóm tắt thành một vector duy nhất bằng phép max-pooling trên các nút của miền. Tập các vector tóm tắt tạo thành một “siêu đồ thị” gồm D nút (mỗi miền là một nút). Một GCN hai lớp (chiều ẩn 32) được áp dụng trên siêu đồ thị này, với ma trận kề liên miền được xây từ tổng băng thông còn lại của các liên kết liên miền giữa từng cặp miền (thêm self-loop, chuẩn hoá $\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2}$). Kết quả là mỗi nút vật lý nhận được hai loại ngữ cảnh: ngữ cảnh nội miền (cục bộ) và ngữ cảnh liên miền (toàn cục), nối lại thành biểu diễn 64 chiều.

3.2.2 Mã hoá yêu cầu mạng ảo

Yêu cầu mạng ảo được mã hoá bằng một GCN hai lớp (chiều ẩn 32) trên đồ thị ảo, với mỗi nút ảo mô tả bằng 7 đặc trưng gồm: nhu cầu CPU, bậc, tổng băng thông các liên kết kề, kích thước VN chuẩn hoá, mật độ liên kết của VN, tỉ lệ số miền được phép, và tỉ lệ liên kết ảo buộc phải định tuyến xuyên miền. Vì thứ tự và sự phối hợp giữa các nút ảo là quan trọng, ta bổ sung một khối *self-attention đa đầu* (4 đầu) trên tập biểu diễn các nút ảo (khối Transformer: attention + mạng truyền thẳng + LayerNorm). Bộ mã hoá VNR dùng **bộ trọng số riêng**, tách biệt với bộ mã hoá mạng vật lý.

3.2.3 Trộn biểu diễn substrate và VNR

Với mỗi nút ảo, ngữ cảnh mạng vật lý được tổng hợp bằng phép max-pooling trên các biểu diễn nút vật lý (chiều 64) rồi nối với biểu diễn của nút ảo (chiều 32). Vector kết hợp 96 chiều này là đầu vào chung cho đầu xếp hạng nút và bộ phê bình

giá trị, đảm bảo mọi đầu ra đều “nhìn” cùng một biểu diễn nhất quán của trạng thái.

3.2.4 Phân tích thiết kế

Đồ án chọn GCN thay vì GAT cho bộ mã hoá chính nhằm giữ kiến trúc nhỏ gọn: toàn bộ mạng chính sách chỉ khoảng 55,700 tham số, phù hợp huấn luyện nhanh trên tô-pô cỡ vừa và giảm rủi ro quá khớp. Cấu trúc phân cấp là lựa chọn cốt lõi cho bài toán đa miền: nó tránh việc cho mỗi nút “nhìn thấy” toàn bộ hàng trăm nút ở các miền khác (vừa tốn kém vừa nhiễu), đồng thời vẫn truyền được thông tin liên miền qua mức thứ hai. Các biến thể dùng GAT và bộ mã hoá lớn hơn được khảo sát trong phân tích ablation ở Chương 5.

3.3 Bộ giải mã chọn ứng viên (Candidate Decoder)

Đây là thành phần trung tâm của phương pháp và là nơi học tăng cường phát huy tác dụng.

3.3.1 Sinh tập ứng viên cho mỗi nút ảo

Với mỗi nút ảo n^v và mỗi miền d thuộc tập miền cho phép $\mathcal{D}(n^v)$, ta lọc ra các nút vật lý trong miền d thoả mãn ràng buộc CPU cứng ($C^{\text{avail}}(n^s) \geq c(n^v)$), rồi giữ lại K ứng viên hàng đầu theo điểm của đầu chọn ứng viên. Theo cách diễn giải chặt của thuật toán gốc, đồ án dùng $K = 1$ cho mỗi miền: mỗi nút ảo chỉ giữ *một* ứng viên tốt nhất trên *mỗi* miền được phép. Cơ chế lọc theo miền này vừa thu hẹp mạnh không gian hành động, vừa đảm bảo lời giải tôn trọng ràng buộc miền.

3.3.2 Cơ chế attention chọn ứng viên

Điểm số cho mỗi cặp (nút ảo n^v , nút vật lý ứng viên n^s) được tính bằng cơ chế cross-attention kết hợp với một *thiên lệch chi phí tường minh*. Truy vấn là biểu diễn nút ảo, khoá là biểu diễn ngữ cảnh của nút vật lý nối với bốn đặc trưng phụ trợ: độ dư CPU chuẩn hoá, chi phí CPU ước lượng $\text{cpu_cost} = c(n^v) \cdot P(n^s)$, cờ nút biên, và chi phí liên kết ước lượng. Điểm cuối cùng là tổng của ba thành phần:

$$\begin{aligned} \text{score}(n^v, n^s) = & \underbrace{\frac{q^\top k}{\sqrt{d_h}}}_{\text{attention}} + \underbrace{\text{MLP}_{\text{res}}([h_{n^v} \parallel h_{n^s}])}_{\text{tương tác phi tuyến}} \\ & - \beta_c \text{cpu_cost} - \beta_\ell \text{link_cost} + \beta_b \text{is_boundary}, \end{aligned} \quad (3.2)$$

trong đó $\beta_c, \beta_\ell, \beta_b$ là các trọng số thiên lệch *học được*. Việc đưa các đặc trưng chi phí vào tường minh giúp đầu chọn ứng viên khởi đầu gần với quy luật xếp hạng theo chi phí ước lượng (PreCost) của heuristic, rồi học các sai lệch có lợi từ đó. Các nút không khả thi về CPU bị gán điểm -10^4 (mặt nạ khả thi cứng) để bị loại hoàn

toàn sau softmax.

3.3.3 Lựa chọn ngẫu nhiên khi huấn luyện và tắt định khi suy diễn

Đây chính là cơ chế cho phép học tăng cường hoạt động. Khi **huấn luyện**, với mỗi nút ảo và mỗi miền, một nút vật lý được *lấy mẫu* từ phân phối Categorical trên các điểm $\text{score}(\cdot)$ của miền đó (với $K > 1$ dùng Gumbel-top-K không hoàn lại). Tính ngẫu nhiên này tạo ra *khám phá*: tác nhân thử các phương án chọn ứng viên khác nhau và nhận phản hồi từ kết quả nhúng. Khi **suy diễn**, ta lấy cực đại (argmax) theo từng miền để có quyết định tắt định.

Phát hiện then chốt là: nếu chỉ dùng đường đi argmax chặt ($K = 1$, không lấy mẫu) ngay từ khi huấn luyện thì *không có khám phá*, do đó không có tín hiệu để học tăng cường cải thiện. Chính việc làm cho lựa chọn ứng viên trở nên ngẫu nhiên trong lúc huấn luyện mới mở ra khả năng vượt trần hiệu năng của mô hình bất chước.

3.3.4 Ánh xạ liên kết

Sau khi cố định ánh xạ nút, các liên kết ảo được xử lý theo một thứ tự lấy mẫu Plackett-Luce (thực nghiệm cho thấy thứ tự ngẫu nhiên hoá này cho tỉ lệ chấp nhận tốt hơn các thứ tự cố định như giảm dần theo băng thông, vì nó tránh dồn lưu lượng vào cùng các đường đi ngắn nhất). Trong pha giải mã và kiểm tra khả thi, mỗi liên kết ảo được ánh xạ vào *một* đường đi ngắn nhất liên tục mang toàn bộ băng thông yêu cầu; nếu không có đường đi đơn nào đủ băng thông, việc nhúng coi như thất bại. Tuy nhiên khi *cam kết* tài nguyên cho một lời giải đã được chấp nhận, hệ thống dùng cơ chế đa đường OA-MP: chia nhỏ băng thông của một liên kết ảo trên tối đa năm đường đi vật lý, tăng khả năng thoả mãn các yêu cầu băng thông lớn. Một mặt nạ chống trùng đảm bảo không có hai nút ảo nào ánh xạ vào cùng một nút vật lý.

3.3.5 Tính toán xác suất hành động hợp thành

Log-xác suất của một lời giải nhúng hoàn chỉnh là tổng của ba thành phần: log-xác suất của thứ tự nút (Plackett-Luce), của thứ tự liên kết (Plackett-Luce), và của các lựa chọn ứng viên (tổng theo từng nút ảo):

$$\log \pi_{\theta}(a \mid s) = \underbrace{\sum_k \log p_k^{\text{node}}}_{\text{thứ tự nút}} + \underbrace{\sum_k \log p_k^{\text{link}}}_{\text{thứ tự liên kết}} + \underbrace{\sum_{n^v} \log p_{n^v}^{\text{cand}}}_{\text{chọn ứng viên}}. \quad (3.3)$$

Ở giai đoạn tinh chỉnh, chỉ thành phần chọn ứng viên mang gradient (hai thành phần còn lại bị đóng băng), nhờ đó tín hiệu học được tập trung hoàn toàn vào đòn bẩy hiệu quả nhất.

3.4 Môi trường học tăng cường

3.4.1 Không gian trạng thái

Trạng thái s gồm: (i) trạng thái tài nguyên hiện tại của mạng vật lý (CPU còn lại của mỗi nút, băng thông còn lại của mỗi liên kết) — biến đổi dần khi các nút/liên kết ảo được cam kết; (ii) cấu trúc và nhu cầu của VNR đang xử lý; và (iii) thông tin tương thích miền giữa nút ảo và nút vật lý. Trạng thái được biểu diễn thông qua các vector mã hoá phân cấp ở Mục 3.2. Các cam kết là *on-policy* và bền vững trong suốt episode.

3.4.2 Không gian hành động

Một hành động hợp thành gồm: một hoán vị thứ tự xử lý các nút ảo, một hoán vị thứ tự xử lý các liên kết ảo, và với mỗi nút ảo một lựa chọn nút vật lý trên mỗi miền cho phép. Ở giai đoạn tinh chỉnh, hai thành phần hoán vị bị đóng băng nên không gian hành động hiệu dụng thu về các lựa chọn ứng viên.

3.4.3 Hàm phần thưởng

Phần thưởng được cấp ở cuối mỗi episode theo dạng tổng quát: nhúng thất bại nhận một phần thưởng âm cố định; nhúng thành công nhận một phần thưởng dương cộng với một số hạng phản ánh độ tiết kiệm chi phí so với mức trung bình động:

$$r = \begin{cases} \rho_{\text{bonus}} + \lambda \cdot \frac{\bar{c}_{\text{EMA}} - c}{\bar{c}_{\text{EMA}}}, & \text{nếu nhúng thành công,} \\ -\rho_{\text{fail}}, & \text{nếu nhúng thất bại,} \end{cases} \quad (3.4)$$

trong đó c là chi phí thực tế của lời giải, $\bar{c}_{\text{EMA}}$ là trung bình động (hệ số suy giảm 0.95) của chi phí các lần nhúng thành công gần đây, λ điều tiết mức độ ưu tiên tiết kiệm chi phí. **Cấu hình thưởng chuẩn** (normal-reward) được dùng cho các kết quả chính của đồ án đặt $\rho_{\text{bonus}} = 1,0$, $\lambda = 0,3$ và $\rho_{\text{fail}} = 1,0$; tức nhúng thành công nhận $r = 1,0 + 0,3 \cdot (\bar{c}_{\text{EMA}} - c)/\bar{c}_{\text{EMA}}$ và nhúng thất bại nhận $r = -1,0$. Cách đặt này ưu tiên trước hết việc *tăng tỉ lệ chấp nhận* (số hạng cố định $\pm 1,0$ chiếm ưu thế), đồng thời vẫn thưởng nhẹ cho các lời giải rẻ hơn trung bình. Bên cạnh cấu hình chuẩn, đồ án còn khảo sát một biến thể *rev_cost* chuẩn hoá theo tỉ số doanh thu/chi phí (bất biến với kích thước, có cắt ngưỡng) nhằm nhấn mạnh hiệu quả tài nguyên; so sánh giữa các cấu hình thưởng được trình bày ở Chương 5.

3.4.4 Cơ chế xử lý hành động không hợp lệ

Ba loại mặt nạ được áp dụng: (i) mặt nạ khả thi CPU — nút vật lý không đủ CPU bị gán điểm -10^4 ; (ii) mặt nạ chống trùng — nút vật lý đã được dùng bị gán điểm $-\infty$ trong giải mã trực tiếp; (iii) bỏ qua miền rỗng — nếu mọi nút trong một

miền đều không khả thi thì miền đó bị loại khỏi bước chọn ứng viên. Nhờ các mặt nạ này, mọi hành động được lấy mẫu đều hợp lệ theo ràng buộc tài nguyên và miền.

3.5 Quy trình huấn luyện hai giai đoạn

3.5.1 Giai đoạn 1: Tiền huấn luyện có giám sát từ OA-MP-VNE

Ở giai đoạn này, đầu chọn ứng viên được huấn luyện để bắt chước lời giải của thuật toán heuristic OA-MP-VNE trên các VNR sinh ngẫu nhiên. Quá trình dùng một bộ huấn luyện dạng actor-critic có chuẩn hoá lợi thế theo lô và có suy giảm dần hệ số entropy (từ 0.01 về 0.001). Kết quả là mô hình R2 — một chính sách khởi đầu đã nắm được các quy luật hợp lý của heuristic và đạt mức hiệu năng tương đương heuristic (ví dụ 24,3% tỉ lệ chấp nhận trên kịch bản 100 nút). Mô hình R2 vừa là điểm khởi đầu, vừa là chính sách tham chiếu cho neo KL ở giai đoạn sau.

3.5.2 Giai đoạn 2: Tinh chỉnh bằng actor-critic có neo KL

Giai đoạn hai tinh chỉnh đầu chọn ứng viên bằng học tăng cường. Phương pháp sử dụng là **actor-critic**: chính sách (actor) được cập nhật theo gradient chính sách, còn một **bộ phê bình (critic)** học được $V_\phi(s)$ đóng vai trò đường cơ sở (baseline) để giảm phương sai. Lợi thế (advantage) của mỗi episode được tính bằng

$$A = r - V_\phi(s), \quad \hat{A} = \frac{A - \mu_A}{\sigma_A + \epsilon}, \quad (3.5)$$

với $\hat{A}$ là lợi thế đã chuẩn hoá theo lô. Hàm mất mát tổng hợp gồm bốn thành phần: mất mát chính sách, mất mát giá trị, phần thưởng entropy khuyến khích khám phá, và số hạng neo KL về chính sách tham chiếu R2:

$$\mathcal{L} = \underbrace{-\mathbb{E}[\log \pi_\theta(a | s) \hat{A}]}_{\text{chính sách}} + c_v \underbrace{(V_\phi(s) - r)^2}_{\text{giá trị}} - \beta_H \underbrace{H[\pi_\theta]}_{\text{entropy}} + \beta_{\text{KL}} \underbrace{\text{KL}(\pi_\theta \| \pi_{\text{ref}})}_{\text{neo về R2}}, \quad (3.6)$$

với các hệ số mặc định $c_v = 0.5$, $\beta_H = 0.01$, $\beta_{\text{KL}} = 0.1$. Số hạng KL giữ cho phân phối chọn ứng viên không trôi quá xa khỏi lời giải bắt chước — điều kiện cần để tinh chỉnh ổn định dưới tín hiệu thưởng nhiều nhiễu.

Biến thể PPO có cắt. Ngoài actor-critic ở trên, đề án còn cài đặt một *biến thể* sử dụng hàm mục tiêu thay thế có cắt của PPO (clipped surrogate): mỗi lô được lưu ảnh chụp trạng thái mạng vật lý, sau đó chính sách được phát lại để tính tỉ số tầm quan trọng $\rho = \exp(\log \pi_\theta - \log \pi_{\theta_{\text{old}}})$ và áp dụng hàm mục tiêu cắt với $\epsilon = 0.2$ qua nhiều vòng gradient. Biến thể này không phải cấu hình tạo ra kết quả chính của đề án, nhưng được dùng làm đối tượng so sánh “PPO so với actor-critic” ở Chương 5.

3.5.3 Kỹ luật đóng băng tham số

Ở giai đoạn hai, chỉ đầu chọn ứng viên, bộ mã hoá và bộ phê bình được cập nhật; hai đầu xếp hạng nút và liên kết bị **đóng băng**. Lý do là tín hiệu học cho thứ tự xử lý quá yếu và phẳng; nếu để các đầu xếp hạng tiếp tục cập nhật, gradient gần như ngẫu nhiên của chúng sẽ lan ngược và *làm hỏng bộ mã hoá dùng chung*, khiến độ phân kỳ KL bùng nổ và tỉ lệ thành công sụt giảm. Kỹ luật đóng băng vì vậy là một thành phần thiết yếu chứ không phải tùy chọn.

3.5.4 Mã giả thuật toán huấn luyện tổng thể

Thuật toán 1 tóm tắt toàn bộ quy trình hai giai đoạn.

Algorithm 1: Huấn luyện hai giai đoạn của RL-OA-MP-VNE

Input: Mạng vật lý G^s ; bộ sinh VNR; heuristic OA-MP-VNE

Output: Chính sách π_θ đã tinh chỉnh

// Giai đoạn 1: học bắt chước

Khởi tạo ngẫu nhiên θ ;

for mỗi lô VNR sinh ngẫu nhiên **do**

 Giải bằng OA-MP-VNE để lấy ánh xạ tham chiếu;

 Cập nhật θ theo mất mát actor-critic có entropy để bắt chước;

end

Lưu chính sách tham chiếu $\pi_{\text{ref}} \leftarrow \pi_\theta$ (mô hình R2);

// Giai đoạn 2: tinh chỉnh actor-critic

Đóng băng đầu xếp hạng nút và liên kết;

for mỗi lô VNR **do**

for mỗi VNR trong lô **do**

 Mã hoá trạng thái; lấy mẫu thứ tự và **lấy mẫu ứng viên** theo từng miền;

 Ánh xạ liên kết bằng đường đi ngắn nhất; cam kết theo đa đường OA-MP;

 Tính phần thưởng r theo Công thức (3.4);

end

 Tính lợi thế chuẩn hoá $\hat{A}$ theo Công thức (3.5);

 Cập nhật θ, ϕ theo mất mát $\mathcal{L}$ trong Công thức (3.6); cắt chuẩn gradient ở 5.0;

end

return π_θ ;

3.5.5 Các thủ thuật ổn định

Để huấn luyện ổn định, đồ án áp dụng: cắt chuẩn gradient ở ngưỡng 5.0; bộ tối ưu AdamW với tốc độ học 3×10^{-4} và suy giảm trọng số 10^{-4} ; chuẩn hoá lợi thế theo lô; phần thưởng entropy để duy trì khám phá; và neo KL về chính sách tham chiếu để tránh sụp đổ phân phối. Các đường cong huấn luyện (mất mát chính sách, mất mát giá trị, KL, entropy, tỉ lệ chấp nhận) được trình bày ở Chương 5 nhằm minh chứng tính hội tụ và ổn định của quá trình.

Chương này đã trình bày đầy đủ kiến trúc, môi trường và thuật toán huấn luyện của RL-OA-MP-VNE, với ba nguyên lý thiết kế cốt lõi: mã hoá phân cấp đa miền, đóng băng đầu xếp hạng và chỉ tinh chỉnh đầu chọn ứng viên, và quy trình hai giai đoạn bắt chước rồi tinh chỉnh actor-critic có neo KL. Chương tiếp theo phân tích lý thuyết các tính chất của phương pháp, bao gồm độ phức tạp tính toán, độ phức tạp bộ nhớ và đặc tính hội tụ.

CHƯƠNG 4. PHÂN TÍCH LÝ THUYẾT

Chương này phân tích các tính chất lý thuyết của phương pháp đề xuất, gồm độ phức tạp tính toán, độ phức tạp bộ nhớ, và đặc tính hội tụ trong ngữ cảnh VNE. Ký hiệu dùng trong chương: $|N^s|, |E^s|$ là số nút và liên kết mạng vật lý; D là số miền; $|N^v|, |E^v|$ là số nút và liên kết của một VNR; d là chiều ẩn (ở đây $d = 32$); L là số lớp GCN; K là số ứng viên giữ lại trên mỗi miền.

4.1 Độ phức tạp tính toán

4.1.1 Độ phức tạp suy diễn (inference)

Chi phí suy diễn cho một VNR gồm bốn thành phần.

Bộ mã hoá phân cấp. Mỗi lớp GCN nội miền có chi phí truyền tin tỉ lệ với số cạnh nhân chiều ẩn, tổng trên các miền là $\mathcal{O}(L |E^s| d)$ (mỗi cạnh chỉ thuộc một miền nên tổng số cạnh nội miền không vượt $|E^s|$). Bước tóm tắt miền và GCN liên miền trên siêu đồ thị D nút tốn $\mathcal{O}(|N^s| d + D^2 d)$. Bộ mã hoá VNR (GCN + self-attention 4 đầu) tốn $\mathcal{O}(L |E^v| d + |N^v|^2 d)$, nhỏ vì $|N^v| \leq 7$. Do đó chi phí mã hoá chủ đạo là

$$\mathcal{O}(L |E^s| d + D^2 d). \quad (4.1)$$

Bộ giải mã chọn ứng viên. Với mỗi nút ảo, đầu chọn ứng viên tính điểm cross-attention cho các nút vật lý khả thi trong các miền cho phép. Trong trường hợp xấu nhất là toàn bộ $|N^s|$ nút, chi phí là $\mathcal{O}(|N^v| |N^s| d)$; tuy nhiên nhờ lọc khả thi CPU và giới hạn K ứng viên mỗi miền, chi phí thực tế giảm còn $\mathcal{O}(|N^v| D K d)$.

Ánh xạ liên kết. Mỗi liên kết ảo dùng một lần tìm đường đi ngắn nhất (Dijkstra) tốn $\mathcal{O}(|E^s| \log |N^s|)$, tổng là $\mathcal{O}(|E^v| |E^s| \log |N^s|)$.

Tối ưu PSO khi triển khai. Ở chế độ triển khai, một bước tối ưu hoá bầy hạt với P hạt và I vòng lặp đánh giá hàm thích nghi tốn $\mathcal{O}(P I |N^v|)$, là một thừa số hằng cộng thêm không phụ thuộc kích thước mạng vật lý.

Tổng hợp, độ phức tạp suy diễn một VNR là tuyến tính theo $|E^s|$ (bỏ qua thừa số log của Dijkstra), tức **khả mở rộng** với tô-pô lớn — trái ngược với độ phức tạp cấp số mũ của lời giải ILP đã nêu ở Chương 2.

4.1.2 Độ phức tạp một bước huấn luyện

Một bước cập nhật xử lý một lô B VNR. Mỗi VNR cần một lượt suy diễn (rollout) cộng một lượt lan truyền ngược; lan truyền ngược cùng cấp độ phức tạp

với lan truyền xuôi. Ở giai đoạn tinh chỉnh actor-critic chuẩn (normal-reward), mỗi lô cập nhật một vòng gradient, nên chi phí một bước là $\mathcal{O}(B \cdot C_{\text{infer}})$ với C_{infer} là chi phí suy diễn ở Mục 4.1.1. Biến thể PPO có cất phát lại chính sách K_{ppo} vòng trên cùng một lô nên chi phí nhân thêm hệ số K_{ppo} (mặc định $K_{\text{ppo}} = 2$).

4.2 Độ phức tạp bộ nhớ

Tổng số tham số của mạng chính sách khoảng 55,700, trong đó ở giai đoạn tinh chỉnh có 19,394 tham số bị đóng băng (hai đầu xếp hạng) và 36,293 tham số được cập nhật (bộ mã hoá, đầu chọn ứng viên, bộ phê bình). Đây là một mô hình *rất nhỏ gọn* so với các mạng học sâu thông thường, giúp suy diễn nhanh và phù hợp triển khai trên hạ tầng hạn chế tài nguyên.

Về bộ nhớ kích hoạt (activation), do đồ thị được xử lý theo từng miền và VNR có kích thước nhỏ, lượng kích hoạt cần lưu cho lan truyền ngược tỉ lệ $\mathcal{O}(L |N^s| d)$ — tuyến tính theo số nút vật lý. Phương pháp không dùng replay buffer lớn: mỗi lô chỉ lưu các đại lượng rollout cần thiết (log-xác suất, phần thưởng, giá trị, và với biến thể PPO là ảnh chụp trạng thái mạng vật lý để phát lại), nên dấu chân bộ nhớ tổng thể nhỏ và ổn định trong suốt huấn luyện.

4.3 Phân tích hội tụ

4.3.1 Cải thiện đơn điệu của gradient chính sách có baseline

Phương pháp tinh chỉnh là một thuật toán gradient chính sách với baseline học được (actor-critic). Theo định lý gradient chính sách, hướng cập nhật $\mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a | s) \hat{A}]$ là ước lượng không chệch của gradient mục tiêu kỳ vọng $J(\theta)$ khi baseline $V_{\phi}(s)$ độc lập với hành động. Việc trừ baseline và chuẩn hoá lợi thế làm *giảm phương sai* của ước lượng gradient mà không gây chệch, nhờ đó các bước cập nhật ổn định hơn và kỳ vọng cải thiện đơn điệu cục bộ của $J(\theta)$ được duy trì với tốc độ học đủ nhỏ. Biến thể PPO bổ sung cận dưới có cắt (clipped surrogate) cho mục tiêu thay thế, đảm bảo mỗi bước cập nhật không làm chính sách trôi quá xa khỏi chính sách cũ — một cơ sở lý thuyết chặt hơn cho cải thiện đơn điệu.

4.3.2 Vai trò của neo KL và đóng băng tham số

Số hạng neo KL về chính sách tham chiếu R2 đóng vai trò một *ràng buộc vùng tin cậy mềm*: nó giới hạn độ lệch của phân phối chọn ứng viên khỏi lời giải bất chước ban đầu, ngăn hiện tượng sụp đổ phân phối khi tín hiệu thưởng nhiều nhiều. Kết hợp với kỷ luật đóng băng hai đầu xếp hạng (Mục 3.5.3), tín hiệu học được dồn vào đúng thành phần có ích, tránh để gradient gần ngẫu nhiên của các đầu xếp hạng làm hỏng bộ mã hoá dùng chung. Đây chính là lý do lý thuyết cho thiết kế “khởi động bằng học bất chước rồi tinh chỉnh có neo”: pha bắt chước cung cấp điểm khởi đầu phương sai thấp trong vùng nghiệm tốt, còn neo KL giữ cho quá trình tinh

chỉnh không rời khỏi vùng đó.

4.3.3 Quan sát thực nghiệm về tính hội tụ

Các đặc tính lý thuyết trên được kiểm chứng qua quỹ đạo huấn luyện thực tế (trình bày chi tiết ở Chương 5): entropy của chính sách giảm dần và bão hoà (chính sách ngày càng tự tin), độ phân kỳ KL dao động quanh một mức nhỏ ổn định thay vì bùng nổ, và tỉ lệ thành công tăng rồi đạt bình nguyên. Sự bão hoà này phù hợp với dự đoán: khi π_θ tiến gần một cực trị cục bộ trong vùng tin cậy do neo KL xác định, lợi thế kỳ vọng tiến về không và các bước cập nhật nhỏ dần.

Chương này đã chỉ ra phương pháp đề xuất có độ phức tạp tính toán tuyến tính theo kích thước mạng vật lý, dấu chân bộ nhớ nhỏ nhờ mô hình gọn và không dùng replay buffer, cùng đặc tính hội tụ ổn định được bảo đảm bởi baseline giảm phương sai và neo KL. Chương tiếp theo trình bày kết quả thực nghiệm để kiểm chứng các phân tích này.

CHƯƠNG 5. ĐÁNH GIÁ THỰC NGHIỆM

Chương này trình bày thiết lập thực nghiệm, các tập dữ liệu, độ đo so sánh và phân tích kết quả của phương pháp đề xuất (cấu hình chuẩn V19 normal-reward) so với các baseline. Các kết quả được phân tích trên ba quy mô mạng vật lý (50, 100 và 200 nút) để kiểm chứng khả năng tổng quát hoá, kèm phân tích ablation và trực quan hoá quỹ đạo huấn luyện nhằm minh chứng tính hội tụ.

5.1 Cấu hình thực nghiệm

5.1.1 Phần cứng và phần mềm

Toàn bộ thực nghiệm được cài đặt bằng Python (≥ 3.9) với thư viện PyTorch cho mạng nơ-ron và NetworkX cho thao tác đồ thị. Mô hình chính sách nhỏ gọn (khoảng 55,700 tham số) nên huấn luyện và suy diễn đều khả thi trên CPU; thời gian mỗi epoch (xử lý 5000 VNR) dao động trong khoảng 300–800 giây như ghi nhận trong nhật ký huấn luyện. Mỗi cấu hình được chạy với hạt giống ngẫu nhiên cố định để bảo đảm khả năng tái lập.

5.1.2 Tập dữ liệu

Đồ án xây dựng các kịch bản đa miền ở ba quy mô. Bảng 5.1 tóm tắt các tham số chính. Ở mỗi kịch bản, mạng vật lý được chia thành 10 miền; mỗi nút vật lý có dung lượng CPU và đơn giá ngẫu nhiên trong khoảng cho trước, mỗi liên kết có băng thông và đơn giá tương ứng. Yêu cầu mạng ảo có kích thước từ 3 đến 7 nút (trung bình 5), nhu cầu CPU trong $[1, 8]$ và nhu cầu băng thông trong $[5, 25]$; thời điểm đến tuân theo tiến trình Poisson và thời gian sống được sinh ngẫu nhiên, mô phỏng kịch bản trực tuyến. Tập huấn luyện gồm 10,000 VNR, tập kiểm thử gồm 3,000 VNR tách biệt.

Bảng 5.1: Tham số các tập dữ liệu thực nghiệm

Kịch bản	Số miền	Số nút	Số liên kết	Số VNR kiểm thử
50 nút	10	50	50	3000
100 nút	10	100	110	3000
200 nút	10	200	—	3000

5.1.3 Siêu tham số huấn luyện

Bảng 5.2 liệt kê các siêu tham số chính của cấu hình chuẩn (normal-reward). Bộ tối ưu là AdamW với tốc độ học 3×10^{-4} và suy giảm trọng số 10^{-4} ; mỗi epoch xử lý 5000 VNR theo lô kích thước 16. Hàm thưởng dùng cấu hình chuẩn $\rho_{\text{bonus}} = 1,0$, $\lambda = 0,3$, $\rho_{\text{fail}} = 1,0$ như trình bày ở Mục 3.4.3.

Bảng 5.2: Siêu tham số cấu hình chuẩn (V19 normal-reward)

Siêu tham số	Giá trị
Bộ tối ưu	AdamW
Tốc độ học	3×10^{-4}
Suy giảm trọng số	10^{-4}
Kích thước lô	16
Số VNR mỗi epoch	5000
Hệ số giá trị c_v	0.5
Hệ số entropy β_H	0.01
Hệ số neo KL β_{KL}	0.1
Ngưỡng cắt gradient	5.0
EMA chi phí (suy giảm)	0.95

5.2 Baseline và độ đo

5.2.1 Các thuật toán so sánh

Đồ án so sánh phương pháp đề xuất với các baseline sau, tất cả đều được cài đặt trong cùng khung thực nghiệm để bảo đảm công bằng:

- **MP-VNE** (heuristic chuẩn): xếp hạng ứng viên theo chi phí ước lượng (PreCost) kết hợp tối ưu hoá bầy hạt PSO (20 hạt, 15 vòng lặp), ánh xạ liên kết bằng đường đi ngắn nhất. Đây là baseline heuristic mạnh nhất, đóng vai trò *trần hiệu năng* tham chiếu.
- **MP-VNE-V4** (bản trung thành với bài báo gốc): PSO với tham số đúng theo công bố (10 hạt, 50 vòng lặp, hệ số quán tính/nhận thức/xã hội 0,3/0,3/0,4, đột biến 10%). Là baseline heuristic được so sánh trực tiếp ở mọi quy mô.
- **R2** (`il_mp_vne_v17`, chỉ học bắt chước): mô hình sau giai đoạn tiền huấn luyện bắt chước, *chưa* qua tinh chỉnh tăng cường. Dùng để cô lập đóng góp của giai đoạn RL.
- **RL-OA-MP-VNE** (`il_mp_vne_v19`, phương pháp đề xuất): mô hình R2 đã được tinh chỉnh actor-critic ở cấu hình chuẩn, triển khai qua PSO.

Các thuật toán MC-VNM và FlagVNE được nhắc tới trong khảo sát (Chương 2) nhưng không được cài đặt lại trong khung thực nghiệm này; việc tích hợp chúng được để lại như hướng phát triển.

5.2.2 Độ đo đánh giá

Năm độ đo được sử dụng: (1) **tỉ lệ chấp nhận** (acceptance ratio) — tỉ số VNR nhúng thành công trên tổng số VNR; (2) **doanh thu** (revenue) tích lũy; (3) **chi phí trung bình** mỗi VNR; (4) **tỉ số doanh thu/chi phí** (R/C); và (5) **độ trễ trung bình**

của các đường đi ánh xạ. Tỷ lệ chấp nhận là độ đo quan trọng nhất vì cấu hình chuẩn được thiết kế hướng tới mục tiêu này.

5.3 Kết quả tổng thể


5.3.1 Kết quả trên kịch bản 50 nút

Bảng 5.3 so sánh phương pháp đề xuất (lấy ở epoch tốt nhất) với baseline heuristic MP-VNE-V4 trên 3000 VNR kiểm thử. Phương pháp đề xuất đạt tỷ lệ chấp nhận **33,13%**, cao hơn baseline (29,03%) 4,1 **điểm phần trăm** — tức tác nhân học tăng cường *vượt* heuristic ở quy mô này. Đổi lại, do chấp nhận thêm cả những yêu cầu tốn kém hơn, chi phí trung bình và tỉ số R/C của phương pháp đề xuất xấp xỉ baseline; đây là đánh đổi hợp lý khi mục tiêu chính là tối đa hoá số yêu cầu được phục vụ.

Bảng 5.3: Kết quả trên kịch bản 50 nút (3000 VNR kiểm thử)

Phương pháp	Chấp nhận (%)	Số TC	Doanh thu	Chi phí TB	R/C
MP-VNE-V4 (heuristic)	29.03	871	460.6	216.5	0.314
RL-OA-MP-VNE (đề xuất, e19)	33.13	994	573.1	233.8	0.310

Hình 5.1 trực quan hoá so sánh theo từng epoch giữa phương pháp đề xuất và MP-VNE-V4 trên bốn độ đo. Phương pháp đề xuất duy trì tỷ lệ chấp nhận cao hơn baseline một cách nhất quán qua các epoch.



Hình 5.1: So sánh RL-OA-MP-VNE (theo từng epoch) với baseline MP-VNE-V4 trên kịch bản 50 nút, bốn độ đo: tỷ lệ chấp nhận, chi phí, R/C, độ trễ.

5.3.2 Kết quả trên kịch bản 100 nút

Bảng 5.4 trình bày kết quả trên kịch bản 100 nút. Ở đây thứ tự hiệu năng rõ rệt: phương pháp đề xuất (26,0%) vượt baseline heuristic MP-VNE-V4 (23,3%) và vượt xa mô hình chỉ học bắt chước R2 (17,2%) — chênh lệch +8,8 **điểm phần trăm** so với R2 cho thấy đóng góp lớn của giai đoạn tinh chỉnh tăng cường. Heuristic MP-VNE đầy đủ vẫn giữ trần cao nhất (32,8%), cho thấy vẫn còn dư địa cải thiện, song khoảng cách đã được thu hẹp đáng kể nhờ học tăng cường.

Bảng 5.4: Kết quả trên kịch bản 100 nút (3000 VNR kiểm thử)

Phương pháp	Chấp nhận (%)	Số TC	Doanh thu	Chi phí TB	R/C
MP-VNE (heuristic, trần)	32.83	985	1173.5	193.9	0.340
RL-OA-MP-VNE (đề xuất)	26.00	780	907.3	219.3	0.308
MP-VNE-V4 (heuristic)	23.30	699	773.6	230.3	0.293
R2 (chỉ học bắt chước)	17.20	516	604.0	292.3	0.217

5.3.3 Kết quả trên kịch bản 200 nút

Bảng 5.5 đánh giá khả năng tổng quát hoá ở quy mô lớn hơn. Ở 200 nút, tỉ lệ chấp nhận của mọi phương pháp đều giảm do mật độ yêu cầu trên tài nguyên cao hơn. Phương pháp đề xuất (12,5%) vẫn vượt mô hình chỉ học bắt chước R2 (11,6%) và bám sát baseline heuristic MP-VNE-V4 (13,4%). Đáng chú ý, mô hình huấn luyện ở 50 nút khi áp dụng trực tiếp lên 200 nút (12,5%) cho kết quả tương đương mô hình huấn luyện riêng ở 200 nút (12,0%), cho thấy chính sách học được có khả năng *chuyển giao* (transfer) tốt giữa các quy mô.

Bảng 5.5: Kết quả trên kịch bản 200 nút (3000 VNR kiểm thử)

Phương pháp	Chấp nhận (%)	Số TC
MP-VNE-V4 (heuristic)	13.37	401
RL-OA-MP-VNE (huấn luyện 50 nút)	12.50	375
RL-OA-MP-VNE (huấn luyện 200 nút)	12.00	360
R2 (chỉ học bắt chước)	11.63	349

5.3.4 Tổng hợp và bàn luận

Tổng hợp ba kịch bản cho thấy một bức tranh nhất quán: *tinh chỉnh tăng cường luôn cải thiện so với mô hình chỉ học bắt chước (R2)*, và phương pháp đề xuất *vượt hoặc bám sát* baseline heuristic được so sánh trực tiếp (MP-VNE-V4) ở mọi quy mô, thậm chí vượt cả ở quy mô 50–100 nút. Khoảng cách tới heuristic MP-VNE đầy đủ thu hẹp khi quy mô tăng. Kết quả này khẳng định luận điểm trung tâm của

đề án: *lựa chọn ứng viên là đòn bẩy hiệu quả*, và làm cho lựa chọn này ngẫu nhiên trong huấn luyện cho phép RL vượt trần của mô hình bất chước.

5.4 Phân tích ablation

5.4.1 Ảnh hưởng của giai đoạn học tăng cường

So sánh R2 (chỉ học bất chước) với RL-OA-MP-VNE (R2 cộng tinh chỉnh tăng cường) chính là phép ablation cô lập đóng góp của giai đoạn 2. Trên kịch bản 100 nút, tỉ lệ chấp nhận tăng từ 17,2% lên 26,0% (+8,8 điểm phần trăm) và chi phí trung bình giảm từ 292,3 xuống 219,3. Điều này chứng tỏ giai đoạn tăng cường không chỉ chấp nhận nhiều yêu cầu hơn mà còn tìm được các lời giải *ré hơn* — đúng với thiết kế hàm thưởng chuẩn (thưởng nhẹ cho lời giải tiết kiệm chi phí).

5.4.2 Vai trò của khám phá trong lựa chọn ứng viên


Như phân tích ở Mục 3.3.3, nếu giữ đường argmax chặt ($K = 1$, không lấy mẫu) trong huấn luyện thì không có tín hiệu để học tăng cường. Việc làm cho lựa chọn ứng viên trở nên ngẫu nhiên (lấy mẫu Categorical theo từng miền) là điều kiện cần để tác nhân vượt trần R2; chính cơ chế này tạo ra cải thiện +8,8 điểm phần trăm nêu trên.

5.4.3 So sánh actor-critic với biến thể PPO có cắt

Đề án cài đặt cả hai chế độ tinh chỉnh: actor-critic chuẩn (`reinforce`: gradient chính sách + phê bình + neo KL + entropy) và biến thể PPO có cắt (`ppo`: thêm hàm mục tiêu thay thế có cắt với $\epsilon = 0,2$ và nhiều vòng gradient). Cấu hình chuẩn của đề án dùng chế độ actor-critic. Phân tích so sánh trực tiếp hai chế độ về tốc độ hội tụ và độ ổn định đang được hoàn tất và sẽ được bổ sung; kỳ vọng lý thuyết là PPO cho cập nhật ổn định hơn nhờ ràng buộc vùng tin cậy chặt, đổi lại chi phí tính toán mỗi bước cao hơn (Mục 4.1.2).


5.5 Trực quan hoá quỹ đạo huấn luyện

Để minh chứng tính hội tụ và đúng đắn của cài đặt, Hình 5.2 trình bày các chỉ báo hội tụ qua khoảng 150 epoch huấn luyện (gộp từ sáu phase liên tiếp). Có thể quan sát ba xu hướng phù hợp với phân tích lý thuyết ở Chương 4: (i) entropy của chính sách giảm dần từ khoảng 9,4 về khoảng 4,3 rồi bão hoà — chính sách ngày càng tự tin; (ii) độ phân kỳ KL dao động quanh một mức nhỏ ổn định ($\approx 0,1-0,25$) thay vì bùng nổ, nhờ tác dụng của neo KL; và (iii) tỉ lệ thành công trực tuyến tăng rồi đạt bình nguyên quanh 34–35%.




Hình 5.2: Các chỉ báo hội tụ của quá trình huấn luyện cấu hình chuẩn trên kịch bản 50 nút: mất mát, KL, entropy và tỉ lệ thành công qua các epoch.

Hình 5.3 và Hình 5.4 lần lượt cho thấy đường cong tỉ lệ chấp nhận (đánh giá trên tập kiểm thử) và đường cong phần thưởng theo epoch. Tỉ lệ chấp nhận đạt đỉnh 33,13% tại epoch 19 rồi dao động trong vùng bình nguyên, cho thấy mô hình đã hội tụ về một chính sách ổn định.



Hình 5.3: Đường cong tỉ lệ chấp nhận theo epoch trên tập kiểm thử 50 nút.



Hình 5.4: Đường cong phần thưởng trung bình theo epoch (cấu hình chuẩn, 50 nút).

5.6 Thảo luận

Kết quả thực nghiệm khẳng định ba điểm. **Thứ nhất**, tinh chỉnh tăng cường mang lại cải thiện ổn định và đáng kể so với học bắt chước thuần túy ở mọi quy mô, lớn nhất là +8,8 điểm phần trăm trên kịch bản 100 nút. **Thứ hai**, phương pháp đề xuất vượt baseline heuristic được so sánh trực tiếp (MP-VNE-V4) ở quy mô 50–100 nút và bám sát ở 200 nút, đồng thời chính sách học được chuyển giao tốt giữa các quy mô. **Thứ ba**, quá trình huấn luyện hội tụ ổn định, không xảy ra hiện tượng sụp đổ phân phối nhờ neo KL và kỷ luật đóng băng.

Về **hạn chế**: khoảng cách tới heuristic MP-VNE đầy đủ vẫn còn (đặc biệt khi heuristic này dùng tối ưu PSO mạnh hơn), và tỉ lệ chấp nhận tuyệt đối giảm ở quy mô 200 nút. Hiệu năng còn phụ thuộc phân phối VNR; với các phân phối lệch nhiều so với lúc huấn luyện, chính sách có thể cần tinh chỉnh lại. Các hướng khắc phục được bàn ở Chương 6.

Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện nhất quán so với mô hình bắt chước và vượt baseline heuristic so sánh trực tiếp trên cả ba quy mô, đồng thời giữ quá trình huấn luyện ổn định và hội tụ. Chương cuối tổng kết các đóng góp và đề xuất hướng phát triển.

CHƯƠNG 6. KẾT LUẬN

6.1 Kết quả đạt được

Đồ án đã đề xuất và hiện thực hoá *RL-OA-MP-VNE* — một phương pháp nhúng mạng ảo đa miền kết hợp mạng nơ-ron đồ thị với học tăng cường. Ba đóng góp chính đã được hoàn thành:

1. **Kiến trúc mã hoá phân cấp đa miền** gồm GCN nội miền và GCN liên miền, kết hợp đầu chọn ứng viên cross-attention có thiên lệch chi phí tường minh và mặt nạ khả thi cứng, với toàn bộ mô hình chỉ khoảng 55,700 tham số.
2. **Quy trình huấn luyện hai giai đoạn** — khởi động bằng học bắt chước OA-MP-VNE rồi tinh chỉnh actor-critic có neo KL — cùng phát hiện then chốt rằng *lựa chọn ứng viên* (chứ không phải thứ tự xử lý) mới là đòn bẩy hiệu quả, và việc làm cho lựa chọn này ngẫu nhiên trong huấn luyện là điều kiện cần để vượt trần của mô hình bắt chước.
3. **Bộ benchmark đa kịch bản và đánh giá hệ thống** trên ba quy mô (50, 100, 200 nút). Kết quả cho thấy phương pháp đề xuất đạt 33,1% tỉ lệ chấp nhận trên kịch bản 50 nút (vượt heuristic MP-VNE-V4 ở mức 29,0%), cải thiện +8,8 điểm phần trăm so với mô hình chỉ học bắt chước trên kịch bản 100 nút (26,0% so với 17,2%), đồng thời chính sách học được chuyển giao tốt sang quy mô 200 nút.

6.2 Hạn chế

Phương pháp còn một số hạn chế. Thứ nhất, vẫn tồn tại khoảng cách tới heuristic MP-VNE đầy đủ (trên 32,8% ở kịch bản 100 nút), đặc biệt khi heuristic này dùng tối ưu PSO mạnh. Thứ hai, tỉ lệ chấp nhận tuyệt đối giảm ở quy mô lớn (200 nút), cho thấy cần kiến trúc mã hoá biểu cảm hơn để mở rộng. Thứ ba, hiệu năng phụ thuộc phân phối VNR lúc huấn luyện; với phân phối lệch nhiều, chính sách có thể cần tinh chỉnh lại. Thứ tư, chi phí huấn luyện (khoảng 150 epoch) tuy chấp nhận được nhưng không nhỏ, và đồ án chưa khảo sát đầy đủ khía cạnh công bằng tài nguyên giữa nhiều người thuê.

6.3 Hướng phát triển trong tương lai

Một số hướng phát triển khả thi gồm: (1) **mở rộng quy mô** lên 500–1000 nút (các tập dữ liệu đã sẵn sàng) với bộ mã hoá GAT đa lớp biểu cảm hơn; (2) **học chuyển giao và meta-RL** để chính sách thích nghi nhanh giữa các tô-pô và phân phối yêu cầu khác nhau; (3) **tích hợp cận trên ILP** cho các tô-pô nhỏ nhằm định lượng khoảng cách tối ưu; (4) **tối ưu trực tuyến** có tính tới thời gian sống và

lịch đến của VNR để giữ “khoảng trống chiến lược”; và (5) bổ sung **tiêu chí công bằng** giữa các miền và người thuê vào hàm thưởng. Việc hoàn tất so sánh trực tiếp giữa chế độ actor-critic và biến thể PPO có cắt (Mục 5.4.3) cũng là một bước tiếp theo trực tiếp.

TÀI LIỆU THAM KHẢO

- [1] D. Kreutz, F. M. V. Ramos, P. E. Verissimo, C. E. Rothenberg, S. Azodolmolky **and** S. Uhlig, “Software-defined networking: A comprehensive survey,” *Proceedings of the IEEE*, 2015.
- [2] R. Mijumbi, J. Serrat, J.-L. Gorricho, N. Bouten, F. De Turck **and** R. Boutaba, “Network function virtualization: State-of-the-art and research challenges,” *IEEE Communications Surveys & Tutorials*, 2016.
- [3] A. Fischer, J. F. Botero, M. T. Beck, H. de Meer **and** X. Hesselbach, “Virtual network embedding: A survey,” *IEEE Communications Surveys & Tutorials*, **jourvol** 15, **number** 4, **pages** 1888–1906, 2013.
- [4] H. Cao, L. Yang **and** H. Zhu, “Survey on virtual network embedding: Theory and practice,” *IEEE Communications Surveys & Tutorials*, 2019.
- [5] N. M. M. K. Chowdhury, M. R. Rahman **and** R. Boutaba, “Virtual network embedding with coordinated node and link mapping,” *in IEEE INFOCOM* 2009.
- [6] X. Cheng, S. Su, Z. Zhang **and others**, “Virtual network embedding through topology-aware node ranking,” *in ACM SIGCOMM Computer Communication Review* 2011.
- [7] A. Author **and** B. Author, “Mp-vne: Marking-probability-based virtual network embedding for online requests,” *Computer Networks*, 2020, TODO: cập nhật metadata chính xác.
- [8] H. Yao, X. Chen, M. Li, P. Zhang **and** L. Wang, “A novel reinforcement learning algorithm for virtual network embedding,” *in Neurocomputing* 2018.
- [9] T. Wang, Q. Fan, C. Wang, L. Ding, N. J. Yuan **and** H. Xiong, “Flagvne: A flexible and generalizable reinforcement learning framework for network resource allocation,” *in Proc. IJCAI* 2024.
- [10] R. S. Sutton **and** A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd. MIT Press, 2018.
- [11] R. J. Williams, “Simple statistical gradient-following algorithms for connectionist reinforcement learning,” *Machine Learning*, **jourvol** 8, **pages** 229–256, 1992.
- [12] J. Schulman, F. Wolski, P. Dhariwal, A. Radford **and** O. Klimov, “Proximal policy optimization algorithms,” *arXiv preprint arXiv:1707.06347*, 2017.
- [13] R. L. Plackett, “The analysis of permutations,” *Journal of the Royal Statistical Society. Series C (Applied Statistics)*, **jourvol** 24, **number** 2, **pages** 193–202, 1975.

- [14] T. N. Kipf **and** M. Welling, “Semi-supervised classification with graph convolutional networks,” **in** *ICLR* 2017.
- [15] P. Veličković, G. Cucurull, A. Casanova, A. Romero, P. Liò **and** Y. Bengio, “Graph attention networks,” **in** *ICLR* 2018.
- [16] A. Vaswani, N. Shazeer, N. Parmar **and others**, “Attention is all you need,” **in** *Advances in Neural Information Processing Systems (NeurIPS)* 2017.

PHỤ LỤC

A. CHI TIẾT KIẾN TRÚC, SIÊU THAM SỐ VÀ KẾT QUẢ

Phụ lục này cung cấp các chi tiết bổ sung về kiến trúc mạng chính sách, siêu tham số và kết quả thực nghiệm đầy đủ theo từng epoch, nhằm hỗ trợ tái lập kết quả của đề án.

A.1 Chi tiết tham số mạng chính sách

Toàn bộ mạng chính sách RL-OA-MP-VNE có khoảng 55,700 tham số, phân bố theo các khối như Bảng A.1. Ở giai đoạn tinh chỉnh tăng cường, hai đầu xếp hạng nút và liên kết (tổng 19,394 tham số) bị đóng băng, còn lại 36,293 tham số được cập nhật.

Bảng A.1: Phân bố tham số theo khối của mạng chính sách

Khối	Số tham số	Trạng thái (giai đoạn 2)
GCN nội miền + liên miền (substrate)	7,296	huấn luyện
GCN mạng ảo (VN-GCN)	1,376	huấn luyện
Self-attention mạng ảo	6,304	huấn luyện
Đầu chọn ứng viên (candidate head)	14,905	huấn luyện
Bộ phê bình giá trị (value head)	6,338	huấn luyện
Đầu xếp hạng nút (node head)	10,561	đóng băng
Đầu xếp hạng liên kết (link head)	8,833	đóng băng
Tổng	55,613	36,293 huấn luyện

A.2 Cấu hình kiến trúc chi tiết

Bảng A.2 liệt kê các tham số cấu hình kiến trúc. Bộ mã hoá nội miền dùng GCN ba lớp, bộ mã hoá liên miền dùng GCN hai lớp, đều với chiều ẩn 32. Khối self-attention mạng ảo dùng 4 đầu. Đặc trưng đầu vào của nút vật lý và nút ảo đều có 7 chiều.

Bảng A.2: Tham số cấu hình kiến trúc

Tham số	Giá trị
Số lớp GCN nội miền	3
Số lớp GCN liên miền	2
Chiều ẩn (mọi GCN)	32
Số lớp GCN mạng ảo	2
Số đầu self-attention	4
Chiều đặc trưng nút vật lý	7
Chiều đặc trưng nút ảo	7
Chiều ẩn đầu chọn ứng viên	64
Số ứng viên giữ lại / miền (K)	1
Hàm kích hoạt	ReLU
Chuẩn hoá	LayerNorm + residual

A.3 Kết quả chi tiết theo epoch trên kịch bản 50 nút

Bảng A.3 trình bày kết quả đánh giá trên 3000 VNR kiểm thử ở từng epoch huấn luyện (cấu hình chuẩn normal-reward). Tỷ lệ chấp nhận đạt đỉnh 33,13% tại epoch 19; giá trị trung bình qua các epoch là khoảng 31,3%, ổn định và luôn cao hơn baseline MP-VNE-V4 (29,03%).

Bảng A.3: Kết quả theo epoch trên kịch bản 50 nút (cấu hình chuẩn)

Epoch	Chấp nhận	R/C	Chi phí	Epoch	Chấp nhận	R/C	Chi phí
1	0.3147	0.3143	231.5	17	0.3100	0.3048	233.4
2	0.2930	0.2836	242.3	18	0.3107	0.3050	224.5
3	0.3243	0.3070	243.6	19	0.3313	0.3099	233.8
4	0.3147	0.3087	236.9	20	0.3257	0.3092	233.5
5	0.3140	0.2970	240.2	21	0.3107	0.3013	234.8
6	0.3047	0.3045	233.2	22	0.3167	0.3090	227.3
7	0.3137	0.3015	235.1	23	0.3150	0.3046	237.7
8	0.2940	0.2918	241.3	24	0.3107	0.3010	239.1
9	0.3060	0.2988	241.9	25	0.3133	0.2975	241.0
10	0.3163	0.3128	228.1	26	0.3093	0.2975	239.9
11	0.3183	0.3059	236.6	27	0.3113	0.2997	235.7
12	0.3057	0.3067	237.5	28	0.3107	0.2934	243.2
13	0.3107	0.2954	240.3	29	0.3180	0.3079	238.5
14	0.3107	0.3002	237.6	30	0.2973	0.2948	245.5
15	0.3087	0.3000	235.0	31	0.3193	0.3046	237.0
16	0.3290	0.3050	235.7	32	0.3113	0.2996	240.2

B. CHI TIẾT TẬP DỮ LIỆU VÀ THUẬT TOÁN SO SÁNH

Phụ lục này mô tả chi tiết cách sinh các tập dữ liệu thực nghiệm và tham số cấu hình của các thuật toán baseline dùng để so sánh, nhằm bảo đảm khả năng tái lập.

B.1 Chi tiết sinh tập dữ liệu

Mỗi kịch bản gồm một mạng vật lý đa miền và hai tập VNR (huấn luyện và kiểm thử) tách biệt. Mạng vật lý được chia thành 10 miền; các nút và liên kết được sinh ngẫu nhiên trong các khoảng tham số ở Bảng B.1. Các liên kết liên miền nối các nút biên giữa những miền lân cận, tạo thành một tô-pô liên miền liên thông.

Bảng B.1: Khoảng tham số sinh mạng vật lý (kịch bản 50 và 100 nút)

Tham số	50 nút	100 nút
Số miền	10	10
Số nút	50	100
Số liên kết	50	110
Dung lượng CPU	10.5–29.4	10.5–29.4
Đơn giá CPU	1.1–3.95	1.03–4.39
Băng thông liên kết	42–93	42–96
Đơn giá băng thông	0.18–0.99	0.29–0.99
Độ trễ xử lý	0.25–1.87	0.25–1.63
Độ trễ truyền dẫn	1.05–9.76	2.47–9.76

Các yêu cầu mạng ảo được sinh với tham số ở Bảng B.2. Thời điểm đến tuân theo tiến trình Poisson và thời gian sống được sinh ngẫu nhiên, mô phỏng kịch bản trực tuyến nơi VNR đến và rời đi liên tục theo thời gian. Tập huấn luyện gồm 10,000 VNR, tập kiểm thử gồm 3,000 VNR.

Bảng B.2: Khoảng tham số sinh yêu cầu mạng ảo

Tham số	Giá trị
Số nút mỗi VNR	3–7 (trung bình 5)
Nhu cầu CPU mỗi nút ảo	1.0–8.0
Nhu cầu băng thông mỗi liên kết ảo	5.0–25.0
Phân phối thời điểm đến	Poisson
Thời gian sống	ngẫu nhiên
Số VNR huấn luyện	10,000
Số VNR kiểm thử	3,000

B.2 Tham số các thuật toán so sánh

Bảng B.3 liệt kê tham số của các thuật toán baseline. **MP-VNE** dùng cấu hình PSO mạnh hơn (20 hạt, 15 vòng lặp), đóng vai trò trần hiệu năng tham chiếu. **MP-VNE-V4** dùng đúng tham số theo bài báo gốc (10 hạt, 50 vòng lặp, hệ số quán tính/nhận thức/xã hội 0,3/0,3/0,4), là baseline được so sánh trực tiếp ở mọi quy mô. Cả hai đều xếp hạng ứng viên theo chi phí ước lượng (PreCost) và ánh xạ liên kết bằng đường đi ngắn nhất.

Bảng B.3: Tham số PSO của các baseline heuristic

Tham số	MP-VNE	MP-VNE-V4
Số hạt (particles)	20	10
Số vòng lặp (iterations)	15	50
Hệ số quán tính α	0.7	0.3
Hệ số nhận thức β	1.5	0.3
Hệ số xã hội γ	1.5	0.4
Xác suất đột biến	0.1	0.1
Số ứng viên (top-K)	5	top-K theo miền

Mô hình baseline **R2** (`il_mp_vne_v17`) là mạng chính sách chỉ qua giai đoạn học bắt chước, chưa tinh chỉnh tăng cường, dùng để cô lập đóng góp của giai đoạn học tăng cường như phân tích ở Mục 5.4.1.